



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

**Συστήμα Πρόγνωσης Συντήρησης Μηχανολογικού
Εξοπλισμού και Προμηθειών με χρήση Μηχανικής
Μάθησης**

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΠΑΠΑΧΡΙΣΤΟΦΙΛΟΥ ΣΑΡΑΝΤΗ

Επιβλέπων: Χρήστος Ζαρολιάγκης

Πατρα, Οκτώβριος 2024



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟ-
ΡΙΚΗΣ

Συστήμα Πρόγνωσης Συντήρησης Μηχανολογικού Εξοπλισμού και Προμηθειών με χρήση Μηχανικής Μάθησης

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΠΑΠΑΧΡΙΣΤΟΦΙΛΟΥ ΣΑΡΑΝΤΗ

Επιβλέπων: Χρήστος Ζαρολιάγκης

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 19η Δεκεμβρίου 2016.

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....
Χρήστος Ζαρολιάγκης
Καθηγητής

.....
Σπυρίδων Κοντογιάννης
Καθηγητής

.....
Σπυρίδων Σιούτας
Καθηγητής

Πατρα, Οκτώβριος 2024



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟ-
ΡΙΚΗΣ

Copyright ©-All rights reserved Παπαχριστοφίλου Σαράντης, 2024.

Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

Υπεύθυνη Δήλωση

Βεβαιώνω ότι είμαι συγγραφέας αυτής της πτυχιακής εργασίας, και ότι κάθε βοήθεια την οποία είχα για την προετοιμασία της είναι πλήρως αναγνωρισμένη και αναφέρεται στην πτυχιακή εργασία. Επίσης έχω αναφέρει τις όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε αυτές αναφέρονται ακριβώς είτε παραφρασμένες. Επίσης, βεβαιώνω ότι αυτή η πτυχιακή εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για τις απαιτήσεις του προγράμματος σπουδών του τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

(Υπογραφή)

.....

Παπαχριστοφίλου Σαράντης

Περίληψη

Η σύγχρονη βιομηχανία αποτελεί έναν χώρο, που χαρακτηρίζεται από συνεχείς τεχνολογικές εξελίξεις και αυξημένη ανταγωνιστικότητα. Η ανάγκη για αποτελεσματική λειτουργία του μηχανολογικού εξοπλισμού κρίνεται επιτακτική, καθώς ακόμα και η παραμικρή υποβάθμιση της απόδοσής του μπορεί να οδηγήσει σε χαμηλής ποιότητας παραγωγή, ατυχήματα και σοβαρές οικονομικές απώλειες. Ως εκ τούτου, δίνεται μεγάλη βαρύτητα στην συνεχή εμποτεία των συστημάτων παραγωγής, προκειμένου να επιλεγεί η κατάλληλη χρονική στιγμή της συντήρησής τους, η οποία θα έχει ως αποτέλεσμα την πρόληψη ανεπιθύμητων διακοπών και την αποτελεσματική διαχείριση κινδύνων.

Οι παραπάνω διαδικασίες εντάσσονται πλέον στην “Βιομηχανία 4.0”, στην οποία αξιοποιούνται το Διαδίκτυο των Αντικειμένων και η Μηχανική Μάθηση με βασικούς στόχους την παρακολούθηση και την πρόγνωση συντήρησης μηχανολογικού εξοπλισμού. Ειδικότερα, μοντέλα Μηχανικής Μάθησης αξιοποιούν δεδομένα που συλλέγονται μέσω αισθητήρων και εστιάζουν σε δύο βασικά ζητήματα. Το πρώτο αφορά τον εντοπισμό ανωμαλιών και την ταξινόμηση του εξοπλισμού σε υγιή ή σε εξοπλισμό που χρήζει συντήρησης, ενώ το δεύτερο εστιάζει, βασισμένο σε προηγούμενους κύκλους λειτουργίας, στην πρόβλεψη της εναπομείνουσας χρήσιμης ζωής μίας μηχανής. Συνεπώς, στα πλαίσια της διπλωματικής αυτής:

- Έγινε κριτική επισκόπηση της υπάρχουσας βιβλιογραφίας η οποία αφορά την “Βιομηχανία 4.0”, τις τεχνολογίες πρόγνωσης συντήρησης και την αξιοποίηση της Μηχανικής Μάθησης στον εντοπισμό και την πρόβλεψη προβλημάτων.
- Ερευνήθηκαν ήδη υπάρχοντα συστήματα Πρόγνωσης Συντήρησης Μηχανολογικού Εξοπλισμού και αναζητήθηκαν διαθέσιμα σύνολα δεδομένων από πραγματικές μηχανές.
- Αναπτύχθηκε σύστημα Εντοπισμού Ανωμαλιών στα μηχανολογικά εξαρτήματα μίας Μηχανής Αλέσματος με χρήση διαφόρων μοντέλων Μηχανικής Μάθησης.
- Αναπτύχθηκε σύστημα Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής ενός κινητήρα αεροσκάφους, χρησιμοποιώντας το σύνολο δεδομένων “C-MAPSS” της NASA και πληθώρα μοντέλων Μηχανικής Μάθησης.
- Πειραματική Αξιολόγηση και Σύγκριση των μοντέλων που χρησιμοποιήθηκαν στα δύο συστήματα με διαδεδομένες μετρικές αξιολόγησης.

Λέξεις Κλειδιά

Βιομηχανία 4.0, Μηχανική Μάθηση, Διαδίκτυο των Αντικειμένων, Πρόγνωση Συντήρησης, Εντοπισμός Ανωμαλιών, Εναπομείνουσα Χρήσιμη Ζωή.

Abstract

Modern industry is an area characterized by continuous technological developments and increased competitiveness. The need for efficient operation of mechanical equipment is considered imperative, as even the slightest degradation of its performance can lead to low-quality production, accidents and serious financial losses. Consequently, great importance is given to the continuous supervision of the production systems, in order to choose the appropriate moment of their maintenance, which will result in the prevention of unwanted interruptions and effective risk management.

The above processes are now part of “Industry 4.0”, in which the Internet of Things and Machine Learning are utilized with the main objectives of monitoring and forecasting the maintenance of mechanical equipment. In particular, Machine Learning models leverage data from sensors and focus on two key issues. The first concerns the detection of anomalies and the classification of equipment as healthy or in need of maintenance, while the second focuses, based on previous operating cycles, on predicting the remaining useful life of a machine. Therefore, within the framework of this diploma:

- A critical review was made of the existing literature regarding “Industry 4.0”, predictive maintenance technologies and the use of Machine Learning in problem detection and prediction.
- Already existing Machinery Maintenance Prediction systems were investigated and available datasets from real machines were searched.
- An anomaly detection system was developed in the mechanical parts of a Milling Machine using various Machine Learning models.
- An aircraft engine Remaining Lifetime Prediction system was developed using the NASA “C-MAPSS” dataset and a variety of Machine Learning models.
- Experimental Evaluation and Comparison of the models used in the two systems with common evaluation metrics.

Keywords

Industry 4.0, Machine Learning, Internet of Things, Predictive Maintenance, Anomaly Detection, Remaining Useful Life.

Ευχαριστίες

Με την παρούσα διπλωματική εργασία ολοκληρώνονται οι σπουδές μου στο προπτυχιακό πρόγραμμα σπουδών του τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

Στις σπουδές μου ήταν καθοριστική η συμβολή των καθηγητών μου στα γνωστικά αντικείμενα που παρακολούθησα, στους οποίους οφείλω να εκφράσω τις ειλικρινείς μου ευχαριστίες για τη συμβολή τους στην ολοκλήρωση των σπουδών μου.

Ιδιαίτερα επιθυμώ να ευχαριστήσω τον καθηγητή μου και επιβλέποντα της παρούσας διπλωματικής εργασίας, κ. Χρήστο Ζαρολιάγκη για την δυνατότητα που μου έδωσε να πραγματοποιήσω αυτή την διπλωματική. Επίσης θα ήθελα να ευχαριστήσω τον κ. Δημήτριο Αμαξηλάτη, για τον χρόνο που διέθεσε, την επιστημονική και συμβουλευτική καθοδήγηση που μου προσέφερε σε όλα τα στάδια εκπόνησης της εργασίας με τις εποικοδομητικές παρατηρήσεις του.

Τέλος, οφείλω να ευχαριστήσω την οικογένειά μου, για τη συμπαράσταση και την υπομονή τους όλα αυτά τα χρόνια, αλλά και τους φίλους μου που έκαναν τα χρόνια φοίτησής μου στο τμήμα όμορφα.

Περιεχόμενα

Περίληψη	i
Abstract	iii
Ευχαριστίες	v
Περιεχόμενα	ix
Κατάλογος Σχημάτων	xiii
1 Εισαγωγή	1
1.1 Κίνητρο και Σημασία	1
1.2 Στόχος	2
1.3 Συνεισφορά	3
1.4 Οργάνωση της Εργασίας	4
2 Θεωρητικό υπόβαθρο	6
2.1 Μηχανική Μάθηση	6
2.1.1 Ορισμοί Μηχανικής Μάθησης	7
2.1.2 Τύποι Μάθησης: Εποπτευόμενη Μάθηση (Supervised)	7
2.1.3 Τύποι Μάθησης: Μη Εποπτευόμενη Μάθηση (Non Supervised)	9
2.1.4 Τύποι Μάθησης: Βαθιά Μάθηση (Deep Learning)	10
2.2 Μοντέλα Εποπτευόμενης Μηχανικής Μάθησης	12
2.2.1 Αλγόριθμος Τυχαίου Δάσους (Random Forest)	12
2.2.2 Δέντρα Απόφασης (Decision Trees)	13
2.2.3 Μηχανές Διανυσματικής Στήριξης (Support Vector Machines)	14
2.2.4 Αφελής Μπεϋζιανός Ταξινομητής (Naive Bayes)	16
2.2.5 Ταξινομητής K-Κοντινότερων Γειτόνων (K-Nearest Neighbors)	17
2.2.6 Γραμμική Παλινδρόμηση (Linear Regression)	18
2.2.7 Λογιστική Παλινδρόμηση (Logistic Regression)	20
2.2.8 Ακραία Ενίσχυση Κλίσης (XGBoost)	21
2.3 Μοντέλα Μη Εποπτευόμενης Μηχανικής Μάθησης	23
2.3.1 K-Μέσοι (K-Means)	23

2.3.2	Ισορροπημένη Επαναληπτική Μείωση και Ομαδοποίηση με Χρήση Ιεραρχιών (BIRCH)	24
2.3.3	Ιεραρχική Ομαδοποίηση (Hierarchical Clustering)	25
2.4	Μοντέλα Βαθιάς Μηχανικής Μάθησης	25
2.4.1	Δίκτυα Μακράς Βραχύχρονης Μνήμης (Long - Short Term Memory)	25
3	Συντήρηση Μηχανολογικού Εξοπλισμού	28
3.1	Συντήρηση Μηχανολογικού Εξοπλισμού	28
3.1.1	Βιομηχανία 4.0	28
3.1.2	Είδη Στρατηγικών Συντήρησης	30
3.2	Προγνωστική Συντήρηση και Μηχανική Μάθηση	31
3.2.1	Ανίχνευση Βλάβης-Ανωμαλίας	32
3.2.2	Πρόβλεψη Εναπομείναςας Χρήσιμης Ζωής	34
3.2.3	Οφέλη της Μηχανικής Μάθησης στην Προγνωστική Συντήρηση	36
3.2.4	Προκλήσεις στην Εφαρμογή Τεχνικών Μηχανικής Μάθησης για Προγνωστική Συντήρηση	37
4	Σύστημα Ανίχνευσης Ανωμαλιών	38
4.1	Εργαλεία που Χρησιμοποιήθηκαν	38
4.2	Σύνολο Δεδομένων	39
4.3	Προεπεξεργασία Δεδομένων	40
4.3.1	Περιγραφική Ανάλυση Συνόλου	40
4.3.2	Μετατροπή Κατηγορικών Δεδομένων σε Αριθμητικά	41
4.3.3	Διαχωρισμός και Υπερδειγματοληψία Συνόλου	41
4.3.4	Κλιμάκωση Τιμών	42
4.4	Προετοιμασία Μοντέλων και Υλοποίηση Συστήματος	44
4.4.1	Αλγόριθμοι που Χρησιμοποιήθηκαν	44
4.4.2	Μέθοδοι Λειτουργίας	44
4.4.3	Υλοποίηση Αλγορίθμου Τυχαίου Δάσους (Random Forest)	46
4.4.4	Υλοποίηση Μηχανής Διανυσματικής Στήριξης (SVM)	47
4.4.5	Υλοποίηση Λογιστικής Παλινδρόμησης (Logistic Regression)	47
4.4.6	Υλοποίηση Κ-Πλησιέστερων Γειτόνων (KNN)	48
4.4.7	Υλοποίηση Αφελή Μπεϋζιανού Ταξινομητή (Naive Bayes)	48
4.4.8	Υλοποίηση Αλγορίθμου Κ-Μέσων (K-Means)	49
4.4.9	Υλοποίηση Ισορροπημένης Επαναληπτικής Μείωσης και Ομαδοποίησης με Χρήση Ιεραρχιών (BIRCH)	49
4.4.10	Υλοποίηση Ιεραρχικής Ομαδοποίησης (Hierarchical Clustering)	50
5	Σύστημα Πρόβλεψης Εναπομείναςας Χρήσιμης Ζωής	52
5.1	Εργαλεία που Χρησιμοποιήθηκαν	52
5.2	Σύνολο Δεδομένων	52
5.3	Προεπεξεργασία Δεδομένων	54

5.3.1 Προσθήκη Στήλης RUL στο Dataframe	54
5.3.2 Αφαίρεση μη-χρήσιμων χαρακτηριστικών	55
5.3.3 Προσαρμογή Συνόλου Δοκιμής	56
5.3.4 Κλιμάκωση Τιμών	57
5.4 Προετοιμασία Μοντέλων και Υλοποίηση Συστήματος	58
5.4.1 Αλγόριθμοι που Χρησιμοποιήθηκαν και Μέθοδοι Λειτουργίας	58
5.4.2 Υλοποίηση Αλγορίθμου Τυχαίου Δάσους (Random Forest)	59
5.4.3 Υλοποίηση Μηχανής Διανυσματικής Στήριξης (SVM)	60
5.4.4 Υλοποίηση Γραμμικής Παλινδρόμησης (Linear Regression)	60
5.4.5 Υλοποίηση Κ-Πλησιέστερων Γειτόνων (KNN)	61
5.4.6 Υλοποίηση Ακραίας Ενίσχυσης Κλίσης (XGBoost)	62
6 Νευρωνικό Δίκτυο Μακράς-Βραχύχρονης Μνήμης	63
6.1 Εργαλεία που Χρησιμοποιήθηκαν	64
6.1.1 Tensorflow	64
6.1.2 Keras	64
6.2 Προετοιμασία Συνόλου Δεδομένων	64
6.2.1 Συναρτήσεις Προετοιμασίας Δεδομένων	65
6.2.2 Προεπεξεργασία Συνόλου Δεδομένων	67
6.3 Αρχιτεκτονική Αναδρομικού Νευρωνικού Δικτύου	70
6.3.1 Εκπαίδευση LSTM Μοντέλου	71
7 Πειραματική Αξιολόγηση	74
7.1 Μετρικές Αξιολόγησης στο πρόβλημα Ταξινόμησης	74
7.2 Μετρικές Αξιολόγησης στο πρόβλημα Παλινδρόμησης	76
7.3 Μετρικές Αξιολόγησης στο πρόβλημα Ομαδοποίησης	77
7.4 Χρόνος Εκπαίδευσης, Ταξινόμησης και Πρόβλεψης	78
7.5 Περιβάλλον Εκτέλεσης	78
7.6 Αποτελέσματα Ανίχνευσης Ανωμαλιών	79
7.6.1 Αποτελέσματα Ταξινόμησης	79
7.6.2 Αποτελέσματα Ομαδοποίησης	85
7.7 Αποτελέσματα Πρόβλεψης Εναπομείνας Χρήσιμης Ζωής	88
7.7.1 Μοντέλα Μηχανικής Μάθησης βιβλιοθήκης Scikit-Learn	88
7.7.2 Αναδρομικό Νευρωνικό Δίκτυο Μακράς Βραχύχρονης Μνήμης	92
7.7.3 Ανάλυση Αποτελεσμάτων Βάσει του Αριθμού Κύκλων Ζωής	94
7.7.4 Συγκεντρωτικά Αποτελέσματα Συστήματος Πρόβλεψης Εναπομείνας Χρήσιμης Ζωής	96
8 Συμπεράσματα και Μελλονικοί Στόχοι	97
8.1 Συμπεράσματα	97
8.2 Μελλονικοί Στόχοι	98

Κατάλογος Σχημάτων

1.1 Βιομηχανία 4.0 [20]	1
2.1 Μηχανική Μάθηση [18]	6
2.2 Λειτουργίες Εποπτευόμενης Μηχανικής Μάθησης [23]	8
2.3 Συσταδοποίηση Δεδομένων [1]	9
2.4 Βαθιά Μάθηση [31]	10
2.5 Αναδρομικό Νευρωνικό Δίκτυο [4]	11
2.6 Αναδρομικό Νευρωνικό Δίκτυο [4]	11
2.7 Αλγόριθμος Τυχαίου Δάσους [45]	12
2.8 Παράδειγμα Δέντρου Απόφασης [19]	14
2.9 Μηχανή Διανυσματικής Στήριξης [22]	15
2.10 Υπερεπίπεδο μεταξύ Θετικών και Αρνητικών Δειγμάτων [37]	15
2.11 Ταξινόμηση με Χρήση Kernel [37]	16
2.12 Αλγόριθμος KNN για $K=3$ και $K=6$ [10]	18
2.13 Καλύτερη Fit Line Συνάρτηση [30]	19
2.14 Σιγμοειδής Συνάρτηση [15]	21
2.15 Παράδειγμα Προόδου XGBoost [44]	22
2.16 Αλγόριθμος K-Μέσων [29]	24
2.17 Αλγόριθμος BIRCH [11]	24
2.18 Αλγόριθμος Ιεραρχικής Ομαδοποίησης [29]	25
2.19 Long Short-Term Memory Formation [14]	26
3.1 Βιομηχανία 4.0 [46]	29
3.2 Στρατηγικές Συντήρησης [32]	30
3.3 Ανίχνευση Ανωμαλιών [12]	32
3.4 Βήματα Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής [28]	34
3.5 Πρόβλεψη Εναπομείνουσας Χρήσιμης Ζωής [3]	36
4.1 Ποσοστό Δειγμάτων που ανήκουν στις κλάσεις Failure και Not Failure	39
4.2 Στατιστική Ανάλυση Συνόλου Δεδομένων	40
4.3 Πλήθος Δειγμάτων Κάθε Κλάσης έπειτα από Υπερδειγματοληψία	42
4.4 Έλεγχος Ακραίων Τιμών για κάθε Χαρακτηριστικό του Συνόλου	42
4.5 Δεδομένα Συνόλου Εκπαίδευσης και Δοκιμής έπειτα από Κλιμάκωση	44

4.6	Οπτικοποίηση Μεθόδου Elbow	49
4.7	Silhouette Scores για διαφορετικό αριθμό συστάδων	50
4.8	Δενδρογράμμα Ιεραρχικής Ομαδοποίησης	50
5.1	Σχηματική Απεικόνιση του κινητήρα της εξομοίωσης CMAPSS [25]	53
5.2	Μητρώο Συσχετίσεων με Κάτω Όριο το 0.85	55
5.3	Δεδομένα πριν και μετά το Standardization	57
6.1	Δομή Αναδρομικού Νευρώνα LSTM [7]	63
6.2	Επίπεδα του Νευρωνικού Δικτύου LSTM	71
7.1	Μητρώο Σύγχησης	75
7.2	ROC Curves	76
7.3	Αποτελέσματα Ακρίβειας Μοντέλων	79
7.4	Αποτελέσματα Ορθότητας Μοντέλων	80
7.5	Αποτελέσματα Ανάκλησης Μοντέλων	81
7.6	Αποτελέσματα F1-Score Μοντέλων	82
7.7	Μητρώο Σύγχυσης Μοντέλων Λογιστικής Παλινδρόμησης και Τυχάιου Δάσους	83
7.8	Μητρώο Σύγχυσης KNN, Naive Bayes, SVM	83
7.9	Χαρακτηριστικές Καμπύλες Δέκτη Μοντέλων Λογιστικής Παλινδρόμησης και Τυχάιου Δάσους	84
7.10	Χαρακτηριστικές Καμπύλες Δέκτη KNN, Naive Bayes, SVM	84
7.11	Silhouette Analysis των μοντέλων	86
7.12	Τρισδιάστατη Οπτικοποίηση των συστάδων των μοντέλων	87
7.13	Μέσο Τετραγωνικό Σφάλμα Μοντέλων	88
7.14	Μέσο Απόλυτο Σφάλμα Μοντέλων	89
7.15	Συντελεστής Προσδιορισμού (R^2) Μοντέλων	90
7.16	Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στον αλγόριθμο Τυχάιου Δάσους	90
7.17	Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στο XGBoost .	91
7.18	Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στον αλγόριθμο KNN	91
7.19	Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στην SVM . . .	91
7.20	Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στην Γραμμική Παλινδρόμηση	92
7.21	Μέσο Τετραγωνικό Σφάλμα, Μέσο Απόλυτο Σφάλμα, Συντελεστής Προσδιορι- σμού Νευρωνικού Δικτύου	93
7.22	Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στο Αναδρομικό Νευρωνικό Δίκτυο	93
7.23	Σύγκριση Αξιολόγησης Αλγορίθμου Τυχάιου Δάσους και Αναδρομικού Νευρω- νικού Δικτύου ανά Τμήμα	94


7.24 Διαφορές Προβλεπόμενων Εναπομείναντων Κύκλων Ζωής από τους Πραγματι- κούς για τις προβλέψεις του Αλγορίθμου Τυχαίου Δάσους	95
7.25 Διαφορές Προβλεπόμενων Εναπομείναντων Κύκλων Ζωής από τους Πραγματι- κούς για τις προβλέψεις του Αναδρομικού Νευρωνικού Δικτύου	95

Κεφάλαιο 1

Εισαγωγή

1.1 Κίνητρο και Σημασία

Η εξέλιξη της βιομηχανίας και η έλευση του Industry 4.0 (Σχήμα 1.1), έχει επαναπροσδιορίσει το τοπίο της σύγχρονης παραγωγικής διαδικασίας. Αυτή η θεμελιώδης αλλαγή, που χαρακτηρίζεται από την εφαρμογή ψηφιακών μέσων και την ανάλυση δεδομένων, προσφέρει πρωτοφανή επίπεδα αυτοματισμού, αποτελεσματικότητας και εποπτείας του μηχανολογικού εξοπλισμού. Την ίδια ώρα η συνεχής και αδιάλειπτη λειτουργία του μηχανολογικού εξοπλισμού είναι πλέον κρίσιμης σημασίας, καθώς ακόμη και η παραμικρή απόκλιση στην απόδοσή του μπορεί να οδηγήσει σε ανεπιθύμητες διακοπές παραγωγής και σοβαρές οικονομικές απώλειες. Η ανάγκη για προληπτική και προγραμματισμένη συντήρηση του εξοπλισμού γίνεται ολοένα και επιτακτικότερη, προκειμένου να διασφαλιστεί η συνεχής και απρόσκοπτη λειτουργία των βιομηχανικών διεργασιών. Συνεπώς, οι βιομηχανίες αγκαλιάζουν αυτήν την εποχή μετασχηματισμού, ενσωματώνοντας προηγμένες τεχνολογίες όπως το Διαδίκτυο των Αντικειμένων και η Μηχανική Μάθηση, με αποτέλεσμα να ξεπερνώνται τα παραδοσιακά όρια ελέγχου και να επιτυγχάνεται πλήρης διασύνδεση στην γραμμή παραγωγής.



Σχήμα 1.1: Βιομηχανία 4.0 [20]

Στο επίκεντρο αυτής της βιομηχανικής εξέλιξης βρίσκεται η έννοια της Προγνωστικής Συντήρησης, μιας στρατηγικής που στοχεύει στη μεγιστοποίηση του χρόνου λειτουργίας του εξοπλισμού και στην ελαχιστοποίηση μη προγραμματισμένων διακοπών λειτουργίας. Σε αντίθεση με τις παραδοσιακές προσεγγίσεις διορθωτικής(Reactive) και προληπτικής(Preventive) συντήρησης, οι οποίες είναι εγγενώς αναποτελεσματικές και συχνά οδηγούν σε δαπανηρές διακοπές, η Προγνωστική Συντήρηση προβλέπει τις αστοχίες του εξοπλισμού πριν αυτές συμβούν. Εκμεταλλευόμενοι δεδομένα που έχουν συλλεχθεί από αισθητήρες και τη δύναμη των αλγορίθμων Μηχανικής Μάθησης, οι οργανισμοί μπορούν να μεταθούν από μια αντιδραστική στάση σε ένα πρότυπο προληπτικής συντήρησης, βελτιστοποιώντας έτσι την απόδοση των μηχανών και την κατανομή πόρων. Πλέον, εντοπίζονται προληπτικά πιθανές αστοχίες του μηχανολογικού εξοπλισμού και υποβάθμιση στην απόδοσή του, έτσι ώστε οι βιομηχανίες να μπορούν να εφαρμόσουν στοχευμένες παρεμβάσεις συντήρησης και να περιορίσουν στο ελάχιστο ανεπιθύμητες και κοστοβόρες διακοπές. Όλα αυτά επιτρέπουν τη λήψη ενημερωμένων αποφάσεων, δίνοντας τη δυνατότητα στους ενδιαφερόμενους να βελτιστοποιήσουν τα χρονοδιαγράμματα συντήρησης και να εξορθολογίσουν τις λειτουργίες τους πιο αποτελεσματικά.

Η επιτυχία της εφαρμογής της Προγνωστικής Συντήρησης σε πρώτο χρόνο εξαρτάται από την αξιοποίηση του Διαδικτύου των Αντικειμένων και συγκεκριμένα από την ποιότητα και ποσότητα των δεδομένων που έχουν συλλεχθεί. Τα δεδομένα αυτά εν συνεχεία επεξεργάζονται και χρησιμοποιούνται για την εκπαίδευση Αλγορίθμων Μηχανικής Μάθησης, οι οποίοι μπορούν να εντοπίσουν πρότυπα που προβλέπουν πιθανές βλάβες, επιτρέποντας έτσι την προγραμματισμένη και αποτελεσματική αντιμετώπισή τους προτού αυτές οδηγήσουν σε διακοπή της παραγωγής. Ειδικότερα, τα μοντέλα Μηχανικής Μάθησης στο πλαίσιο της Προγνωστικής Συντήρησης στοχεύουν στην ανίχνευση ανωμαλιών στην απόδοση του εξοπλισμού και στην πρόβλεψη της εναπομείνουσας χρήσιμης ζωής των μηχανών. Με τον τρόπο αυτό το κόστος παραγωγής μειώνεται κατακόρυφα σε σχέση με τις περιπτώσεις διορθωτικής(Reactive) και προληπτικής(Preventive) συντήρησης, καθώς αυτή υλοποιείται μόνο όταν υπάρχει πραγματική ανάγκη, την ώρα που ο χρόνος διακοπής λειτουργίας του συστήματος ελαχιστοποιείται.

Συμπερασματικά, η Μηχανική Μάθηση αναδεικνύεται ως ένας μετασχηματιστικός παράγοντας της Προγνωστικής Συντήρησης στον μηχανολογικό εξοπλισμό και σε συνδυασμό με την ανάλυση δεδομένων που δημιουργούνται από το IoT, οι οργανισμοί μπορούν να ξεκλείδωσουν νέα επίπεδα απόδοσης και αξιοπιστίας. Για τον λόγο αυτό οι βιομηχανίες στρέφονται ολοένα και περισσότερο στην ψηφιακή βιομηχανική επανάσταση, γεγονός που καθιστά την δημιουργία συστημάτων Πρόγνωσης Συντήρησης Μηχανολογικού Εξοπλισμού μία απαραίτητη και απαιτητική διαδικασία.

1.2 Στόχος

Στα πλαίσια της παρούσας διπλωματικής εργασίας, βασικός στόχος είναι η υλοποίηση ενός συστήματος Πρόγνωσης Συντήρησης Μηχανολογικού Εξοπλισμού και Προμηθειών

με χρήση Μηχανικής Μάθησης. Συλλέγοντας και επεξεργάζοντας σύνολα δεδομένων από μηχανές εκπαιδεύουμε πληθώρα μοντέλων Μηχανικής Μάθησης και εστιάζουμε στην υλοποίηση δύο συγκεκριμένων διαδικασιών. Τα μοντέλα αυτά προέρχονται από διαφορετικές βιβλιοθήκες, έτσι ώστε να υπάρχει πληρέστερη εικόνα σχετικά με την απόδοση των εκάστοτε τεχνολογιών. Όσον αφορά τις διαδικασίες, η πρώτη αφορά την ταξινόμηση του εξοπλισμού σε κατηγορίες ανάλογα με την κατάσταση της υγείας του, ενώ η δεύτερη στοχεύει βασισμένη σε μετρήσεις προηγούμενων κύκλων ζωής να προβλέψει την εναπομείνασα χρήσιμη ζωή μίας μηχανής. Για την αξιολόγηση των δύο αυτών λειτουργιών χρησιμοποιούνται διαδεδομένες μετρικές αξιολόγησης, προκειμένου να παρουσιαστούν οι δυνατότητες του κάθε μοντέλου.

1.3 Συνεισφορά

Σύμφωνα με τους στόχους που τίθενται στην ενότητα 1.2, η παρούσα διπλωματική συνεισφέρει στον τομέα της Πρόγνωσης Συντήρησης μηχανολογικού εξοπλισμού με την ανάπτυξη και την αξιολόγηση ενός συστήματος, το οποίο χρησιμοποιεί ποικίλα μοντέλα Μηχανικής Μάθησης και έρχεται να επισφραγίσει την αντικατάσταση των κλασικών μεθόδων συντήρησης όπως η Διορθωτική(Reactive) και η Προληπτική(Preventive) με την Προγνωστική(Predictive).

Για την επίτευξη των παραπάνω γίνεται αρχικά μία αναζήτηση και μελέτη συνόλων δεδομένων που αφορούν μηχανολογικό εξοπλισμό και είναι διαθέσιμα στο διαδίκτυο. Συγκρίνοντας τα εντοπίζονται διαφορές μεταξύ πραγματικών δεδομένων και δεδομένων που έχουν προκύψει έπειτα από προσομοίωση, ενώ ταυτόχρονα παρατηρούνται τα στοιχεία εκείνα, τα οποία ευθύνονται για την υποβάθμιση της απόδοσης της εκάστοτε μηχανής. Μέσω ανάλυσης μεγάλων όγκων δεδομένων ανακαλύπτονται πρότυπα, τάσεις και συσχετίσεις στοιχείων που μπορούν να είναι χρήσιμα για τη βελτίωση του συστήματος πρόβλεψης συντήρησης.

Στον τομέα της ανίχνευσης ανωμαλιών στην απόδοση του εξοπλισμού και ειδικότερα στην ταξινόμησή του σε κατηγορίες ανάλογα με την κατάσταση της υγείας του, χρησιμοποιούνται αλγόριθμοι Μηχανικής Μάθησης που είναι ειδικοί σε προβλήματα ταξινόμησης. Τα μοντέλα αυτά αξιολογούνται με βάση την ακρίβειά τους, την ανάκληση, το F1-Score και την Log-Loss, προκειμένου να εντοπιστεί το ιδανικότερο και να έχουμε τα καλύτερα αποτελέσματα. Στην προσπάθεια για καλύτερα αποτελέσματα γίνεται επαναδειγματοληψία σε σύνολα δεδομένων που δεν είχαν ίσο αριθμό δειγμάτων σε κάθε κλάση. Αξίζει να σημειωθεί πως η ακρίβεια αυξάνεται όταν από τα σύνολα δεδομένων αφαιρούνται τα στοιχεία εκείνα, τα οποία δεν σχετίζονται ιδιαίτερα με την έξοδο του μοντέλου.

Αντίστοιχα με τον τομέα της ανίχνευσης ανωμαλιών, στο πεδίο πρόβλεψης εναπομείνουσας χρήσιμης ζωής πραγματοποιείται εκπαίδευση πολλών και διαφορετικών αλγορίθμων που είναι ειδικοί σε προβλήματα πρόβλεψης. Στην περίπτωση αυτή γίνεται αξιολόγηση με βάση το Μέσο Τετραγωνικό Σφάλμα και την ρίζα του, το Μέσο Απόλυτο Σφάλμα και το R2-Score, για την ανάδειξη του καταλληλότερου μοντέλου. Ιδιαίτερο ενδιαφέρον παρουσιάζουν προσεγγίσεις όπου τέθηκε άνω όριο στις προβλέψεις των μοντέλων ή η πρόβλεψη έγινε υπολογίζοντας μέσους όρους άλλων προβλέψεων. Ακόμα, συμπεραίνουμε πως η ακρίβεια των

μοντέλων αυξάνεται αρκετά, όταν οι κύκλοι ζωής της μηχανής που απομένουν λιγοστεύουν και άρα εντάσσεται στην κατηγορία υψηλού ρίσκου.

Όσον αφορά το σύστημα Πρόγνωσης εξ ολοκλήρου, χρησιμοποιούνται μοντέλα από διαφορετικές βιβλιοθήκες, με σκοπό να υπάρχει μία πλήρης εικόνα στο πεδίο της Μηχανικής Μάθησης. Κάθε αλγόριθμος έχει τις δικές του ιδιαιτερότητες και παράγει μοναδικά αποτελέσματα. Έτσι, παρέχουμε μία εικόνα για τις δυνατότητες των βιβλιοθηκών Scikit Learn και Tensorflow , συγκρίνοντας τα αποτελέσματα των μοντέλων, τα οποία είναι ορισμένα και στις δύο βιβλιοθήκες. Τέλος, ανάλογα με τα χαρακτηριστικά του εκάστοτε μοντέλου, αναζητούμε τις παραμέτρους εκείνες που είναι ιδανικές για τις ανάγκες του συστήματος, χρησιμοποιώντας την τεχνική Grid Search .

1.4 Οργάνωση της Εργασίας

Η δομή των υπόλοιπων κεφαλαίων της εργασίας έχει ως εξής:

Στο **2ο Κεφάλαιο** παρουσιάζονται το Θεωρητικό Υπόβαθρο και οι βασικές έννοιες που πραγματεύεται η παρούσα διπλωματική εργασία. Πιο συγκεκριμένα, δίνονται βασικοί ορισμοί γύρω από το πεδίο της συντήρησης μηχανολογικού εξοπλισμού και προμηθειών, ενώ περιγράφεται η σύνδεσή του με το Διαδίκτυο των Αντικειμένων και τη Μηχανική Μάθηση. Η έννοια της Μηχανικής Μάθησης και οι βασικές αρχές της αναλύονται σε ένα γενικό πλαίσιο, ωστόσο γίνεται και αναφορά στην εφαρμογή της σε βιομηχανικές διαδικασίες. Τέλος, δίνεται σύντομη περιγραφή των μοντέλων Μηχανικής Μάθησης που χρησιμοποιήθηκαν στο πλαίσιο του συστήματος Πρόγνωσης Συντήρησης, όπως και των μετρικών μέσω των οποίων έγινε η αξιολόγησή τους.

Στο **3ο Κεφάλαιο** γίνεται μία γενική παρουσίαση της αρχιτεκτονικής του συστήματος που έχει υλοποιηθεί, τονίζοντας την χρησιμότητα και την αξιοπιστία του στο πλαίσιο της προβλεπτικής συντήρησης. Η υλοποίηση αποτελείται, αρχικά, από την συλλογή συνόλων δεδομένων σχετικά με μηχανολογικό εξοπλισμό, τα οποία είναι διαθέσιμα στο διαδίκτυο και την προεπεξεργασία τους. Εν συνεχεία, τα δεδομένα αυτά τροφοδοτούνται σε αλγόριθμους Μηχανικής Μάθησης για την εκπαίδευσή τους και ακολουθεί η παραγωγή των αποτελεσμάτων.

Το **Κεφάλαιο 4** συνεχίζει την ενασχόληση με το σύστημα Πρόγνωσης Συντήρησης, ωστόσο εστιάζει στη πρώτη από τις δύο λειτουργίες του, η οποία είναι η ανίχνευση ανωμαλιών στην απόδοση της μηχανής και η ταξινόμησή της σε κατηγορίες ανάλογα την κατάσταση της υγείας της. Παρουσιάζονται όλες οι τεχνικές προεπεξεργασίας των δεδομένων, καθώς και οι αλγόριθμοι που εκπαιδεύτηκαν πάνω σε αυτά.

Από την άλλη στο **5ο Κεφάλαιο** περιγράφεται η δεύτερη λειτουργία του συστήματος και ειδικότερα ο τρόπος με τον οποίο επιτυγχάνονται οι προβλέψεις σχετικά με τους χρήσιμους κύκλους ζωής που απομένουν σε μηχανολογικό εξοπλισμό. Παρόμοια με το προηγούμενο κεφάλαιο, παρατίθεται ο τρόπος προσέγγισης του συνόλου δεδομένων και απαριθμούνται τα μοντέλα Μηχανικής Μάθησης, τα οποία αξιοποιούνται για να προβλέψουμε με ακρίβεια την RUL των μηχανών.

Στο **6ο Κεφάλαιο** παρουσιάζονται τα πειράματα που διεξήχθησαν για την αξιολόγηση της λειτουργίας του συστήματος. Στο πλαίσιο της διπλωματικής αυτής εργασίας τα πειράματα χωρίστηκαν σε δύο κατηγορίες, μία για κάθε λειτουργία του συστήματος. Τα αποτελέσματα αυτών των πειραμάτων παρουσιάζονται και σχολιάζονται επίσης σε αυτό το κεφάλαιο.

Τέλος, στο **Κεφάλαιο 7** παρατίθενται τα συμπεράσματα που εξήχθησαν από αυτή τη διπλωματική εργασία. Βάση των αποτελεσμάτων αυτών παρουσιάζονται, ακόμη, οι μελλοντικοί στόχοι και οι επεκτάσεις του συστήματος που υλοποιήθηκε.

Κεφάλαιο 2


Θεωρητικό υπόβαθρο

Στόχος της ενότητας αυτής είναι να παρουσιάσει τις βασικές έννοιες και ορισμούς, οι οποίοι αφορούν την επιστήμη των υπολογιστών και θα χρησιμοποιηθούν στο υπόλοιπο μέρος της εργασίας. Ειδικότερα, περιγράφονται το πεδίο της Μηχανικής Μάθησης και τα μοντέλα, τα οποία αξιοποιήθηκαν στα συστήματα που υλοποιήθηκαν.

2.1 Μηχανική Μάθηση

Η Μηχανική Μάθηση αποτελεί έναν κλάδο της επιστήμης των υπολογιστών, ο οποίος σε γενικές γραμμές στοχεύει στο να επιτρέψει στους υπολογιστές να “μάθουν” χωρίς να προηγείται ο απευθείας προγραμματισμός [24]. Έχει ρίζες στην εξέλιξη της Τεχνητής Νοημοσύνης το 1950 και εστιάζει σε πρακτικές εφαρμογές, όπως η πρόβλεψη και η βελτιστοποίηση. Ο υπολογιστής στην Μηχανική Μάθηση μαθαίνει βελτιώνοντας την απόδοσή του σε διαδικασίες μέσω “έμπειρίας”. Στην πράξη “έμπειρία” σημαίνει προσαρμογή σε δεδομένα και διαχείρισή τους με πιο αποτελεσματικό τρόπο, χωρίς αρκετό προγραμματισμό και πολυπλοκότητα.

Στο σχήμα 2.1 παρουσιάζονται όλες οι βασικές πτυχές της Μηχανικής Μάθησης:



Σχήμα 2.1: Μηχανική Μάθηση [18]

Όσον αφορά τις εφαρμογές της Μηχανικής Μάθησης αυτές αφορούν ποικίλα πεδία, από τους υπολογισμούς που υλοποιούν οι συσκευές που χρησιμοποιούμε καθημερινά, μέχρι την ιατρική και την βιομηχανία. Συνεπώς, έχουν αναπτυχθεί πολλοί και διαφορετικοί αλγόριθμοι, προκειμένου να υπάρχει ο κατάλληλος για κάθε λογής πρόβλημα, δίνοντας επιπλέον επιλογές στους μηχανικούς. Συνεπώς, υπάρχουν αρκετά είδη μάθησης, ωστόσο στα πλαίσια του Συστήματος που αναπτύχθηκε παρουσιάζονται και χρησιμοποιούνται τα δύο.

2.1.1 Ορισμοί Μηχανικής Μάθησης

Αποκλειστικός Ορισμός της Μηχανικής Μάθησης δεν υπάρχει, ωστόσο παρακάτω μπορούμε να δούμε τέσσερις βασικούς τεχνικούς και λειτουργικούς ορισμούς όπως υπάρχουν στο διαδίκτυο [18]:

Ένα πρόγραμμα υπολογιστή λέγεται ότι μαθαίνει μέσω εμπειρίας E σε σχέση με κάποια κλάση διεργασιών T και με απόδοση P , εάν η απόδοσή του στις εργασίες του T , όπως μετράται από το P , βελτιώνεται από την εμπειρία E .

Tom M. Mitchell

Η Μηχανική Μάθηση είναι η εκπαίδευση ενός μοντέλου με δεδομένα, η οποία γενικεύει μία απόφαση έναντι μίας μετρικής απόδοσης.

Jason Brownlee

Η Μηχανική Μάθηση είναι ένας κλάδος της τεχνητής νοημοσύνης, στον οποίο ο υπολογιστής δημιουργεί που βασίζονται σε μη επεξεργασμένα δεδομένα που έχουν τροφοδοτηθεί σε αυτόν.
Dictionary.com

Η μηχανική μάθηση είναι ένας επιστημονικός κλάδος, ο οποίος ασχολείται με τον σχεδιασμό και την ανάπτυξη αλγορίθμων που επιτρέπουν στους υπολογιστές να εξελίσσουν συμπεριφορές βασισμένες σε εμπειρικά δεδομένα, όπως δεδομένα από αισθητήρες ή βάσεις δεδομένων.

Wikipedia

2.1.2 Τύποι Μάθησης: Εποπτευόμενη Μάθηση (Supervised)


Οι μέθοδοι και τα μοντέλα εποπτευόμενης μάθησης κάνουν προβλέψεις βασισμένες σε ετικετοποιημένα δεδομένα. Κάθε δείγμα εκπαίδευσης περιλαμβάνει μία είσοδο και την αναμενόμενη έξοδο, έτσι ώστε ο αλγόριθμος έπειτα από την εκπαίδευσή του πάνω σε αυτά τα δείγματα να μπορεί να βγάλει ένα συμπέρασμα - μία βάσιμη τιμή μεταβλητών εξόδου από τις μεταβλητές εισόδου. Στην ουσία, τα δεδομένα έχουν ετικέτες, προκειμένου το μοντέλο να γνωρίζει τα μονοπάτια και τις συνδέσεις που θα πρέπει να αναζητά και να εστιάσει στην παραγωγή μίας σχέσης μεταξύ των στοιχείων εισόδου και εξόδου. Δύο χαρακτηριστικές διαδικασίες εποπτευόμενης μάθησης, με τις οποίες ασχολείται η παρούσα διπλωματική εργασία είναι η ταξινόμηση και η παλινδρόμηση.

Ταξινόμηση (Classification)

Η ταξινόμηση (classification) απεικονίζει τα δεδομένα σε προκαθορισμένες ομάδες ή κατηγορίες - κλάσεις. Αναφέρεται συχνά σαν εποπτευόμενη μάθηση, επειδή οι κατηγορίες - κλάσεις καθορίζονται πριν ακόμα εξεταστούν τα δεδομένα [11]. Στόχος της ταξινόμησης είναι η εύρεση μίας τεχνικής αντιστοίχισης για ένα σύνολο δεδομένων με ένα σύνολο κλάσεων. Οι αλγόριθμοι της διαδικασίας απαιτούν οι κατηγορίες να ορίζονται με βάση τις τιμές των γνωρισμάτων των δεδομένων. Συχνά περιγράφουν αυτές τις κατηγορίες κοιτάζοντας τα χαρακτηριστικά των δεδομένων που είναι ήδη γνωστό ότι ανήκουν στις κατηγορίες. Η αναγνώριση προτύπων (pattern recognition) αποτελεί ένα είδος κατηγοριοποίησης, όπου ένα πρότυπο εισόδου κατηγοριοποιείται σε μία από διάφορες κατηγορίες, με βάση την εγγύτητά του ως προς αυτές τις προκαθορισμένες κατηγορίες. Συνεπώς, την διαδικασία ταξινόμησης η μεταβλητή στόχος είναι διακριτή, ωστόσο υπάρχουν και περιπτώσεις όπου η έξοδος είναι μία συνεχής τιμή, όμως πρόκειται για την πιθανότητα να ανήκει η είσοδος σε μία κλάση.

Παλινδρόμηση (Regression)

Ως Παλινδρόμηση ορίζεται μία στατιστική προσέγγιση, η οποία χρησιμοποιείται για να απεικονιστεί ένα στοιχειώδες δεδομένο σε μία πραγματική μεταβλητή πρόβλεψης. Ο στόχος της παλινδρόμησης περιλαμβάνει την εκμάθηση της συνάρτησης που κάνει την απεικόνιση και συσχετίζει τις μεταβλητές μεταξύ τους. Προϋποθέτει ότι τα σχετικά δεδομένα ταιριάζουν με μερικά γνωστά είδη συνάρτησης (π.χ. γραμμική, λογαριθμική κλπ.) και μετά καθορίζει την καλύτερη συνάρτηση αυτού του είδους που μοντελοποιεί τα δεδομένα που έχουν δοθεί. Ένα είδος ανάλυσης σφάλματος χρησιμοποιείται για να καθορίσει ποια συνάρτηση είναι "ή καλύτερη", με τα πιο διαδεδομένα να είναι το μέσο τετραγωνικό σφάλμα (MSE) και το μέσο απόλυτο σφάλμα (MAE).




Σχήμα 2.2: Λειτουργίες Εποπτευόμενης Μηχανικής Μάθησης [23]

2.1.3 Τύποι Μάθησης: Μη Εποπτευόμενη Μάθηση (Non Supervised)

Η μάθηση χωρίς επίβλεψη είναι ένας κλάδος της μηχανικής μάθησης, ο οποίος ασχολείται με δεδομένα χωρίς ετικέτες. Σε αντίθεση με την επιβλεπόμενη μάθηση, όπου τα δεδομένα επισημαίνονται με μια συγκεκριμένη κατηγορία ή αποτέλεσμα, οι αλγόριθμοι μάθησης χωρίς επίβλεψη έχουν ως αποστολή την εύρεση μοτίβων και σχέσεων εντός των δεδομένων χωρίς καμία προηγούμενη γνώση της σημασίας των δεδομένων. Αυτό καθιστά τη μάθηση χωρίς επίβλεψη ένα ισχυρό εργαλείο για τη διερευνητική ανάλυση δεδομένων, όπου ο στόχος είναι η κατανόηση της υποκείμενης τους δομής.

Συσταδοποίηση (Clustering)

Η συσταδοποίηση στη μη επιβλεπόμενη μηχανική μάθηση είναι η διαδικασία ομαδοποίησης μη επισημειωμένων δεδομένων σε γκρουπ με βάση τις ομοιότητές τους. Ο στόχος της ομαδοποίησης είναι ο εντοπισμός μοτίβων και σχέσεων στα δεδομένα χωρίς πρότερη γνώση της σημασίας τους. Σε γενικές γραμμές αυτή η τεχνική εφαρμόζεται για την ομαδοποίηση δεδομένων λαμβάνοντας υπόψη διαφορετικά μοτίβα, όπως ομοιότητες ή διαφορές, που βρίσκει το εκάστοτε μοντέλο μηχανικής μάθησης. Αυτοί οι αλγόριθμοι χρησιμοποιούνται για την επεξεργασία ακατέργαστων, μη ταξινομημένων αντικειμένων-δεδομένων σε ομάδες.




Σχήμα 2.3: Συσταδοποίηση Δεδομένων [1]

Για παράδειγμα, στο παραπάνω σχήμα (2.3), αρχικά τα δεδομένα παρουσιάζονται χωρίς να έχουν κατηγοριοποιηθεί σε κάποια κλάση και δεν υπάρχει σαφής διάκριση. Δεξιά, τα ίδια δεδομένα έπειτα από την εφαρμογή ενός αλγορίθμου ομαδοποίησης, έχουν χωριστεί σε τρεις ομάδες με βάση τα χαρακτηριστικά τους.

2.1.4 Τύποι Μάθησης: Βαθιά Μάθηση (Deep Learning)

Η Βαθιά Μάθηση είναι ένας κλάδος της Μηχανικής Μάθησης (Σχήμα 2.4), ο οποίος βασίζεται στα Τεχνητά Νευρωνικά Δίκτυα, έναν τύπο υπολογιστικών συστημάτων που προσομοιώνει τον τρόπο με τον οποίο λειτουργεί ο ανθρώπινος εγκέφαλος [38]. Οι αλγόριθμοι βαθιάς μάθησης και τα νευρωνικά δίκτυα αποτελούνται από πολλά επίπεδα διασυνδεδεμένων νευρώνων, οι οποίοι επεξεργάζονται μαζί και μαθαίνουν από τα δεδομένα εισόδου.

Σε ένα εξ ολοκλήρου συνδεδεμένο Βαθύ Νευρωνικό Δίκτυο, υπάρχει ένα επίπεδο εισόδου και ένα ή περισσότερα κρυμμένα επίπεδα συνδεδεμένα το ένα μετά το άλλο. Κάθε νευρώνας δέχεται είσοδο από το προηγούμενο επίπεδο νευρώνων και δίνει την έξοδό του, στην είσοδο του επόμενου επιπέδου, με την διαδικασία αυτή να συνεχίζεται μέχρι το τελικό επίπεδο να παράξει την έξοδο του δικτύου. Τα επίπεδα του νευρωνικού δικτύου μετατρέπουν τα δεδομένα εισόδου μέσω μη γραμμικών μετασχηματισμών, επιτρέποντας στο μοντέλο να μαθαίνει προοδευτικά πολύπλοκες αναπαραστάσεις.




Σχήμα 2.4: Βαθιά Μάθηση [31]

Η Βαθιά Μάθηση βρίσκει εφαρμογή αρκετά συχνά σε πεδία όπως αυτό της αναγνώρισης εικόνας, στην επεξεργασία φυσικής γλώσσας και στην ανάλυση ομιλίας. Τα μοντέλα της μάθησης αυτής τις περισσότερες φορές αποδίδουν καλύτερα από άλλους αλγορίθμους μηχανικής μάθησης, όταν τα προβλήματα που αντιμετωπίζουν είναι πολύπλοκα και αποτελούνται από πολύ μεγάλο όγκο δεδομένων. Επίσης, αξίζει να σημειωθεί πως η Βαθιά Μάθηση μπορεί να εφαρμοστεί σε προβλήματα εποπτευόμενης, μη-εποπτευόμενης και ενισχυτικής μάθησης, χρησιμοποιώντας ποικίλους τρόπους επεξεργασίας.

Αναδρομικά Νευρωνικά Δίκτυα (Recurrent Neural Networks)

Στο πλαίσιο της βαθιάς μάθησης χρησιμοποιούνται πολλοί και διαφορετικοί τύποι νευρωνικών δικτύων. Ένας από αυτούς είναι τα Αναδρομικά Νευρωνικά Δίκτυα [4] ή αλλιώς (RNNs), στα οποία η έξοδος του προηγούμενου βήματος τροφοδοτείται στο επόμενο βήμα ως


είσοδος. Το κύριο και πιο σημαντικό χαρακτηριστικό των Αναδρομικών Νευρωνικών Δικτύων είναι η κρυμμένη του κατάσταση, η οποία θυμάται κάποια πληροφορία για μία ακολουθία.



Σχήμα 2.5: Αναδρομικό Νευρωνικό Δίκτυο [4]

Χρησιμοποιεί τις ίδιες παραμέτρους για κάθε είσοδο και πραγματοποιεί την ίδια διαδικασία σε όλες τις εισόδους και τα κρυμμένα επίπεδα, για την παραγωγή της εξόδου. Υπάρχουν τέσσερις τύποι Αναδρομικών Νευρωνικών Δικτύων ανάλογα τον αριθμό εισόδων και εξόδων: α) Ένα σε ένα, β) Ένα σε πολλά, γ) Πολλά σε ένα, δ) Πολλά σε πολλά.

Η θεμελιώδης μονάδα επεξεργασίας στα Αναδρομικά Νευρωνικά Δίκτυα είναι ο αναδρομικός νευρώνας. Η μονάδα αυτή έχει τη δυνατότητα να διατηρεί μία κρυφή κατάσταση, επιτρέποντας στο δίκτυο να καταγράφει ακολουθιακές εξαρτήσεις απομνημονεύοντας προηγούμενες εισόδους κατά την επεξεργασία. Σε αντίθεση με τα βαθιά νευρωνικά δίκτυα, εδώ τα βάρη παραμένουν ίδια κατά μήκος του δικτύου.



Σχήμα 2.6: Αναδρομικό Νευρωνικό Δίκτυο [4]

Πώς Λειτουργούν τα Αναδρομικά Νευρωνικά Δίκτυα ;

Τα Αναδρομικά Νευρωνικά Δίκτυα αποτελούνται από πολλαπλές σταθερές μονάδες ενεργοποίησης λειτουργίας, μία για κάθε χρονικό βήμα. Κάθε μονάδα έχει μία αρχική κατάσταση, η οποία αποκαλείται κρυμμένη. Αυτή η κρυμμένη κατάσταση διατηρεί την πρότερη γνώση, την οποία έχει το δίκτυο μία δεδομένη στιγμή και ενημερώνεται σε κάθε


χρονικό βήμα για να σημάνει την αλλαγή στη γνώση του δικτύου σχετικά με το παρελθόν. Πιο συγκεκριμένα, η κρυμμένη κατάσταση αλλάζει λαμβάνοντας υπόψη την προηγούμενη κατάσταση και την είσοδο.

2.2 Μοντέλα Εποπτευόμενης Μηχανικής Μάθησης

2.2.1 Αλγόριθμος Τυχαίου Δάσους (Random Forest)

Ο ταξινομητής τυχαίου δάσους αποτελείται από έναν συνδυασμό ταξινομητών δέντρων, όπου κάθε ταξινομητής δημιουργείται χρησιμοποιώντας έναν τυχαίο διάνυσμα που δειγματοληπτείται ανεξάρτητα από το εισερχόμενο διάνυσμα, και κάθε δέντρο δίνει μία ψήφο για την πιο δημοφιλή κλάση για να ταξινομήσει ένα εισερχόμενο διάνυσμα [33].

Ο ταξινομητής τυχαίου δάσους μπορεί να αποτελείται από τη χρήση τυχαία επιλεγμένων χαρακτηριστικών ή συνδυασμών χαρακτηριστικών σε κάθε κόμβο για να αναπτυχθεί ένα δέντρο. Η μέθοδος *bagging*, είναι μια μέθοδος για τη δημιουργία ενός συνόλου εκπαίδευσης από τυχαία N παραδείγματα με επανατοποθέτηση, όπου N είναι το μέγεθος του αρχικού συνόλου εκπαίδευσης, που χρησιμοποιήθηκε για κάθε επιλεγμένο χαρακτηριστικό ή συνδυασμό χαρακτηριστικών. Κάθε δείγμα ταξινομείται λαμβάνοντας την πιο δημοφιλή κλάση που ψηφίστηκε από όλους τους προβλεπτές δέντρων στο δάσος.



Σχήμα 2.7: Αλγόριθμος Τυχαίου Δάσους [45]

Ο σχεδιασμός ενός δέντρου απόφασης απαιτεί την επιλογή ενός μέτρου επιλογής χαρακτηριστικών και μιας μεθόδου κλαδέματος. Υπάρχουν πολλές προσεγγίσεις για την επιλογή χαρακτηριστικών που χρησιμοποιούνται για την επαγωγή δέντρων απόφασης και οι περισσότερες από αυτές αναθέτουν ένα μέτρο ποιότητας απευθείας στο χαρακτηριστικό. Τα πιο συχνά χρησιμοποιούμενα μέτρα επιλογής χαρακτηριστικών στην επαγωγή δέντρων

απόφασης είναι το κριτήριο Ποσοστού Πληροφοριών και ο Δείκτης Gini. Ο ταξινομητής τυχαίου δάσους χρησιμοποιεί τον Δείκτη Gini ως μέτρο επιλογής χαρακτηριστικών, το οποίο μετρά την ανισότητα ενός χαρακτηριστικού σε σχέση με τις κλάσεις. Για ένα δεδομένο σύνολο εκπαίδευσης T , επιλέγοντας ένα δείγμα τυχαία και λέγοντας ότι ανήκει σε κάποια κλάση C_i , ο δείκτης Gini μπορεί να γραφεί ως:

$$f(C_i, T) = \sum_{j=i} \left(\frac{f(C_i, T)}{|T|} \right) \left(\frac{f(C_i, T)}{|T|} \right) \quad (2.1)$$


όπου $f(C_i, T)/|T|$ είναι η πιθανότητα ότι η επιλεγμένη περίπτωση ανήκει στην κλάση C_i .

Κάθε φορά αναπτύσσεται ένα δέντρο στο μέγιστο βάθος σε νέα δεδομένα εκπαίδευσης χρησιμοποιώντας έναν συνδυασμό χαρακτηριστικών. Αυτά τα πλήρως ανεπτυγμένα δέντρα δεν κλαδεύονται. Αυτό είναι ένα από τα κύρια πλεονεκτήματα του ταξινομητή τυχαίου δάσους σε σχέση με άλλες μεθόδους δέντρων απόφασης όπως αυτή που προτάθηκε από τον Quinlan (1993). Οι μελέτες υποδεικνύουν ότι η επιλογή των μεθόδων κλαδέματος, και όχι των κριτηρίων επιλογής χαρακτηριστικών, επηρεάζουν την απόδοση των ταξινομητών που βασίζονται σε δέντρα. Ο Breiman (1999) προτείνει ότι καθώς αυξάνεται ο αριθμός των δέντρων, το σφάλμα γενίκευσης πάντα συγκλίνει ακόμη και χωρίς το κλάδεμα του δέντρου και η υπερπροσαρμογή δεν αποτελεί πρόβλημα λόγω του Ισχυρού Νόμου των Μεγάλων Αριθμών. Ο αριθμός των χαρακτηριστικών που χρησιμοποιούνται σε κάθε κόμβο για να δημιουργηθεί ένα δέντρο και ο αριθμός των δέντρων που θα αναπτυχθούν είναι δύο παράμετροι που ορίζονται από τον χρήστη για τη δημιουργία ενός ταξινομητή τυχαίου δάσους. Σε κάθε κόμβο, μόνο τα επιλεγμένα χαρακτηριστικά εξετάζονται για την καλύτερη διαίρεση. Έτσι, ο ταξινομητής τυχαίου δάσους αποτελείται από N δέντρα, όπου N είναι ο αριθμός των δέντρων που θα αναπτυχθούν, ο οποίος μπορεί να είναι οποιαδήποτε τιμή ορισμένη από τον χρήστη. Για να ταξινομηθεί ένα νέο σύνολο δεδομένων, κάθε δείγμα του νέου αυτού συνόλου δεδομένων περνά μέσα από καθένα από τα N δέντρα. Το δάσος επιλέγει μια κλάση που έχει τις περισσότερες από τις N ψήφους, για αυτήν την περίπτωση.

2.2.2 Δέντρα Απόφασης (Decision Trees)

Τα Δέντρα Απόφασης είναι μια τεχνική για την προσέγγιση διακριτών τιμών μίας μεταβλητής στόχου, στην οποία η συνάρτηση μάθησης αναπαρίσταται με την μορφή ενός δέντρου απόφασης [5]. Ένα δέντρο απόφασης κατηγοριοποιεί παραδείγματα ταξινομώντας τα από τη ρίζα έως κάποιο φύλλο βάσει των τιμών ορισμένων χαρακτηριστικών. Κάθε κόμβος αντιπροσωπεύει κάποια απόφαση (συνθήκη ελέγχου) σε ένα χαρακτηριστικό του δείγματος, ενώ κάθε κλαδί αντιπροσωπεύει μια πιθανή τιμή για το χαρακτηριστικό αυτό. Η ταξινόμηση ενός παραδείγματος ξεκινά από τον κόμβο της ρίζας που ονομάζεται κόμβος απόφασης. Βάσει της τιμής του κόμβου, το δέντρο διασχίζει το κλαδί, το οποίο αντιστοιχεί στην τιμή της εξόδου του χαρακτηριστικού δοκιμής.

Αυτή η διαδικασία συνεχίζεται στο υποδέντρο με επικεφαλής τον νέο κόμβο στο τέλος του προηγούμενου κλαδιού. Τελικά, ο κόμβος-φύλλο υποδηλώνει τις κατηγορίες ταξινόμησης ή την τελική απόφαση. Κατά τη χρήση ενός δέντρου απόφασης, το ενδιαφέρον επικεντρώνεται



Σχήμα 2.8: Παράδειγμα Δέντρου Απόφασης [19]

στο πώς να αποφασιστεί ποιο χαρακτηριστικό είναι ο καλύτερος ταξινομητής σε κάθε επίπεδο κόμβου. Στατιστικές μετρικές όπως το κέρδος πληροφορίας, ο δείκτης Gini, το Chi-square και η εντροπία υπολογίζονται για κάθε κόμβο, προκειμένου να υπολογιστεί η αξία αυτού του κόμβου. Διάφοροι αλγόριθμοι χρησιμοποιούνται για την υλοποίηση των δέντρων απόφασης. Οι πιο δημοφιλείς είναι: Classification and Regression Tree (CART), Iterative Dichotomiser 3 (ID3), Automatic Interaction Detection (CHAID), Chi-Squared C4.5 and C5.0 και M5.


2.2.3 Μηχανές Διανυσματικής Στήριξης (Support Vector Machines)

Οι μηχανές διανυσματικής στήριξης (Support Vector Machines) είναι ένα εποπτευόμενο μοντέλο μηχανικής μάθησης, το οποίο χρησιμοποιείται για να λύσει πολύπλοκα προβλήματα ταξινόμησης, παλινδρόμησης και ανίχνευσης ακραίων τιμών [22]. Βασικός στόχος των Support Vector Machines είναι ο υπολογισμός του βέλτιστου υπερεπιπέδου σε έναν N-διάστατο χώρο, το οποίο θα μπορεί να διαχωρίσει τα σημεία δεδομένων σε ξεχωριστές κλάσεις από χαρακτηριστικά. Η διάστασή του εξαρτάται από τον αριθμό των χαρακτηριστικών. Εάν ο αριθμός των χαρακτηριστικών εισόδου είναι δύο, τότε το υπερεπίπεδο είναι απλώς μια γραμμή, εάν ο αριθμός των χαρακτηριστικών εισόδου είναι τρία, τότε το υπερεπίπεδο γίνεται δισδιάστατο επίπεδο.

Σημαντικοί Όροι [37]

- **Διανύσματα Στήριξης:** Είναι τα σημεία τα οποία βρίσκονται πιο κοντά στο υπερεπίπεδο. Η διαχωριστική γραμμή μεταξύ των κλάσεων καθορίζεται με την βοήθεια των σημείων αυτών.
- **Margin (Περιθώριο):** Είναι η απόσταση μεταξύ του υπερεπιπέδου και των συμπτυγμάτων. Στο μοντέλο SVM στοχεύουμε σε μεγάλα περιθώρια.

Μεταξύ των διανυσμάτων στήριξης είναι δυνατόν να υπάρχουν πολλά υπερεπίπεδα.



Σχήμα 2.9: Μηχανή Διανυσματικής Στήριξης [22]


Καλύτερο θεωρείται αυτό, το οποίο θα μεγιστοποιεί την απόσταση μεταξύ των πλησιέστερων σημείων διαφορετικών κλάσεων. Όπως φαίνεται στην παραπάνω εικόνα το περιθώριο που εκτείνεται παράλληλα με το υπερεπίπεδο χωρίς εσωτερικά διανύσματα στήριξης θα πρέπει να είναι το μέγιστο, έτσι ώστε η διαχώριση της κλάσης A από την κλάση B να είναι ιδανική. Επειδή δεν υπάρχει προτίμηση σε κάποια από τις κλάσεις, για κάθε διεύθυνση επιλέγεται το επίπεδο που έχει ισαπέχει από τα πλησιέστερα σε αυτό σημεία των κλάσεων A και B.

Μαθηματική Διαισθηση Μηχανών Διανυσματικής Στήριξης

Εξίσωση γραμμικού υπερεπιπέδου: $\mathbf{w}^T \mathbf{x} + b = 0$

Απόσταση υπερεπιπέδου με Διάνυσμα Στήριξης: $\frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|}$

όπου $\mathbf{x}$ είναι η Ευκλείδεια Νόρμα: $\|\mathbf{w}\| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$




Σχήμα 2.10: Υπερεπίπεδο μεταξύ Θετικών και Αρνητικών Δειγμάτων [37]

Για την ταξινόμηση ενός σημείου ως θετικού ή αρνητικού ακολουθούμε τον εξής κανόνα απόφασης:

$$y = \begin{cases} +1 & \text{if } \vec{X} \cdot \vec{w} + b \geq 0 \\ -1 & \text{if } \vec{X} \cdot \vec{w} + b < 0 \end{cases}$$

Αν δηλαδή $\mathbf{w}^T \mathbf{x} + b \geq 0$, τότε το σημείο θεωρείται θετικό, ενώ όταν $\mathbf{w}^T \mathbf{x} + b < 0$ το σημείο θεωρείται αρνητικό. Άλλο ένα σημαντικό στοιχείο των Support Vector Machines είναι πως μπορούν να ταξινομήσουν ακόμα και μη γραμμικά σύνολα δεδομένων με τη χρήση Kernels. Πιο συγκεκριμένα, τα σύνολα μετατρέπονται σε χώρους διαφορετικών διαστάσεων με τη βοήθεια τετραγωνικών συναρτήσεων, των Kernels και η επιλογή του σωστού Kernel εξαρτάται από τον συντονισμό των υπερπαραμέτρων. Χαρακτηριστικό παράδειγμα φαίνεται στην παρακάτω εικόνα :



Σχήμα 2.11: Ταξινόμηση με Χρήση Kernel [37]

2.2.4 Αφελής Μπεϋζιανός Ταξινομητής (Naive Bayes)

Οι ταξινομητές Naive Bayes αποτελούν μία συλλογή από αλγορίθμους ταξινόμησης, οι οποίοι βασίζονται στο Θεώρημα του Bayes και στον κανόνα πως κάθε ζεύγος χαρακτηριστικών που ταξινομούνται έχουν το ίδιο βάρος και είναι ανεξάρτητα μεταξύ τους [34]. Η εφαρμογή του Naive Bayes απαιτεί πρότερη γνώση σχετικά με την πιθανότητα συγκεκριμένων γεγονότων.

Θεώρημα Bayes

Το θεώρημα του Bayes υπολογίζει την πιθανότητα να συμβεί ένα γεγονός A , δεδομένου ότι το γεγονός B είναι αληθές [16].

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $P(A)$ και $P(B)$ είναι οι πιθανότητες των A και B που είναι ανεξάρτητα μεταξύ τους.
- $P(A|B)$, υπό συνθήκη πιθανότητα, η πιθανότητα να ισχύει το A δεδομένου ότι το B είναι αληθές.
- $P(B|A)$, είναι η πιθανότητα του B δεδομένου ότι το A είναι αληθές.

Έστω, y μία μεταβλητή κλάσης και X ένα διάνυσμα χαρακτηριστικών με μέγεθος n . Εφαρμόζεται το Θεώρημα του Bayes ως εξής:

$$P(y|X) = \frac{P(X|y)P(y)}{P(X)} \quad , \quad X = (x_1, x_2, x_3, \dots, x_n)$$

Ισχύει πως τα χαρακτηριστικά είναι μεταξύ τους ανεξάρτητα, συνεπώς προκύπτει ότι:

$$P(y|x_1, \dots, x_n) = \frac{P(x_1|y)P(x_2|y)\dots P(x_n|y)P(y)}{P(x_1)P(x_2)\dots P(x_n)}$$

Ο παρονομαστής παραμένει σταθερός, οπότε παραλείπεται:

$$P(y|x_1, \dots, x_n) \propto P(y) \prod_{i=1}^n P(x_i|y)$$

Πλέον, για να ολοκληρωθεί το μοντέλο ταξινόμησης, υπολογίζεται η πιθανότητα του δεδομένου διανύσματος εισόδου $\mathbf{X}$ για όλες τις δυνατές τιμές της μεταβλητής κλάσης y και επιλέγεται η μέγιστη από αυτές:

$$y = \operatorname{argmax}_y P(y) \prod_{i=1}^n P(x_i|y)$$

Η παραπάνω διαδικασία απαιτεί διακριτά δεδομένα, καθώς σε περίπτωση συνεχών δεδομένων χρειάζεται να γίνουν υποθέσεις σχετικά με την κατανομή των τιμών κάθε χαρακτηριστικού.

2.2.5 Ταξινομητής K-Κοντινότερων Γειτόνων (K-Nearest Neighbors)


Ο αλγόριθμος των K-Πλησιέστερων Γειτόνων αποτελεί ένα αρκετά δημοφιλές μοντέλο μηχανικής μάθησης, το οποίο χρησιμοποιείται σε προβλήματα ταξινόμησης και παλινδρόμησης. Βασίζεται στην ιδέα [43] ότι παρόμοια σημεία δεδομένων τείνουν να έχουν παρόμοιες ετικέτες και τιμές, με το K να ορίζει τον αριθμό των πλησιέστερων γειτόνων που εξετάζονται στο εκάστοτε πρόβλημα.

Στον συγκεκριμένο αλγόριθμο, κάθε χαρακτηριστικό του συνόλου εκπαίδευσης αναπαρίσταται ως μία διαφορετική διάσταση σε έναν χώρο και η τιμή που έχει το κάθε χαρακτηριστικό σε μία παρατήρηση, αποτελεί τις συντεταγμένες του στην διάσταση αυτή [41]. Κατά την διαδικασία της εκπαίδευσης, ο αλγόριθμος KNN αποθηκεύει ολόκληρο το σύνολο δεδομένων εκπαίδευσης ως αναφορά. Όταν καλείται να κάνει προβλέψεις, υπολογίζει την απόσταση μεταξύ των σημείων δεδομένων της εισόδου και όλων των παραδειγμάτων εκπαίδευσης, χρησιμοποιώντας μία μετρική απόστασης, με συνηθέστερη την Ευκλείδεια απόσταση. Έτσι, ο αλγόριθμος υπολογίζει τους K πλησιέστερους γείτονες προς το σημείο δεδομένων εισόδου βάσει απόστασης, όπως φαίνεται και στο σχήμα 2.12.

Στην περίπτωση της ταξινόμησης, ο KNN αναθέτει ως ετικέτα στην είσοδο, την πιο κοινή κλάση ανάμεσα σε αυτές των K πλησιέστερων γειτόνων. Όσον αφορά τα προβλήματα παλινδρόμησης υπολογίζει τον μέσο όρο των τιμών της μεταβλητής στόχου των K πλησιέστερων γειτόνων με σκοπό να προβλέψει την τιμή της μεταβλητής στόχου για το σημείο εισόδου.

Αναλυτικά Βήματα του Αλγορίθμου KNN :

- Διευκρινίζεται ο θετικός ακέραιος k , μαζί με ένα νέο δείγμα.
- Επιλέγουμε τα k στοιχεία εισόδου στη βάση δεδομένων μας που είναι πιο κοντά στο νέο δείγμα.



Σχήμα 2.12: Αλγόριθμος KNN για $K=3$ και $K=6$ [10]

- Βρίσκουμε την πιο συχνή ταξινόμηση(κλάση) αυτών των στοιχείων.
- Αυτή είναι και η κλάση, στην οποία αναθέτουμε το νέο δείγμα.

Πρόκειται για ένα ευθύ και εύκολο μοντέλο Μηχανικής Μάθησης ως προς την κατανόηση και την υλοποίηση, ωστόσο η απόδοσή του εξαρτάται σε μεγάλο βαθμό από την επιλογή του K και της μετρικής απόστασης. Οι εφαρμογές του αλγορίθμου εκτείνονται σε διάφορους τομείς όπως η Αναγνώριση Μονοπατιών, οι Μηχανές Προτάσεων, η Οικονομία και η Υγεία.

2.2.6 Γραμμική Παλινδρόμηση (Linear Regression)

Η Γραμμική Παλινδρόμηση αποτελεί έναν τύπο αλγορίθμου Εποπτευόμενης Μηχανικής Μάθησης, ο οποίος υπολογίζει την γραμμική συσχέτιση μεταξύ μίας εξαρτημένης μεταβλητής και μίας (Απλή Γραμμική Παλινδρόμηση) ή περισσότερων (Πολλαπλή Γραμμική Παλινδρόμηση ανεξάρτητων μεταβλητών, προσαρμόζοντας μια γραμμική εξίσωση σε παρατηρούμενα δεδομένα [26]. Ουσιαστικά, αναζητά την ιδανική γραμμή, η οποία ελαχιστοποιεί το άθροισμα των τετραγωνικών διαφορών μεταξύ προβλεπόμενων και πραγματικών τιμών.

Η εξίσωση του μοντέλου παρέχει σαφείς συντελεστές που διευκρυνίζουν την επίδραση κάθε ανεξάρτητης μεταβλητής στην εξαρτημένη, διευκολύνοντας τη βαθύτερη κατανόηση των σχέσεων των στοιχείων ενός συνόλου δεδομένων. Πρόκειται για ένα διαφανές μοντέλο, εύκολο στην εφαρμογή, το οποίο χρησιμεύει ως θεμελιώδης ιδέα για πιο σύνθετους αλγόριθμους. Τεχνικές όπως η τακτοποίηση και οι μηχανές υποστήριξης διανυσμάτων αντλούν έμπνευση από τη γραμμική παλινδρόμηση, επεκτείνοντας τη χρησιμότητά της. Επιπλέον, η γραμμική παλινδρόμηση είναι ένας ακρογωνιαίος λίθος στη δοκιμή υποθέσεων, επιτρέποντας στους ερευνητές να επικυρώσουν βασικές υποθέσεις σχετικά με τα δεδομένα.

Απλή Γραμμική Παλινδρόμηση

Πρόκειται για την πιο απλή μορφή γραμμικής παλινδρόμησης, καθώς περιλαμβάνει μόνο μία ανεξάρτητη μεταβλητή και μία ανεξάρτητη μεταβλητή. Η εξίσωση της Απλής Γραμμικής


Παλινδρόμησης είναι: $y = \beta_0 + \beta_1 X$, όπου y είναι η εξαρτημένη μεταβλητή, X είναι η ανεξάρτητη μεταβλητή, β_0 είναι η τομή και β_1 η κλίση.

Πολλαπλή Γραμμική Παλινδρόμηση

Εδώ περιλαμβάνονται περισσότερες από μία ανεξάρτητες μεταβλητές και μία εξαρτημένη μεταβλητή. Η εξίσωση της Απλής Γραμμικής Παλινδρόμησης είναι: $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$, όπου y είναι η εξαρτημένη μεταβλητή, $X_1, X_2, \dots, X_n$ είναι η ανεξάρτητες μεταβλητές, β_0 είναι η τομή και $\beta_1, \beta_2, \dots, \beta_n$ η κλίσεις.

Fit Line Συνάρτηση

Στόχος του αλγορίθμου είναι η εύρεση της καλύτερης Fit Line συνάρτησης, η οποία θα μπορεί να προβλέπει τιμές βασιζόμενη στις ανεξάρτητες μεταβλητές. Ως καλύτερη συνάρτηση ορίζεται αυτή με το μικρότερο σφάλμα μεταξύ προβλεπόμενων και πραγματικών τιμών.



Σχήμα 2.13: Καλύτερη Fit Line Συνάρτηση [30]

Όπως βλέπουμε και στο σχήμα 2.13 η καλύτερη Fit Line Συνάρτηση παρέχει μία ευθεία γραμμή, η οποία αναπαριστά την σχέση μεταξύ εξαρτημένων (Y) και ανεξάρτητων (X) μεταβλητών. Η κλίση της γραμμής δηλώνει το πόσο πολύ η εξαρτημένη μεταβλητή αλλάζει για μια μονάδα αλλαγής στις ανεξάρτητες μεταβλητές.

Εφαρμόζεται σε αρκετά πεδία όπως τα χρηματοοικονομικά και η ψυχολογία, με σκοπό την κατανόηση και την πρόβλεψη της συμπεριφοράς μίας συγκεκριμένης μεταβλητής. Αποτελεί έναν αρκετά αποδοτικό υπολογιστικά αλγόριθμο, ο οποίος μπορεί μάλιστα να διαχειριστεί αποτελεσματικά μεγάλα σύνολα δεδομένων. Επίσης, έχει τη δυνατότητα να εκπαιδεύεται γρήγορα, με αποτέλεσμα να είναι κατάλληλος για εφαρμογές πραγματικού χρόνου. Τέλος, η Γραμμική Παλινδρόμηση είναι αρκετά εύρωστη όσον αφορά τις ακραίες τιμές, καθώς αυτές έχουν ελάχιστες επιπτώσεις στην συνολική απόδοση του μοντέλου.

Ωστόσο, είναι σημαντικό να λαμβάνονται υπόψη οι περιορισμοί του μοντέλου, όπως η υπόθεση της γραμμικότητας και η ευαισθησία στην πολυσυγγραμμικότητα. Όταν αυτοί οι περιορισμοί εξετάζονται προσεκτικά, η Γραμμική Παλινδρόμηση μπορεί να είναι ένα ισχυρό

εργαλείο για την ανάλυση και την πρόβλεψη δεδομένων.

2.2.7 Λογιστική Παλινδρόμηση (Logistic Regression)

Η Λογιστική Παλινδρόμηση ως αλγόριθμος Μηχανικής Μάθησης χρησιμοποιείται σε προβλήματα δυαδικής ταξινόμησης, χρησιμοποιώντας ως βάση την Σιγμοειδή συνάρτηση. Η συνάρτηση αυτή δέχεται ως είσοδο ανεξάρτητες μεταβλητές και παράγει στην έξοδο μία τιμή πιθανότητας μεταξύ 0 και 1 [15]. Αναφέρεται ως παλινδρόμηση διότι αποτελεί μία επέκταση της Γραμμικής Παλινδρόμησης, αλλά αφορά κυρίως προβλήματα ταξινόμησης. Στην Λογιστική Παλινδρόμηση αντί να προσαρμόσουμε μια γραμμική παλινδρόμησης, προσαρμόζουμε μια λογιστική συνάρτηση σχήματος «S», η οποία προβλέπει δύο μέγιστες τιμές (0 ή 1).

Ο αλγόριθμος Λογιστικής Παλινδρόμησης μετατρέπει την τιμή της συνεχούς εξόδου της συνάρτησης γραμμικής παλινδρόμησης σε κατηγορηματική τιμή, μέσω της Σιγμοειδούς συνάρτησης, η οποία αντιστοιχίζει κάθε σύνολο τιμών ανεξάρτητων μεταβλητών με τιμές μεταξύ 0 και 1.

Έστω X τα ανεξάρτητα χαρακτηριστικά εισόδου:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix}$$

και η εξαρτημένη μεταβλητή Y παίρνει δυαδικές τιμές:

$$Y = \begin{cases} 0 & , \text{αν Κλάση 1} \\ 1 & , \text{αν Κλάση 2} \end{cases}$$

τότε, εφαρμόζεται η πολυγραμμική συνάρτηση προς τις μεταβλητές εισόδου Q .

$$z = \left(\sum_{i=1}^n w_i x_i \right) + b$$


Εδώ x_i η i οστή παρατήρηση του X , $w_i = [w_1, w_2, w_3, \dots, w_m]$ είναι τα βάρη ή οι συντελεστές, και b είναι ο όρος bias. Στην ουσία, αυτό μπορεί να παρουσιαστεί ως το εσωτερικό γινόμενο του βάρους με το bias.

$$z = w \cdot X + b$$

Στην συνέχεια, αξιοποιείται η Σιγμοειδής Συνάρτηση όπου ως είσοδος τίθεται το z και στην έξοδο βρίσκουμε μία πιθανότητα μεταξύ 0 και 1: $\sigma(z) = \frac{1}{1+e^{-z}}$

Όπως φαίνεται στο Σχήμα 2.14, η Σιγμοειδής Συνάρτηση μετατρέπει τις συνεχείς μεταβλητές σε πιθανότητες μεταξύ 0 και 1.

- $\sigma(z)$ τείνει προς το 1 όσο το $z \rightarrow \infty$: $\lim_{z \rightarrow \infty} \sigma(z) = 1$
- $\sigma(z)$ τείνει προς το 0 όσο το $z \rightarrow -\infty$: $\lim_{z \rightarrow -\infty} \sigma(z) = 0$



Σχήμα 2.14: Σιγμοειδής Συνάρτηση [15]

- $\sigma(z)$ βρίσκεται πάντα μεταξύ 0 και 1: $0 \leq \sigma(z) \leq 1$

Όπου η πιθανότητα να είναι μία κλάση μπορεί να μετρηθεί ως:

$$P(y = 1) = \sigma(z)$$

$$P(y = 0) = 1 - \sigma(z)$$

Τελική συνάρτηση Λογιστικής Παλινδρόμησης: $p(X; b, w) = \frac{1}{1 + e^{-w \cdot X + b}}$

Πολυωνυμική Λογιστική Παλινδρόμηση

Η μεταβλητή στόχος μπορεί να έχει 3 ή περισσότερους πιθανούς τύπους που δεν είναι ταξινομημένοι (δηλαδή οι τύποι δεν έχουν ποσοτική σημασία). Στην περίπτωση αυτή στην θέση της Σιγμοειδούς Συνάρτησης χρησιμοποιείται η συνάρτηση Softmax, η οποία για K κλάσεις είναι:

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Εδώ, το K αντιπροσωπεύει τον αριθμό των στοιχείων στο διάνυσμα z , και το i, j επαναλαμβάνεται σε όλα τα στοιχεία του διανύσματος.

Τότε η πιθανότητα για την κλάση c θα είναι:

$$P(Y = c \mid X = x) = \frac{e^{w_k \cdot x + b_k}}{\sum_{k=1}^K e^{w_k \cdot x + b_k}}$$

2.2.8 Ακραία Ενίσχυση Κλίσης (XGBoost)

Ο Extreme Gradient Boosting αλγόριθμος ανήκει στις ensemble μεθόδους Μηχανικής Μάθησης και αποτελεί μία κατανεμημένη βιβλιοθήκη ενίσχυσης, σχεδιασμένη για αποτελεσματική και επεκτάσιμη εκπαίδευση μοντέλων [44]. Χαρακτηρίζεται από ικανή διαχείριση

μεγάλων συνόλων δεδομένων και από υψηλές αποδόσεις σε λειτουργίες ταξινόμησης και παλινδρόμησης, ενώ κατέχει αρκετά μεγάλη φήμη λόγω της απόδοσής της σε διαγωνισμούς μηχανικής μάθησης. Άλλο ένα σημαντικό χαρακτηριστικό του XGBoost είναι η αντιμετώπιση τιμών που λείπουν, χωρίς να απαιτεί ιδιαίτερη προεπεξεργασία.

x	y	F0	y-F0	h1	F1	y-F1	h2	F2	y-F2	h3	F3
5	82	134	-52	-38.25	95.75	-13.75	6.75	102.50	-20.50	-10.08333	92.41667
7	80	134	-54	-38.25	95.75	-15.75	6.75	102.50	-22.50	-10.08333	92.41667
12	103	134	-31	-38.25	95.75	7.25	6.75	102.50	0.50	-10.08333	92.41667
23	118	134	-16	-38.25	95.75	22.25	6.75	102.50	15.50	-10.08333	92.41667
25	172	134	38	25.50	159.50	12.50	6.75	166.25	5.75	-10.08333	156.16667
28	127	134	-7	25.50	159.50	-32.50	6.75	166.25	-39.25	-10.08333	156.16667
29	204	134	70	25.50	159.50	44.50	6.75	166.25	37.75	15.12500	181.37500
34	189	134	55	25.50	159.50	29.50	6.75	166.25	22.75	15.12500	181.37500
35	99	134	-35	25.50	159.50	-60.50	-27.00	132.50	-33.50	15.12500	147.62500
40	166	134	32	25.50	159.50	6.50	-27.00	132.50	33.50	15.12500	147.62500

Σχήμα 2.15: Παράδειγμα Προόδου XGBoost [44]

Πιο συγκεκριμένα, ο αλγόριθμος ξεκινά με ένα αρχικό μοντέλο (Δέντρο Απόφασης), το οποίο συνήθως είναι ένας απλός μέσος όρος της μεταβλητής στόχου για διαδικασίες παλινδρόμησης ή οι πιθανότητες ένταξης σε μία κλάση για λειτουργίες ταξινόμησης. Για κάθε στιγμιότυπο του συνόλου εκπαίδευσης, υπολογίζεται το σφάλμα όπως βλέπουμε και στο Σχήμα 2.15, οι διαφορές δηλαδή μεταξύ των προβλεπόμενων και των πραγματικών τιμών. Στην συνέχεια, ένα νέο δέντρο απόφασης εκπαιδεύεται πάνω στα σφάλματα αυτά. Το νέο Δέντρο εστιάζει στα στιγμιότυπα, στα οποία είχε τις υψηλότερες αστοχίες το προηγούμενο και κατασκευάζεται έτσι ώστε να διορθώσει τα λάθη του. Οι νέες προβλέψεις προστίθενται στις αρχικές προβλέψεις του κύριου μοντέλου. Αυτή η ενημέρωση μπορεί να κλιμακωθεί με έναν ρυθμό εκμάθησης (παράμετρος συρρίκνωσης), για τον έλεγχο της συμβολής κάθε νέου δέντρου και για τη επίτευξη της γενίκευσης. Τα παραπάνω βήματα, εκτός του αρχικού, επαναλαμβάνονται για έναν προκαθορισμένο αριθμό φορών ή μέχρις ότου τα σφάλματα να μειωθούν σημαντικά.

Ο XGBoost βελτιώνεται [17] σε κάθε βήμα μέσω της ακόλουθης συνάρτησης:

$$\text{Obj}(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

Στον παραπάνω τύπο l είναι συνάρτηση λάθους που μετρά την διαφορά μεταξύ προβλεπόμενων και πραγματικών τιμών και Ω είναι ο όρος κανονικοποίησης που τιμωρεί την πολυπλοκότητα του μοντέλου (π.χ. αριθμός φύλλων στο δέντρο). Η επέκταση Taylor δεύτερης τάξης της συνάρτησης απώλειας χρησιμοποιείται για την προσέγγιση και την ελαχιστοποίηση της αντικειμενικής συνάρτησης.

Προηγμένες δυνατότητες του XGBoost

- Κανονικοποίηση: Ο XGBoost περιλαμβάνει L1 (Lasso) και L2 (Ridge) όρους κανονικοποίησης για να ελέγχει την πολυπλοκότητα του μοντέλου και να αποφεύγει την υπερβολική

προσαρμογή.

- **Επίγνωση Αραιότητας:** Ο αλγόριθμος διαχειρίζεται αποδοτικά τα αραιά δεδομένα, ειδικούς αλγορίθμους εύρεσης διαχωρισμού ή μοτίβων αραιότητας.
- **Weighted Quantile Sketch:** Το XGBoost χρησιμοποιεί έναν νέο αλγόριθμο για το χειρισμό σταθμισμένων δεδομένων, διασφαλίζοντας τη βέλτιστη εύρεση διαχωρισμού ακόμη και παρουσία στιγμιotypών με βάρη.
- **Παράλληλη Επεξεργασία:** Ο XGBoost υποστηρίζει παράλληλη επεξεργασία, επιτρέποντας στην διαδικασία εκπαίδευσης να κατανέμεται σε πολλούς πυρήνες και μηχανές, αυξάνοντας σε μεγάλο βαθμό την ταχύτητα των υπολογισμών.
- **Κλάδεμα Δέντρων:** Εν αντιθέσει με την παραδοσιακή τακτική κλαδέματος, ο αλγόριθμος μεγαλώνει το δέντρο μέχρι το μέγιστο βάθος του και στην συνέχεια το μικραίνει προς τα πίσω στο ιδανικό μέγεθος.
- **Επίγνωση προσωρινής μνήμης:** Ο αλγόριθμος έχει σχεδιαστεί για να εκμεταλλεύεται αποτελεσματικά τους πόρους υλικού, βελτιστοποιώντας τη χρήση της μνήμης και τα μοτίβα πρόσβασης.

2.3 Μοντέλα Μη Εποπτευόμενης Μηχανικής Μάθησης

2.3.1 K-Μέσοι (K-Means)

Ο αλγόριθμος K-Μέσων δημιουργεί ένα αρχικό σύνολο από k cluster centers, τα οποία επιλέγονται τυχαία στον χώρο δεδομένων και ομοιόμορφα, εντός του εύρους για κάθε διάσταση[29]. Κάθε επανάληψη του αλγορίθμου K-Μέσων αποτελείται από δύο βήματα: 1) ανάθεση συστάδων, 2) ενημέρωση κεντροειδών. Δεδομένων των k μέσων των συστάδων, στο βήμα ανάθεσης, κάθε σημείο $x_j \in D$ ανατίθεται στον πλησιέστερο μέσο, με αποτέλεσμα να υλοποιείται μία ομαδοποίηση, όπου κάθε συστάδα C_i περιλαμβάνει τα σημεία εκείνα που βρίσκονται πιο κοντά στο m_i από οποιαδήποτε άλλη μέση τιμή συστάδας. Αυτό σημαίνει πως κάθε σημείο x_j ανατίθεται στην συστάδα C_i^* , όπου:

$$i^* = \arg \min_{i=1}^k \{ \|x_j - \mu_i\|^2 \}$$

Αφού έχει παραχθεί ένα σύνολο C_i από ομάδες, με $i = 1, \dots, k$, στο βήμα ενημέρωσης κεντροειδών υπολογίζονται οι νέες τιμές για κάθε μία από αυτές. Τα βήματα ανάθεσης συστάδων και ενημέρωσης κεντροειδούς εκτελούνται επαναληπτικά μέχρι να φτάσουμε σε ένα σταθερό σημείο ή σε τοπικά ελάχιστα.

Ουσιαστικά, όπως φαίνεται και στην εικόνα 2.16, σε κάθε επανάληψη, ο αλγόριθμος επιχειρεί να ελαχιστοποιήσει την μέση τετραγωνική απόσταση μεταξύ των δεδομένων και των κεντροειδών των συστάδων. Από άποψη πολυπλοκότητας, κάθε βήμα ανάθεσης απαιτεί $O(nkd)$ χρόνο, ενώ το βήμα επαναυπολογισμού διαρκεί $O(nd)$, όπου n είναι τα σημεία δεδομένων και d οι διαστάσεις τους.

```

K-MEANS ( $\mathbf{D}, k, \epsilon$ ):
1  $t = 0$ 
2 Randomly initialize  $k$  centroids:  $\mu_1^t, \mu_2^t, \dots, \mu_k^t \in \mathbb{R}^d$ 
3 repeat
4    $t \leftarrow t + 1$ 
5    $C_i \leftarrow \emptyset$  for all  $i = 1, \dots, k$ 
   // Cluster Assignment Step
6   foreach  $\mathbf{x}_j \in \mathbf{D}$  do
7      $i^* \leftarrow \operatorname{argmin}_i \{ \|\mathbf{x}_j - \mu_i^{t-1}\|^2 \}$ 
8      $C_{i^*} \leftarrow C_{i^*} \cup \{\mathbf{x}_j\}$  // Assign  $\mathbf{x}_j$  to closest centroid
   // Centroid Update Step
9   foreach  $i = 1, \dots, k$  do
10     $\mu_i^t \leftarrow \frac{1}{|C_i|} \sum_{\mathbf{x}_j \in C_i} \mathbf{x}_j$ 
11 until  $\sum_{i=1}^k \|\mu_i^t - \mu_i^{t-1}\|^2 \leq \epsilon$ 

```

Σχήμα 2.16: Αλγόριθμος K-Μέσων [29]

2.3.2 Ισορροπημένη Επαναληπτική Μείωση και Ομαδοποίηση με Χρήση Ιεραρχιών (BIRCH)

Ο αλγόριθμος BIRCH αποτελεί έναν αλγόριθμο σχεδιασμένο για ομαδοποίηση μεγάλου όγκου αριθμητικών δεδομένων[11]. Η βασική του ιδέα είναι πως ιεραρχικά και αυξητικά δημιουργείται ένα CF δέντρο, στο οποίο αποθηκεύεται η απαραίτητη πληροφορία ομαδοποίησης, οδηγώντας στην επίτευξή της σε μία μόνο σάρωση.

```

Input:
   $D = \{t_1, t_2, \dots, t_n\}$  //Set of elements
   $T$  // Threshold for CF tree construction
Output:
   $K$  //Set of clusters
BIRCH clustering algorithm:
  for each  $t_i \in D$  do
    determine correct leaf node for  $t_i$  insertion;
    if threshold condition is not violated, then
      add  $t_i$  to cluster and update CF triples;
    else
      if room to insert  $t_i$ , then
        insert  $t_i$  as single cluster and update CF triples;
      else
        split leaf node and redistribute CF features;

```

Σχήμα 2.17: Αλγόριθμος BIRCH [11]

Πιο αναλυτικά, σύμφωνα με τον ψευδοκώδικα της εικόνας 2.17 ο αλγόριθμος ξεκινά θέτοντας την τιμή κατωφλίου T , η οποία καθορίζει την μέγιστη διάμετρο κάθε ομάδας. Στη συνέχεια, CF δέντρο, το οποίο είναι ένα τρίπτυχο που περιέχει τον αριθμό των σημείων, το άθροισμα των σημείων και το άθροισμα των τετραγώνων των σημείων της συστάδας, αρχι-

κοποιείται. Ακολουθεί η εισαγωγή των σημείων δεδομένων t_i , κατά την οποία σαρώνεται το δέντρο από την ρίζα και εντοπίζεται ο κοντινότερος κόμβος φύλλου. Αν η προσθήκη του t_i δεν παραβιάζει το κατώφλι T , το δέντρο συμπεριλαμβάνει το σημείο αυτό. Αν το T παραβιάζεται, αλλά ο κόμβος έχει χώρο, το t_i προστίθεται ως ξεχωριστή συστάδα εντός του εν λόγω κόμβου φύλλου. Εάν δεν υπάρχει χώρος στον κόμβο φύλλο, ο κόμβος διασπάται και τα CF ανακατανέμονται μεταξύ των νέων κόμβων για να φιλοξενήσουν το νέο σημείο.

Το δέντρο παραμένει ισορροπημένο, όπως ένα B-δέντρο. Εφόσον το μέγεθός του γίνει πολύ μεγάλο, το κατώφλι T αυξάνεται και μερικές συστάδες ενώνονται. Το τελικό σύνολο συστάδων προέρχεται από το CF δέντρο, στο οποίο κάθε κόμβος φίλο αναπαριστά μία συστάδα.

2.3.3 Ιεραρχική Ομαδοποίηση (Hierarchical Clustering)

Στην διαδικασία της ιεραρχικής ομαδοποίησης[29] κάθε ένα από τα σημεία δεδομένων βρίσκεται αρχικά σε διαφορετική συστάδα από τα υπόλοιπα. Επαναληπτικά, οι δύο κοντινότερες συστάδες ενώνονται μέχρι τη στιγμή, στην οποία όλα τα σημεία αποτελούν μέρος του ίδιου cluster. Ειδικότερα, δεδομένου ενός συνόλου από συστάδες $C = C_1, C_2, \dots, C_m$, εντοπίζεται το κοντινότερο ζεύγος C_i, C_j και ενώνεται σε μία νέα $C_{ij} = C_i \cup C_j$. Στην συνέχεια, το σύνολο των συστάδων ενημερώνεται αφαιρώντας τις C_i και C_j και προσθέτοντας την $C_{ij} = C_i \cup C_j$, ως εξής $C' = (C \setminus \{C_i, C_j\}) \cup \{C_{ij}\}$. Η προηγούμενη διαδικασία επαναλαμβάνεται έως ότου η C περιέχει μόνο μία συστάδα.

AGGLOMERATIVE CLUSTERING(D, k):

```

1  $C \leftarrow \{C_i = \{\mathbf{x}_i\} \mid \mathbf{x}_i \in D\}$  // Each point in separate cluster
2  $\Delta \leftarrow \{\|\mathbf{x}_i - \mathbf{x}_j\| : \mathbf{x}_i, \mathbf{x}_j \in D\}$  // Compute distance matrix
3 repeat
4   Find the closest pair of clusters  $C_i, C_j \in C$ 
5    $C_{ij} \leftarrow C_i \cup C_j$  // Merge the clusters
6    $C \leftarrow (C \setminus \{C_i, C_j\}) \cup \{C_{ij}\}$  // Update the clustering
7   Update distance matrix  $\Delta$  to reflect new clustering
8 until  $|C| = k$ 
```

Σχήμα 2.18: Αλγόριθμος Ιεραρχικής Ομαδοποίησης [29]


Η απόσταση μεταξύ δύο σημείων, συνήθως υπολογίζεται χρησιμοποιώντας την ευκλείδεια απόσταση. Ως κριτήρια σύνδεσης μπορούν να αξιοποιηθούν η μικρότερη, η μεγαλύτερη και η μέση απόσταση ανάμεσα σε ζεύγη συστάδων, όπως και η απόσταση μεταξύ των κεντροειδών.

2.4 Μοντέλα Βαθιάς Μηχανικής Μάθησης

2.4.1 Δίκτυα Μακράς Βραχύχρονης Μνήμης (Long - Short Term Memory)

Το Long Shot-Term Memory είναι ένα είδος Αναδρομικού Νευρωνικού Δικτύου, το οποίο είναι ικανό να διατηρήσει μακροπρόθεσμες εξαρτήσεις σε ακολουθιακά δεδομένα. Χρησιμοποιεί ένα κύτταρο μνήμης και πύλες για τον έλεγχο της διάδοσης της πληροφορίας, με

αποτέλεσμα, επιλεκτικά, να διατηρεί ή να αποβάλλει πληροφορία ανάλογα με τις εκάστοτε ανάγκες [8]. Επιπλέον, αποφεύγεται το πρόβλημα της εξαφάνισης της κλίσης που μαστίζει παραδοσιακά τα Αναδρομικά Νευρωνικά Δίκτυα.



Σχήμα 2.19: Long Short-Term Memory Formation [14]

Όπως και στα απλά Αναδρομικά Νευρωνικά Δίκτυα, έτσι και τα LSTM πέρα από τις πραγματικές καταστάσεις $C(t-1)$ και $C(t)$, έχουν και μία κρυφή κατάσταση όπου το $H(t-1)$ αντιπροσωπεύει την κρυφή κατάσταση της προηγούμενης χρονικής στιγμής και το $H(t)$ αντιστοιχεί στην τωρινή χρονική στιγμή. Στο κύτταρο μνήμης του LSTM υπάρχουν τρεις τύποι πυλών: η πύλη εισόδου, η πύλη forget και η πύλη εξόδου [39].

Πύλη Forget

Η πληροφορία που δεν είναι πλέον χρήσιμη στο κύτταρο κατάστασης, απομακρύνεται μέσω της πύλης forget. Δύο είσοδοι, η x_t (είσοδος την συγκεκριμένη χρονική στιγμή) και η h_t (έξοδος προηγούμενου κελιού) οδηγούνται στην είσοδο της πύλης, πολλαπλασιάζονται με τα βάρη και ακολουθεί η προσθήκη των bias. Το αποτέλεσμα διέρχεται μέσω μίας συνάρτησης ενεργοποίησης, η οποία δίνει μία δυαδική έξοδο. Εάν για μια συγκεκριμένη κατάσταση κελιού η έξοδος είναι 0, το κομμάτι της πληροφορίας ξεχνιέται, ενώ για έξοδο 1, η πληροφορία διατηρείται για μελλοντική χρήση. Εξίσωση πύλης forget: $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$

- W_f : Μητρώο βάρους για την πύλη forget
- h_{t-1} : Κρυφή κατάσταση στο προηγούμενο βήμα χρόνου $t-1$
- x_t : Είσοδος στο βήμα χρόνου t
- b_f : Bias διάνυσμα για την πύλη forget
- σ : Σιγμοειδής συνάρτηση ενεργοποίησης

Πύλη Εισόδου

Η προσθήκη χρήσιμης πληροφορίας στο κύτταρο κατάστασης, γίνεται μέσω της πύλης εισόδου. Πρώτα η πληροφορία κανονικοποιείται μέσω της Σιγμοειδούς συνάρτησης και

φιλτράρει τις τιμές που είναι σημαντικές όπως η πύλη forget χρησιμοποιώντας εισόδους x_t και h_{t-1} . Τότε, παράγεται ένα διάνυσμα από την συνάρτηση tanh, το οποίο δίνει στην έξοδο τιμές από -1 έως 1. Τελικά, οι τιμές του διανύσματος και οι κανονικοποιημένες τιμές πολλαπλασιάζονται για την απόκτηση πληροφορίας. Εξίσωση πύλης εισόδου: $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$ και $\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$.

Η προηγούμενη κατάσταση πολλαπλασιάζεται με το f_t , αγνοώντας τις πληροφορίες που είχαμε προηγουμένως επιλέξει να αγνοήσουμε. Στη συνέχεια, συμπεριλαμβάνουμε το $i_t * C_t$, το οποίο αντιπροσωπεύει τις ενημερωμένες υποψήφιας τιμές, προσαρμοσμένες στο ποσό με το οποίο επιλέξαμε να ενημερώσουμε κάθε τιμή κατάστασης. Έτσι, προκύπτει: $C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$

- $\odot$: Πολλαπλασιασμός Στοιχείο με Στοιχείο
- tanh: tanh Συνάρτηση Ενεργοποίησης

Πύλη Εξόδου

Η διαδικασία εξαγωγής χρήσιμης πληροφορίας από την τωρινή κατάσταση του κελιού, με σκοπό να παρουσιαστεί ως έξοδος, γίνεται από την πύλη εξόδου. Αρχικά, ένα διάνυσμα παράγεται εφαρμόζοντας την συνάρτηση tanh στο κελί. Τότε, η πληροφορία κανονικοποιείται μέσω της Σιγμοειδούς συνάρτησης και φιλτράρει τις τιμές που είναι σημαντικές όπως η πύλη forget χρησιμοποιώντας εισόδους x_t και h_{t-1} . Τελικά, οι τιμές του διανύσματος και οι κανονικοποιημένες τιμές πολλαπλασιάζονται για να σταλούν ως είσοδος και έξοδος στο επόμενο κελί. Εξίσωση πύλης εξόδου: $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$

Συμπερασματικά, τα LSTMs επεξεργάζονται και αναλύουν ακολουθιακά δεδομένα, όπως χρονοσειρές. Είναι αρκετά διαδεδομένα σε εφαρμογές επεξεργασίας φυσικής γλώσσας, αναγνώρισης ομιλίας, ανάλυση βίντεο και εντοπισμού ανωμαλιών. Είναι ιδιαίτερα ικανά στην εκμάθηση και τη διατήρηση πληροφορίας από το παρελθόν, γεγονός που τα καθιστά ιδανικά για προβλήματα αναγνώρισης δραστηριότητας και μονοπατιών.

Κεφάλαιο 3

Συντήρηση Μηχανολογικού Εξοπλισμού

Στο κεφάλαιο αυτό αναλύονται οι βασικές έννοιες που αφορούν τη συντήρηση του μηχανολογικού εξοπλισμού στο πλαίσιο της Βιομηχανίας 4.0. Περιγράφονται τα διάφορα είδη συντήρησης εξοπλισμού, με ιδιαίτερη έμφαση στην προγνωστική συντήρηση σε συνδυασμό με την μηχανική μάθηση, η οποία αποτελεί το κύριο θέμα της παρούσας διπλωματικής εργασίας.

3.1 Συντήρηση Μηχανολογικού Εξοπλισμού

Γενικά, μία στρατηγική συντήρησης καθορίζει όλες εκείνες τις ενέργειες και τις διαδικασίες που πραγματοποιούνται, ώστε να διατηρηθεί η υγεία και η ασφάλεια του μηχανολογικού εξοπλισμού καθόλη τη διάρκεια των κύκλων ζωής του. Ο σχεδιασμός, η διαχείριση και ο έλεγχος αποτελούν βασικά συστατικά της συντήρησης και απαιτούν μία προσέγγιση, η οποία ξεκινά με την ταυτοποίηση των πιο κρίσιμων στοιχείων, αλλά και των σημαντικότερων αποτυχιών που μπορούν να συμβούν.

3.1.1 Βιομηχανία 4.0

Η “Βιομηχανία 4.0”, η οποία συχνά αναφέρεται ως η 4η Βιομηχανική Επανάσταση, ενσωματώνει ψηφιακές τεχνολογίες αυτοματισμού και ανταλλαγής δεδομένων στις κατασκευαστικές και βιομηχανικές διαδικασίες. Στον πυρήνα του, το Industry 4.0 επιδιώκει να δημιουργήσει “έξυπνα” εργοστάσια, όπου διασυνδεδεμένα συστήματα επικοινωνούν και συνεργάζονται αυτόνομα, βελτιστοποιώντας τις διαδικασίες παραγωγής.

Αυτή η νέα βιομηχανική εποχή βασίζεται σε τρεις βασικούς τεχνολογικούς πυλώνες [2]:

- Συστήματα Κυβερνο-Φυσικών Συστημάτων (CPS): Τα συστήματα κυβερνο-φυσικών συστημάτων ενσωματώνουν ψηφιακές τεχνολογίες σε φυσικές διεργασίες, δίνοντας τη δυνατότητα για συνεχή επικοινωνία και συνεργασία μεταξύ μηχανών, συστημάτων και

ανθρώπων. Αυτά τα διασυνδεδεμένα συστήματα χρησιμοποιούν αισθητήρες, ενεργοποιητές και συστήματα ελέγχου για την παρακολούθηση και τον έλεγχο φυσικών διεργασιών σε πραγματικό χρόνο.

- **Διαδίκτυο των Αντικειμένων (IoT):** Το Διαδίκτυο των Αντικειμένων αναφέρεται στο δίκτυο των διασυνδεδεμένων συσκευών, αισθητήρων και μηχανημάτων που συλλέγουν και ανταλλάσσουν δεδομένα μέσω του διαδικτύου. Σε ένα περιβάλλον Βιομηχανίας 4.0, οι τεχνολογίες IoT επιτρέπουν τη συνεχή παρακολούθηση της απόδοσης του εξοπλισμού, των περιβαλλοντικών συνθηκών και των διαδικασιών παραγωγής, διευκολύνοντας την προγνωστική συντήρηση και τη λήψη αποφάσεων βασισμένων σε δεδομένα.
- **Προηγμένη Ανάλυση Δεδομένων:** Η Βιομηχανία 4.0 εκμεταλλεύεται προηγμένες τεχνικές ανάλυσης δεδομένων, συμπεριλαμβανομένης της μηχανικής μάθησης, της τεχνητής νοημοσύνης και της ανάλυσης μεγάλων δεδομένων, για να εξαγεί χρήσιμες πληροφορίες από τα τεράστια ποσά δεδομένων που παράγονται από τα συστήματα και τις συσκευές IoT. Μέσω της ανάλυσης ιστορικών δεδομένων, της ανίχνευσης μοτίβων και της πρόβλεψης μελλοντικών αποτελεσμάτων, η ανάλυση δεδομένων επιτρέπει στις εταιρείες να βελτιστοποιήσουν τις διαδικασίες παραγωγής, να βελτιώσουν την απόδοση και να οδηγηθούν στην καινοτομία.



Σχήμα 3.1: Βιομηχανία 4.0 [46]

Η Βιομηχανία 4.0 στοχεύει στον μετασχηματισμό των παραδοσιακών περιβαλλόντων κατασκευής σε υψηλά προσαρμόσιμα και ανταποκρίσιμα οικοσυστήματα, όπου οι διαδικασίες παραγωγής βελτιστοποιούνται σε πραγματικό χρόνο και οι πόροι διατίθενται αποτελεσματικά. Μέσω της υιοθέτησης της ψηφιοποίησης, της αυτοματοποίησης και της σύνδεσης, οι οργανισμοί μπορούν να ξεκλειδώσουν νέες ευκαιρίες για καινοτομία, να ενισχύσουν τον ανταγωνισμό τους και να αντιμετωπίσουν πολύπλοκες προκλήσεις στην παγκόσμια αγορά.


3.1.2 Είδη Στρατηγικών Συντήρησης

Διορθωτική Συντήρηση (Reactive)

Η διορθωτική συντήρηση αναφέρεται σε όλες εκείνες τις ενέργειες, οι οποίες σχετίζονται με την αντικατάσταση ή την επιδιόρθωση ενός συστήματος που έχει υποστεί βλάβη [6]. Από την στιγμή που πραγματοποιείται αφού η αποτυχία έχει ήδη συμβεί, συνήθως, οδηγεί σε κοστοβόρα διακοπή της βιομηχανικής διαδικασίας, σε αύξηση εξόδων λόγω μη προγραμματισμένων επιδιορθώσεων και σε παρουσία ζητημάτων ασφαλείας. Δεδομένης της αβεβαιότητας της συγκεκριμένης πολιτικής όπου δεν μπορούν να προβλεφθούν χρόνοι διακοπής και κόστη ανακατασκευής, η Διορθωτική Συντήρηση εφαρμόζεται κυρίως σε στοιχεία, τα οποία χαρακτηρίζονται από χαμηλό ρίσκο.

Προληπτική Συντήρηση (Preventive)

Η προληπτική συντήρηση περιλαμβάνει δραστηριότητες, οι οποίες με βάση συγκεκριμένα κριτήρια έχουν ως στόχο να μειώσουν την πιθανότητα αποτυχίας και την υποβάθμιση της λειτουργικής απόδοσης ενός συστήματος. Οι δύο βασικές προσεγγίσεις που την χαρακτηρίζουν είναι ο προγραμματισμένος έλεγχος συγκεκριμένων στοιχείων σε συγκεκριμένα χρονικά διαστήματα, ασχέτως της κατάστασης υγείας του εξοπλισμού, και η συντήρηση συστημάτων που έχουν ξεπεράσει έναν μεγάλο αριθμό κύκλων λειτουργίας. Ωστόσο, άσκοπες παρεμβάσεις που αυξάνουν το κόστος συντήρησης και καταναλώνουν πόρους και μερική επιδιόρθωση εξοπλισμού που δεν επαναφέρει το σύστημα στην αρχική του κατάσταση καθιστούν την προληπτική συντήρηση ριψοκίνδυνη.



Σχήμα 3.2: Στρατηγικές Συντήρησης [32]

Προγνωστική Συντήρηση (Predictive)

Η προγνωστική συντήρηση [32] αντιπροσωπεύει το επόμενο βήμα προς την έξυπνη συντήρηση μηχανολογικού εξοπλισμού βιομηχανικών συστημάτων. Κεντρικό στοιχείο αυτής της μεθόδου είναι η συνεχής παρακολούθηση διαφορετικών παραμέτρων (δονήσεις, θερμοκρασία,

πίεση), προκειμένου να εντοπιστούν σημαντικές αλλαγές, οι οποίες αποτελούν χαρακτηριστικό που προμηνύει αποτυχία. Σε αυτό το πλαίσιο, η δυνατότητα πρόβλεψης της συμπεριφοράς ενός συστήματος και των συνεπειών της βασίζεται α) στην εγκατάσταση ειδικών αισθητήρων για την αδιάκοπη εποπτεία της κατάστασης υγείας, β) στην εξαγωγή κρίσιμων πληροφοριών που οδηγούν στην λήψη σωστών αποφάσεων προτού προκύψουν βλάβες και γ) στην ανάγκη για ικανούς χειριστές, ώστε να αξιοποιηθούν τεχνολογίες λήψης, ανάλυσης δεδομένων, αλλά και μοντέλων μηχανικής μάθησης, τα οποία θα δώσουν τα απαραίτητα συμπεράσματα. Ένα πρόγραμμα προγνωστικής συντήρησης δύναται να μειώσει την συχνότητα αχρείαστων διεργασιών και τον χρόνο διακοπής λειτουργίας, αφού διαβεβαιώνει πως το σύστημα θα συντηρηθεί μόνο όταν παρουσιαστεί πραγματική ανάγκη.

Κεντρικές τεχνικές παρακολούθησης που ανήκουν στην Προγνωστική Συντήρηση είναι η Ανάλυση Δόνησης (Vibration analysis), Υπέρυθρη Θερμογραφία (Infrared thermography), η Ακουστική Ανάλυση (Acoustic analysis), η Ανάλυση Λιπαντικών (Analysis of lubricants) και η Δοκιμή Υπερήχων (Ultrasonic testing).


3.2 Προγνωστική Συντήρηση και Μηχανική Μάθηση

Οι αλγόριθμοι μηχανικής μάθησης έχουν αναδειχθεί ως ισχυρά εργαλεία στον τομέα της συντήρησης, προσφέροντας τη δυνατότητα ανάλυσης τεράστιων ποσοτήτων δεδομένων και εξαγωγής πρακτικών πληροφοριών. Ανιχνεύοντας μοτίβα, ανωμαλίες και στοιχεία αστοχίας στα δεδομένα απόδοσης εξοπλισμού, τα μοντέλα Μηχανικής Μάθησης δίνουν τη δυνατότητα στους οργανισμούς να περάσουν από την αντιδραστική και την διορθωτική συντήρηση σε προληπτικές και προγνωστικές στρατηγικές [9]. Είναι σημαντικό ότι αυτές οι προβλέψεις γίνονται πιο ακριβείς με την πάροδο του χρόνου καθώς το σύστημα μαθαίνει και εξελίσσεται. Χωρίς μηχανική μάθηση, οι εταιρείες πρέπει να δημιουργήσουν προγνωστικά προγράμματα συντήρησης βασισμένα σε απλούς, κοινούς αλγόριθμους, οι οποίοι είναι αρκετά στάσιμοι.

Η διαδικασία Προγνωστικής Συντήρησης αναπτύσσεται σύμφωνα με τρεις βασικούς άξονες φάσεις [13]. Η πρώτη προβλέπει την συλλογή δεδομένων, όπου τα δεδομένα μπορούν να παρέχονται από διαφορετικές πηγές και να έχουν διαφορετική φύση, όπως δεδομένα παρακολούθησης, δεδομένα συμβάντων συντήρησης και δεδομένα διεργασίας. Στη συνέχεια, υπάρχει η επεξεργασία των δεδομένων, καθώς είναι απαραίτητο να πραγματοποιηθεί “καθάρισμα” του συνόλου δεδομένων, να αναλυθούν τα δεδομένα και να επαληθευτεί η συνέπειά τους με τη διεργασία, η οποία παρακολουθείται. Ακολουθεί, η διαδικασία για την εξαγωγή χαρακτηριστικών και πληροφοριών με απότερο στόχο την Προγνωστική Συντήρηση. Τέλος, πραγματοποιείται η φάση λήψης αποφάσεων για τη συντήρηση. Χωρίζεται σε δύο κύριες κατηγορίες, σύμφωνα με τις οποίες εφαρμόζονται διαφορετικές τεχνικές: η ανίχνευση βλάβης-ανωμαλίας (Anomaly Detection), κατά την οποία η βλάβη εντοπίζεται σε πραγματικό χρόνο και η πρόβλεψη βλάβης, κατά την οποία στόχος είναι η εκτίμηση της εναπομείνουσας ωφέλιμης ζωής (Remaining Useful Life Estimation) του παρακολουθούμενου εξαρτήματος.

3.2.1 Ανίχνευση Βλάβης-Ανωμαλίας

Η τεχνική της Πρόγνωσης Συντήρησης σχετίζεται άμεσα με την μοντελοποίηση της ομαλής λειτουργίας ενός συστήματος και τον εντοπισμό αποκλίσεων, οι οποίες συχνά υποδηλώνουν παρούσες ή εξελισσόμενες αστοχίες του εξοπλισμού. Αυτή η διαδικασία ονομάζεται Ανίχνευση Ανωμαλίας και, πιο αναλυτικά, αφορά την ταυτοποίηση μεταβλητών ή αντικειμένων που δεν ανήκουν στο αναμενόμενο μονοπάτι ενός συνόλου δεδομένων και είναι συνήθως μη παρατηρήσιμα για το ανθρώπινο μάτι [21]. Εφαρμόζεται σε πολλούς και διαφορετικούς τομείς πέραν του μηχανολογικού εξοπλισμού Βιομηχανιών, ενώ η σημασία της έγκειται στο γεγονός πως οποιοδήποτε σφάλμα στην λειτουργία του εξοπλισμού μεταφράζεται ως σημαντική πληροφορία για την υγεία ενός συστήματος.



Σχήμα 3.3: Ανίχνευση Ανωμαλιών [12]

Η ανίχνευση ανωμαλιών αποτελεί μία αρκετά κοινή προσέγγιση για τον εντοπισμό σφαλμάτων. Στα πλαίσια του λάθους, του σφάλματος και της αποτυχίας, μία ανωμαλία μπορεί να θεωρηθεί ως ένα πιθανό σφάλμα, το οποίο προκλήθηκε από ένα λάθος και είναι δυνατόν να προκαλέσει μία αποτυχία. Ως εκ τούτου, μια ανωμαλία μπορεί να υποδείξει ένα σφάλμα και επομένως να χρησιμοποιηθεί για υπό συνθήκη Προγνωστική Συντήρηση, καθώς αποτελεί πρώιμο δείγμα αποτυχίας, το οποίο συνήθως οδηγεί υποβάθμιση ή ακόμα και διακοπή λειτουργίας. Ως κεντρικές τεχνικές Ανίχνευσης Ανωμαλιών διακρίνονται οι ακόλουθες [42]:

- **Φυσικά Μοντέλα:** Η φυσική μοντελοποίηση της κανονικής συμπεριφοράς με βάση τις υποκείμενες προδιαγραφές επιτρέπει τον εντοπισμό αποκλίσεων (υπολειμμάτων) ως ανωμαλιών. Επιπλέον ή εναλλακτικά, μπορούν να μοντελοποιηθούν απίθανες καταστάσεις και γνωστά σφάλματα.
- **Ανίχνευση ανωμαλιών Χωρίς Επίβλεψη:** Σε ένα μη επιβλεπόμενο περιβάλλον, οι ανωμαλίες μπορούν να ανιχνευθούν καθορίζοντας αν ένα υποσύνολο x_i είναι ανώμαλο σε σχέση με τα υπόλοιπα δεδομένα X . Δεν χρησιμοποιούνται ετικέτες τάξης, κάτι που σημαίνει πως το σύνολο X δεν περιέχει δεδομένα αναφοράς, τα οποία συνοδεύονται

από το όνομα της κλάσης στην οποία ανήκουν. Παραδείγματα μη επιβλεπόμενων μεθόδων χρησιμοποιούν μετρικές απόστασης ή πυκνότητας, ομαδοποίηση, και μεθόδους που βασίζονται σε δέντρα απόφασης ή νευρωνικά δίκτυα.

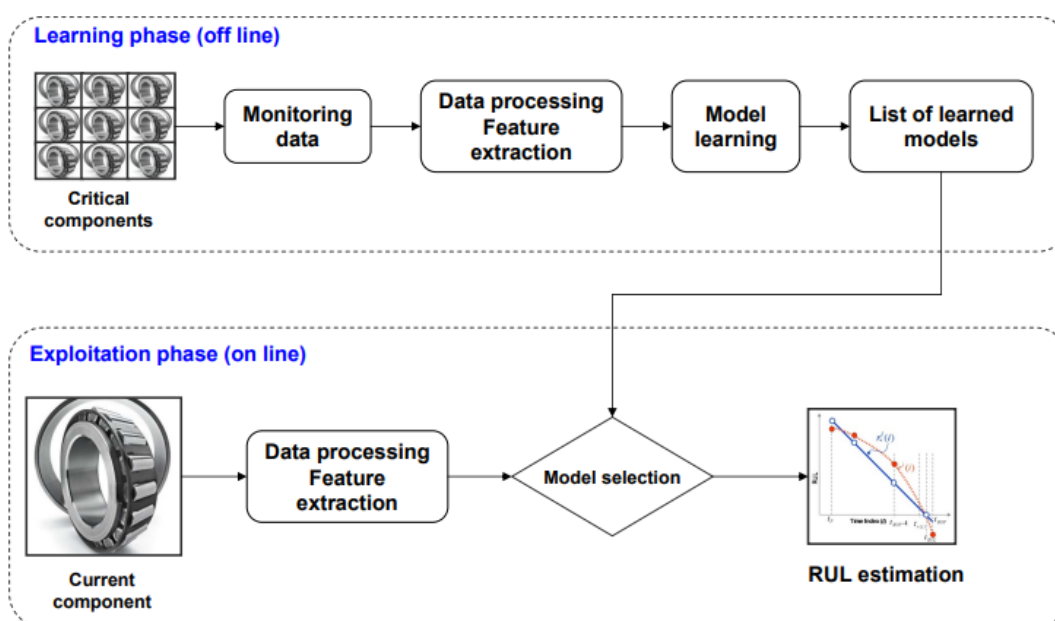
- **Ανίχνευση Ανωμαλιών με Ημιεπίβλεψη:** Ενώ οι χωρίς επίβλεψη μέθοδοι μπορούν να εφαρμοστούν απουσία ετικετών, αυτή η έλλειψη πληροφορίας αντισταθμίζεται από τις υποθέσεις των μοντέλων σχετικά με τις ανωμαλίες. Για περιπτώσεις όπου είναι δυνατόν να ληφθούν κανονικά δεδομένα, π.χ. με τη χρήση προσομοιώσεων ή πραγματικών συστημάτων που δεν είναι πιθανό να παρουσιάσουν ανώμαλη συμπεριφορά κατά τη διάρκεια της συλλογής δεδομένων, ημι-επιβλεπόμενες τεχνικές μπορούν να εφαρμοστούν. Τα μοντέλα μηχανικής μάθησης μπορούν να εκπαιδευτούν σε κανονικά δεδομένα για να μοντελοποιήσουν την κανονική συμπεριφορά του συστήματος και κατά τη διάρκεια της λειτουργίας, οι όποιες αποκλίσεις παρατηρηθούν, αναφέρονται ως ανωμαλίες.
- **Ανίχνευση ανωμαλιών με Επίβλεψη:** Εάν είναι διαθέσιμα τόσο τα κανονικά όσο και τα αντιπροσωπευτικά δεδομένα ανωμαλιών, η διεργασία που ακολουθείται μπορεί να θεωρηθεί ως πρόβλημα ταξινόμησης δύο ή περισσότερων κατηγοριών. Τα κοινά μοντέλα μηχανικής μάθησης μπορούν να εκπαιδευτούν σε κανονικά δεδομένα και δεδομένα που υποδηλώνουν βλάβες, ταξινομώντας τις νέες περιπτώσεις είτε ως φυσιολογικές είτε ως καταστάσεις που προμηνύουν αποτυχία. Για την διαδικασία αυτή, κλασικοί ταξινομητές μπορούν να χρησιμοποιηθούν, ωστόσο είτε τα δεδομένα, είτε οι ταξινομητές θα πρέπει να προσαρμοστούν στην υψηλή ανισορροπία των κλάσεων.
- **Υβριδικές προσεγγίσεις:** Διαφορετικοί τύποι υβριδικών προσεγγίσεων αντιμετωπίζουν τα μειονεκτήματα των μεμονωμένων μεθόδων, συνδυάζοντας μοντέλα που βασίζονται σε δεδομένα και φυσικά μοντέλα.

Ένα από τα βασικά προβλήματα που αντιμετωπίζει ο εντοπισμός ανωμαλιών όταν γίνεται χρήση παραδοσιακών στατιστικών μεθόδων σε συνδυασμό με μοντέλα μηχανικής μάθησης είναι η ύπαρξη θορύβου στα δεδομένα. Συχνά, επισημαίνεται ως ανωμαλία, δεδομένου ότι η διαφορά μεταξύ φυσιολογικής και μη φυσιολογικής συμπεριφοράς δεν είναι ως επί το πλείστον συγκεκριμένη. Επιπλέον, τα χαρακτηριστικά της συμπεριφοράς του εξοπλισμού δύναται να αλλάζουν συχνά, επηρεάζοντας τα μέσο όριο κάθε μεταβλητής. Το μοτίβο της ανωμαλίας βασίζεται κυρίως στην εποχικότητα, η οποία απαιτεί πιο δυναμικές τεχνικές για την κατανόηση της αλλαγής των τάσεων της ανωμαλίας.

Η ύπαρξη αυστηρά κωδικοποιημένων ορίων τείνει να στέλνει αρκετά μεγάλο αριθμό ψευδών συναγερμών για συνθήκες που στην πραγματικότητα είναι φυσιολογικές για έναν συγκεκριμένο αισθητήρα. Αυτό σπαταλά άσκοπα χρόνο από την παραγωγική διαδικασία και επηρεάζει επίσης τη διαθεσιμότητα του αισθητήρα. Από την άλλη, ενδέχεται να υπάρχουν περιπτώσεις ελλিপών συναγερμών για καταστάσεις που είναι στην πραγματικότητα προβληματικές, αλλά δεν επισημαίνονται. Αυτή είναι μια πιο σοβαρή κατάσταση, καθώς η ζημιά έχει ήδη γίνει, οδηγώντας σε υψηλά κόστη επισκευής και απώλεια παραγωγής.

3.2.2 Πρόβλεψη Εναπομείνουσας Χρήσιμης Ζωής

Όταν πρόκειται για προγνωστική συντήρηση, οι τεχνικές μηχανικής μάθησης διαδραματίζουν καθοριστικό ρόλο στην πρόβλεψη της υγείας του εξοπλισμού. Μεταξύ αυτών, τα μοντέλα παλινδρόμησης χρησιμοποιούνται ευρέως για την πρόβλεψη της εναπομείνουσας ωφέλιμης ζωής. Ως εναπομείνουσα ωφέλιμη ζωή μηχανολογικού εξοπλισμού, ορίζεται το αναμενόμενο χρονικό διάστημα λειτουργίας μεταξύ της παρούσας στιγμής και της στιγμής κατά την οποία κάποιο εξάρτημα ή ολόκληρο το σύστημα θα χρειαστεί αντικατάσταση [35]. Ο ορθός υπολογισμός της, εξασφαλίζει την αξιοπιστία και την ασφάλεια των συστημάτων, καθώς παρέχει δεδομένα αναφοράς για την ανάπτυξη σχεδίων και χρονοδιαγραμμάτων συντήρησης, ενώ παράλληλα επιτρέπει τη βελτιστοποίηση της λειτουργικής τους απόδοσης μέσω αποφυγής μη προγραμματισμένων διακοπών και σημαντικών μόνιμων βλαβών. Στο πλαίσιο της πρόβλεψης αυτής, η βασική ιδέα της παλινδρόμησης είναι να μοντελοποιήσει στο πεδίο του χρόνου τη σχέση μεταξύ των διαφόρων μετρήσεων των αισθητήρων μέχρι να αστοχήσει ένα κομμάτι του εξοπλισμού.




Σχήμα 3.4: Βήματα Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής [28]

Η διαδικασία υπολογισμού της Εναπομείνουσας Χρήσιμης Ζωής ολοκληρώνεται σε δύο κύριες φάσεις, όπως φαίνεται και στο σχήμα 3.4: την φάση μάθησης και την φάση εκμετάλλευσης [27]. Κατά την φάση μάθησης αφού ταυτοποιηθούν τα κρίσιμα τμήματα του μηχανολογικού εξοπλισμού μέσω μεθόδων αποτυχίας και ανάλυση κρισιμότητας (FMECA), είναι απαραίτητος ο καθορισμός των αισθητήρων, οι οποίοι θα χρησιμοποιηθούν για την εποπτεία της συμπεριφοράς και της υποβάθμισης απόδοσης του εκάστοτε εξαρτήματος. Με τον τρόπο αυτό, συλλέγονται σημαντικά δεδομένα, η επεξεργασία και η ανάλυση των οποίων ακολουθείται από την τοπική εκπαίδευση μοντέλων. Έπειτα, ξεκινά η φάση εκμετάλλευσης με την επιλογή του καταλληλότερου μοντέλου και καταλήγει στον υπολογισμό της Εναπο-

μείνου Χρήσιμης Ζωής. Συνήθως, για την εκτίμηση αυτή, υπολογίζονται τρεις τιμές και συγκεκριμένα τα άνω και κάτω όρια σε συνδυασμό με μία μέση τιμή.

Για την ακριβή πρόβλεψη της RUL του εξοπλισμού έχουν αναπτυχθεί ποικίλα μοντέλα και προσεγγίσεις [40]. Πιο αναλυτικά :

- **Μοντέλα Βασισμένα στη Γνώση:** Πρόκειται για μοντέλα που αξιολογούν την ομοιότητα μεταξύ μιας παρατηρούμενης κατάστασης και μιας βάσης δεδομένων με προηγούμενες καθορισμένες αποτυχίες, με το προβλεπόμενο προσδόκιμο ζωής να βασίζεται σε προηγούμενα γεγονότα. Χωρίζονται σε συστήματα εμπειρογνομόνων, τα οποία χρησιμοποιούν τη γνώση εμπειρογνομόνων για την αξιολόγηση σεναρίων αστοχίας, και σε ασαφή συστήματα που χειρίζονται την αβεβαιότητα και την ασάφεια στα δεδομένα αστοχίας για την πρόβλεψη των αποτελεσμάτων.
- **Μοντέλα Προσδόκιμου Ζωής:** Αυτά τα μοντέλα εκτιμούν το προσδόκιμο ζωής μεμονωμένων εξαρτημάτων μηχανών με βάση τον αναμενόμενο κίνδυνο φθοράς υπό γνωστές συνθήκες λειτουργίας. Διαχωρίζονται σε στατιστικά και στοχαστικά μοντέλα :
 - **Στοχαστικά Μοντέλα:** Οι συγκεντρωτικές συναρτήσεις αξιοπιστίας εκτιμούν τη συνολική αξιοπιστία με βάση ιστορικά δεδομένα. Μέθοδοι υπό συνθήκη πιθανότητας, όπως η συνάρτηση πυκνότητας πιθανότητας RUL και τα δίκτυα Bayes, προβλέπουν την πιθανότητα αστοχίας.
 - **Στατιστικά Μοντέλα:** Η παρέκταση τάσεων χρησιμοποιεί ιστορικές τάσεις για την πρόβλεψη μελλοντικών επιδόσεων. Τα μοντέλα αυτοπαλινδρομικού κινητού μέσου (ARMA) αναλύουν δεδομένα χρονοσειρών για την πρόβλεψη μελλοντικών τιμών και τα μοντέλα αναλογικών κινδύνων (PHM) εξετάζουν την επίδραση διαφόρων παραγόντων στο ποσοστό κινδύνου.
- **Τεχνητά Νευρωνικά Δίκτυα:** Αυτά τα μοντέλα εκτιμούν την εναπομείνουσα ωφέλιμη ζωή ενός εξαρτήματος ή μιας μηχανής χρησιμοποιώντας μια μαθηματική αναπαράσταση που προέρχεται από δεδομένα παρατήρησης και όχι από τη φυσική κατανόηση των διαδικασιών αστοχίας. Μπορούν να χρησιμοποιηθούν για άμεση πρόβλεψη της RUL, προβλέποντας απευθείας την εναπομείνουσα ωφέλιμη ζωή του εξοπλισμού, ή για παραμετρική εκτίμηση που αφορά άλλα μοντέλα, παρέχοντας εκτιμήσεις παραμέτρων για τη βελτίωση της ακρίβειάς τους.
- **Φυσικά Μοντέλα:** Αυτά τα μοντέλα εκτιμούν την RUL ενός εξαρτήματος ή μηχανήματος με βάση μια μαθηματική αναπαράσταση της φυσικής συμπεριφοράς των διαδικασιών υποβάθμισης. Τείνουν συνήθως να είναι ιδιαίτερα εξιδεικευμένα ως προς την εκάστοτε εφαρμογή ή τύπο αποτυχίας και, ως εκ τούτου, δεν ταξινομούνται περαιτέρω.



Σχήμα 3.5: Πρόβλεψη Εναπομείνουσας Χρήσιμης Ζωής [3]

3.2.3 Οφέλη της Μηχανικής Μάθησης στην Προγνωστική Συντήρηση

Η ενσωμάτωση των μοντέλων μηχανικής μάθησης στις στρατηγικές προγνωστικής συντήρησης προσφέρει σημαντικά οφέλη:

- **Πρόβλεψη της Εναπομείνουσας Χρήσιμης Ζωής (RUL)**

Με τη χρήση μοντέλων παλινδρόμησης, μπορεί να εκτιμηθεί η RUL του εξοπλισμού, επιτρέποντας τον ακριβή προγραμματισμό της συντήρησης. Αυτό εξασφαλίζει ότι οι επεμβάσεις γίνονται έγκαιρα για να αποφευχθούν απρογραμμάτιστες διακοπές, βελτιστοποιώντας τον προγραμματισμό συντήρησης και την κατανομή των πόρων.

- **Ανίχνευση Ανωμαλιών και Προτύπων Βλαβών**

Η μηχανική μάθηση αριστεύει στον εντοπισμό αποκλίσεων από τη φυσιολογική λειτουργία. Οι αλγόριθμοι ανίχνευσης ανωμαλιών επεξεργάζονται τεράστια ποσά δεδομένων για να αποκαλύψουν ισχυρές ενδείξεις φθοράς ή δυσλειτουργίας του εξοπλισμού, επιτρέποντας την λήψη προληπτικών ενεργειών συντήρησης πριν τα προβλήματα κλιμακωθούν.

- **Παροχή Έγκαιρων Προειδοποιήσεων**

Με την ικανότητα να αναλύουν τάσεις και να προβλέπουν μελλοντικές συνθήκες, τα μοντέλα μηχανικής μάθησης λειτουργούν ως σύστημα έγκαιρης προειδοποίησης. Εντοπίζουν πιθανές βλάβες του εξοπλισμού, προσφέροντας την ευκαιρία διόρθωσης προβλημάτων πριν οδηγήσουν σε κοστοβόρες διακοπές λειτουργίας.

- **Βελτιστοποίηση Περιοδικών Λειτουργιών Συντήρησης**

Οι παραδοσιακοί προγραμματισμοί συντήρησης μπορεί να οδηγήσουν σε περιττές επιθεωρήσεις ή χαμένες ευκαιρίες για επισκευή. Η μηχανική μάθηση βελτιστοποιεί αυτές τις λειτουργίες, ευθυγραμμίζοντας τις εργασίες συντήρησης με τις πραγματικές ανάγκες του εξοπλισμού, μειώνοντας έτσι το λειτουργικό κόστος.

3.2.4 Προκλήσεις στην Εφαρμογή Τεχνικών Μηχανικής Μάθησης για Προγνωστική Συντήρηση

Η εφαρμογή τεχνικών μηχανικής μάθησης (Machine Learning) για προγνωστική συντήρηση συναντά διάφορες προκλήσεις που μπορούν να επηρεάσουν την επιτυχία αυτών των προγραμμάτων. Πιο αναλυτικά :

- **Σημασία των Δεδομένων Εκπαίδευσης με Σενάρια Αστοχίας**

Τα μοντέλα μηχανικής μάθησης απαιτούν ποικίλα παραδείγματα αστοχιών εξοπλισμού για να κατανοήσουν τα υποκείμενα πρότυπα και τις συνθήκες που οδηγούν σε βλάβες. Χωρίς αυτές τις κρίσιμες πληροφορίες, οι προβλεπτικές δυνατότητες του μοντέλου μειώνονται σημαντικά.

- **Επαρκής Συλλογή Δεδομένων Εκπαίδευσης**

Η συλλογή αρκετών δεδομένων που απεικονίζουν αστοχίες αποτελεί σημαντικό εμπόδιο, καθώς αυτά τα γεγονότα είναι ευτυχώς σπάνια σε καλά συντηρημένες λειτουργίες. Η σπανιότητα των αστοχιών σημαίνει ότι υπάρχουν λιγότερα δεδομένα για την εκπαίδευση ισχυρών μοντέλων, καθιστώντας δύσκολη την αποτελεσματική μάθηση αυτών των συστημάτων.

- **Χρονοβόρα Συλλογή Δεδομένων**

Η διαδικασία συλλογής λεπτομερών χρονοσειρών δεδομένων και πληροφοριών αστοχίας απαιτεί πολύ χρόνο. Περιλαμβάνει προσεκτική παρακολούθηση και καταγραφή σε μεγάλες χρονικές περιόδους, γεγονός που μπορεί να καθυστερήσει την υλοποίηση λύσεων προγνωστικής συντήρησης.

- **Περιορισμένη Διαθεσιμότητα Ποιοτικών Δεδομένων**

Τα ποιοτικά δεδομένα εκπαίδευσης είναι συχνά σπάνια για διάφορους λόγους, όπως η μη συλλογή ιστορικών δεδομένων, τα προβλήματα με αισθητήρες ή εξοπλισμό καταγραφής δεδομένων ή απλά επειδή τα απαραίτητα σημεία δεδομένων δεν θεωρήθηκαν πολύτιμα την στιγμή που έπρεπε.

Συμπέρασμα

Η χρήση της μηχανικής μάθησης για την προγνωστική συντήρηση αποτελεί έναν έξυπνο τρόπο για τη βελτίωση της αξιοπιστίας του εξοπλισμού και την ελαχιστοποίηση του χρόνου διακοπής λειτουργίας. Με αυτά τα προηγμένα εργαλεία, οι επιχειρήσεις μπορούν να εντοπίζουν και να αντιμετωπίζουν προβλήματα προτού προκύψουν δυσάρεστες καταστάσεις.

Κεφάλαιο 4

Σύστημα Ανίχνευσης Ανωμαλιών

Σε αυτό το κεφάλαιο αναλύεται η μεθοδολογία για την υλοποίηση μοντέλων μηχανικής μάθησης με σκοπό την ανίχνευση ανωμαλιών στην λειτουργία μίας αλεστικής μηχανής. Αρχικά, παρέχονται πληροφορίες σχετικά με το περιβάλλον και τα εργαλεία, τα οποία χρησιμοποιήθηκαν κατά την υλοποίηση του συστήματος. Στην συνέχεια, παρουσιάζεται το σύνολο δεδομένων πάνω στο οποίο εκπαιδεύτηκαν και δοκιμάστηκαν τα μοντέλα, ενώ ακολουθεί η αναλυτική περιγραφή των βημάτων προεπεξεργασίας, στην οποία υποβλήθηκε. Τέλος, επεξηγούνται οι λεπτομέρειες εφαρμογής των διαφορετικών μοντέλων που χρησιμοποιήθηκαν στις διαδικασίες ταξινόμησης και ομαδοποίησης.

4.1 Εργαλεία που Χρησιμοποιήθηκαν

Η υλοποίηση έγινε στην εφαρμογή Visual Studio Code και γράφτηκε σε Jupyter Notebook, σε γλώσσα προγραμματισμού Python. Το Visual Studio Code¹ είναι μία ελεύθερη, ανοιχτού λογισμικού εφαρμογή επεξεργασίας κώδικα που αναπτύχθηκε από τη Microsoft και προσφέρει λειτουργίες όπως debugging, έλεγχο εκδόσεων και επεκτάσεις για την υποστήριξη διαφόρων γλωσσών προγραμματισμού. Το Jupyter Notebook² είναι μία εφαρμογή ανοιχτού κώδικα, η οποία επιτρέπει τον διαμοιρασμό εγγράφων που περιέχουν κώδικα, εξισώσεις και γραφήματα. Όπως αναφέρθηκε παραπάνω, το σύστημα αναπτύχθηκε σε γλώσσα Python³, μία γλώσσα προγραμματισμού υψηλού επιπέδου, γνωστή για την ευελιξία, την ανάλυση δεδομένων και την κατοχή βιβλιοθηκών που είναι απαραίτητες για την ανάπτυξη μοντέλων μηχανικής μάθησης. Μία τέτοια βιβλιοθήκη είναι η Scikit-learn⁴, η οποία παρέχει απλά και αποδοτικά εργαλεία μηχανικής μάθησης που αφορούν θέματα ταξινόμησης, παλινδρόμησης και ομαδοποίησης. Χρήσιμες βιβλιοθήκες, οι οποίες χρησιμοποιήθηκαν είναι, επίσης, η Pandas⁵, η οποία χρησιμεύει στην διαχείριση και την ανάλυση δεδομένων, παρέχοντας δομές όπως τα Dataframes, αλλά και η Numpy⁶, μία θεμελιώδης βιβλιοθήκη της Python για αριθμητικούς υπολογισμούς, παρέχοντας υποστήριξη για μεγάλους, πολυδιάστατους πίνακες και μητρώα.

¹<https://code.visualstudio.com/>

²<https://jupyter.org/>

³<https://www.python.org/>


⁴<https://scikit-learn.org/>

⁵<https://pandas.pydata.org/>

⁶<https://numpy.org/>

4.2 Σύνολο Δεδομένων

Το επιλεγμένο σύνολο δεδομένων δημιουργήθηκε μέσω εξομοίωσης μίας μηχανής αλέσματος και είναι διαθέσιμο στην διαδικτυακή πλατφόρμα Kaggle⁷. Αποτελείται από 10000 σημεία δεδομένων, όπου το καθένα συνοδεύεται από 6 χαρακτηριστικά και δύο στήλες κλάσης. Πιο αναλυτικά, τα χαρακτηριστικά του συνόλου περιλαμβάνουν τα εξής: Τύπος Μηχανής(L, M ή H), Θερμοκρασία Αέρα (Βαθμοί Κέλβιν), Θερμοκρασία Επεξεργασίας (Βαθμοί Κέλβιν), Ταχύτητα Περιστροφής, Ροπή Περιστροφής και Φθορά Εργαλείων. Οι στήλες κλάσης συνδέονται μεταξύ τους, καθώς η μία δηλώνει αν υπάρχει βλάβη ή όχι, ενώ η δεύτερη επεξηγεί τον τύπο της βλάβης. Όπως αναφέρθηκε, το σύνολο προέκυψε μέσω εξομοίωσης λειτουργίας μίας μονάδας αλέσματος σε πραγματικές συνθήκες, συνεπώς τα δεδομένα, τα οποία δηλώνουν την ύπαρξη βλάβης στη μηχανή είναι ελάχιστα σε σχέση με αυτά που αναφέρονται σε υγιή λειτουργία, όπως φαίνεται και στο σχήμα 4.1.



Σχήμα 4.1: Ποσοστό Δειγμάτων που ανήκουν στις κλάσεις Failure και Not Failure

Όσον αφορά τους τύπους αποτυχίας της μηχανής, αυτοί είναι οι ακόλουθοι:

- **Αποτυχία λόγω Φθοράς Εξαρτήματος (Tool Wear Failure):** Στην προκειμένη περίπτωση παρατηρείται πρόβλημα σε κάποιο εξάρτημα. Το εν λόγω εξάρτημα θα πρέπει να αντικατασταθεί, αλλιώς θα προκληθεί βλάβη εντός 200 έως 240 λεπτών.
- **Αποτυχία Διάχυσης Θερμότητας (Heat Dissipation Failure):** Εφόσον η διαφορά θερμοκρασίας αέρα και επεξεργασίας είναι κάτω από τους $8.6K$ και η ταχύτητα περιστροφής του εξαρτήματος είναι κάτω από 1380 περιστροφές το λεπτό, τότε προκαλείται η συγκεκριμένη αποτυχία. Η κατάσταση αυτή παρατηρείται 115 φορές στο σύνολο δεδομένων.
- **Αποτυχία Ισχύος (Power Failure):** Η αποτυχία αυτή προκύπτει εάν η ισχύς της μονάδας είναι κάτω από $3500W$ ή μεγαλύτερη από $9000W$. Το σενάριο αυτό οδηγεί σε 95 αποτυχίες.

⁷<https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset>

- **Αποτυχία Υπερβολικής Καταπόνησης (Overstrain Failure):** Η αποτυχία αυτή προκαλείται όταν το γινόμενο της φθοράς των εξαρτημάτων με την ροπή περιστροφής ξεπερνά την τιμή $11,000 \text{ min} * Nm$ για τις μονάδες τύπου L , την τιμή $12,000 \text{ min}Nm$ για τις μονάδες τύπου M και την τιμή $13,000 \text{ min} * Nm$ για τις H .
- **Τυχαίες Αποτυχίες (Random Failures):** Κάθε διαδικασία έχει 0.01% πιθανότητα να αποτύχει, ανεξάρτητα από τις παραμέτρους λειτουργίας της μηχανής. 19 τέτοιες τυχαίες αποτυχίες εντοπίζονται στο σύνολο 10,000 δειγμάτων.

4.3 Προεπεξεργασία Δεδομένων

Τα δεδομένα είναι σε μορφή csv, συνεπώς ορίζουμε το μονοπάτι του φακέλου στον οποίο βρίσκονται και τα μετατρέπουμε σε dataframes για την πιο εύκολη επεξεργασία τους, με τις παρακάτω γραμμές κώδικα.

```
1 dataset_path = '/Milling_Dataset/Dataset/ai4i2020.csv'
2 milling_df = pd.read_csv(dataset_path)
```

Κώδικας 4.1: Μετατροπή Συνόλου σε Dataframe

4.3.1 Περιγραφική Ανάλυση Συνόλου

Έχοντας, πλέον, το σύνολο δεδομένων της μηχανής αποθηκευμένο στο `milling_df`, προχωράμε στην ανάλυση και την επεξεργασία των χαρακτηριστικών. Αρχικά, επιβεβαιώνουμε πως δεν υπάρχουν null τιμές ανάμεσα στα 10000 δείγματα και στη συνέχεια παρατηρούμε την περιγραφική στατιστική ανάλυση των στοιχείων.

```
1 milling_df.describe()
```

	UDI	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Target
count	10000.00000	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000
mean	5000.50000	300.004930	310.005560	1538.776100	39.986910	107.951000	0.033900
std	2886.89568	2.000259	1.483734	179.284096	9.968934	63.654147	0.180981
min	1.00000	295.300000	305.700000	1168.000000	3.800000	0.000000	0.000000
25%	2500.75000	298.300000	308.800000	1423.000000	33.200000	53.000000	0.000000
50%	5000.50000	300.100000	310.100000	1503.000000	40.100000	108.000000	0.000000
75%	7500.25000	301.500000	311.100000	1612.000000	46.800000	162.000000	0.000000
max	10000.00000	304.500000	313.800000	2886.000000	76.600000	253.000000	1.000000

Σχήμα 4.2: Στατιστική Ανάλυση Συνόλου Δεδομένων

Από τα παραπάνω στοιχεία, αυτά που δεν μας παρέχουν ουσιώδη πληροφορία είναι το UDI και το Product ID κάθε δείγματος και για τον λόγο αυτό τα απομακρύνουμε από το dataframe. Από το `milling_df` αφαιρούνται επίσης όλα τα δείγματα, τα οποία ανήκουν στην κατηγορία Random Failures. Αυτό συμβαίνει, καθώς παρόλο που αναφέρονται σε αποτυχία του συστήματος, ταξινομούνται στην κατηγορία υγιούς λειτουργίας, περιπλέκοντας αρκετά το σύνολο.

4.3.2 Μετατροπή Κατηγορικών Δεδομένων σε Αριθμητικά

Οι στήλες Type και Failure Type περιέχουν κατηγορικές μεταβλητές, οι οποίες για να επεξεργαστούν από τα μοντέλα μηχανικής μάθησης χρειάζεται να μετατραπούν σε αριθμητικά δεδομένα. Για τον λόγο αυτό αξιοποιείται ο Label Encoder⁸, ο οποίος παρέχεται από την Scikit-learn και αποτελεί ένα εργαλείο που στόχος του είναι να αντιστοιχίσει κάθε κατηγορική ετικέτα σε έναν ακέραιο αριθμό. Η αντιστοίχιση γίνεται στους αριθμούς από το 0 μέχρι το $v-1$, όπου v είναι ο αριθμός των μοναδικών κατηγοριών.

```
1 from sklearn.preprocessing import LabelEncoder
2 le = LabelEncoder()
3
4 milling_df['Failure Type'] = le.fit_transform(milling_df['Failure Type'])
5 failure_type_mapping = dict(zip(le.classes_, le.transform(le.classes_)))
6 print("Limited Label Mapping for 'Failure Type':", list(failure_type_mapping.
7 items())[0:2])
8 print("Limited Label Mapping for 'Failure Type':", list(failure_type_mapping.
9 items())[2:])
10
11 milling_df['Type'] = le.fit_transform(milling_df['Type'])
12 type_mapping = dict(zip(le.classes_, le.transform(le.classes_)))
13 print("Label Mapping for 'Type':", type_mapping)
```

Κώδικας 4.2: Εφαρμογή Label Encoder

```
Limited Label Mapping for 'Failure Type': [('Heat Dissipation Failure', 0), ('No Failure', 1)]
Limited Label Mapping for 'Failure Type': [('Overstrain Failure', 2), ('Power Failure', 3), ('Tool Wear Failure', 4)]
Label Mapping for 'Type': {'H': 0, 'L': 1, 'M': 2}
```

4.3.3 Διαχωρισμός και Υπερδειγματοληψία Συνόλου

Έπειτα από τα παραπάνω βήματα προεπεξεργασίας το σύνολο δεδομένων αποτελείται από 9982 δείγματα. Ακολουθεί ο διαχωρισμός του, μέσω της `train_test_split` και ποσοστό 50%, σε σύνολο εκπαίδευσης και σύνολο δοκιμής. Ωστόσο, η ύπαρξη ελάχιστων δειγμάτων που δηλώνουν αποτυχία συστήματος δημιουργεί μεγάλη ανισορροπία στις κλάσεις, γεγονός που μπορεί να οδηγήσει κακή απόδοση των αλγορίθμων μηχανικής μάθησης. Συνεπώς, προκειμένου να ενισχύσουμε τις υποεκπροσωπούμενες κλάσεις εφαρμόζουμε την τεχνική υπερδειγματοληψίας **SMOTE**⁹.


SMOTE

Η τεχνική SMOTE αποτελεί μία τεχνική που χρησιμοποιείται για την αντιμετώπιση της ανισορροπίας στις κλάσεις σε σύνολα δεδομένων ταξινόμησης. Δημιουργεί νέα, συνθετικά

⁸<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html>

⁹https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTE.html


δείγματα, τα οποία προκύπτουν από την παρεμβολή μεταξύ των ήδη υπάρχοντων δειγμάτων των μειονοτικών κλάσεων. Συγκεκριμένα, λαμβάνοντας υπόψη τα χαρακτηριστικά δύο ή περισσότερων υπάρχοντων δειγμάτων της κλάσης, δημιουργεί νέα σημεία στο χώρο. Αυτό μειώνει τον κίνδυνο υπερεκπαίδευσης, ο οποίος μπορεί να προκύψει αν απλά αντιγράψουμε τα ίδια δείγματα, αφού πλέον οι αλγόριθμοι δεν παραμελούν καμία από τις κλάσεις και λαμβάνουν καλύτερες αποφάσεις. Ως αποτέλεσμα (Σχήμα 4.3), προκύπτει ένα νέο σύνολο δεδομένων εκπαίδευσης, το οποίο αποτελείται από 24,086 δείγματα, 4800 περίπου για κάθε μία από τις κλάσεις.



Σχήμα 4.3: Πλήθος Δειγμάτων Κάθε Κλάσης έπειτα από Υπερδειγματοληψία

4.3.4 Κλιμάκωση Τιμών

Το επόμενο βήμα σχετίζεται με την κλιμάκωση των τιμών του συνόλου για την αποδοτικότερη εφαρμογή του σε διάφορα μοντέλα μηχανικής μάθησης. Για την καλύτερη επιλογή μεθόδου κλιμάκωσης, πρώτα εξετάζουμε τα δεδομένα για ακραίες τιμές, υπολογίζοντας την καμπυλότητα skewness για κάθε χαρακτηριστικό.



Σχήμα 4.4: Έλεγχος Ακραίων Τιμών για κάθε Χαρακτηριστικό του Συνόλου

Όπως βλέπουμε στο σχήμα 4.4 τα χαρακτηριστικά Air Temperature, Process Tempera-

ture και Tool wear έχουν μικρή τιμή καμπυλότητας και ελάχιστες ακραίες τιμές. Αντιθέτως, τα χαρακτηριστικά Rotational Speed και Torque διακρίνονται από μεγαλύτερη καμπυλότητα και αρκετές ακραίες τιμές. Για τον λόγο αυτό κλιμακώνουμε τις στήλες Rotational Speed και Torque με τον Robust Scaler, ο οποίος παρουσιάζει μικρότερη ευαισθησία στις ακραίες τιμές, ενώ στις υπόλοιπες στήλες εφαρμόζουμε Min-Max Scaling, το οποίο είναι ιδιαίτερα αποτελεσματικό σε δεδομένα χωρίς outliers.

Robust Scaler

Ο Robust Scaler αποτελεί μία μέθοδο κλιμάκωσης που χρησιμοποιείται σε περιπτώσεις όπου τα δεδομένα περιέχουν ακραίες τιμές (outliers). Λειτουργεί βασιζόμενος στην διάμεσο και στους ενδοτεταρτημοριακούς αποστάτες, αντί για μέσες και ακραίες τιμές. Ο βασικός τύπος για τον Robust Scaler είναι ο εξής:

$$X_{\text{scaled}} = \frac{X - \text{median}(X)}{\text{IQR}(X)} \quad (4.1)$$

Όπου X είναι η αρχική τιμή του χαρακτηριστικού, $\text{median}(X)$ η διάμεσος του χαρακτηριστικού και $\text{IQR}(X)$ η ενδοτεταρτημοριακή απόσταση $Q3-Q1$.

Min-Max Scaler

Η τεχνική Min-Max Scaling είναι μία μέθοδος κανονικοποίησης που χρησιμοποιείται για την κλιμάκωση των δεδομένων έτσι ώστε να βρίσκονται σε ένα συγκεκριμένο εύρος τιμών, συνήθως μεταξύ 0 και 1. Είναι ιδιαίτερα χρήσιμη σε περιπτώσεις, στις οποίες τα χαρακτηριστικά έχουν διαφορετικά εύρη τιμών και θέλουμε να τα φέρουμε σε μια συγκρίσιμη κλίμακα. Ο βασικός τύπος για τον Min-Max Scaler είναι ο εξής:

$$X_{\text{scaled}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \times (\text{newmax} - \text{newmin}) + \text{newmin} \quad (4.2)$$

Η διαδικασία αυτή, είναι απαραίτητη, καθώς υπάρχουν αρκετά μοντέλα μηχανικής μάθησης, τα οποία είναι ευαίσθητα στις κλίμακες των χαρακτηριστικών, όπως αλγόριθμοι που χρησιμοποιούν αποστάσεις, π.χ., K-Nearest Neighbors και Support Vector Machines.

Πλέον, μετά από όλα τα παραπάνω βήματα προεπεξεργασίας, καταλήγουμε με διαφορετικά dataframes, προκειμένου να πραγματοποιηθούν ποικίλες δοκιμές και να εφαρμοστούν τα κατάλληλα στο εκάστοτε μοντέλο. Πιο αναλυτικά, έχουμε στην διάθεσή μας τα εξής:

- **X_x:** Dataframe που προκύπτει από το milling_df, εφόσον αφαιρέσουμε τις στήλες Dataframe και Dataframe. Περιέχει 9982 δείγματα.
- **X_resampled:** Dataframe το οποίο προέκυψε έπειτα από την εφαρμογή της τεχνικής SMOTEomek και περιέχει 24,086 δείγματα.
- **X_Scaled:** Αφού εφαρμόσουμε τις προαναφερθείσες τεχνικές κλιμάκωσης στο X_resampled, παίρνουμε ως αποτέλεσμα το dataframe X_Scaled.

Scaled Training Data (X_Scaled):						
	Rotational speed [rpm]	Torque [Nm]	Air temperature [K]	Process temperature [K]	Tool wear [min]	Type
0	0.502591	-0.459324	0.791209	0.580247	0.189723	0.5
1	1.062176	-0.817698	0.384615	0.555556	0.134387	1.0
2	2.585492	-1.342640	0.747253	0.703704	0.766798	0.5
3	1.077720	-0.676368	0.648352	0.641975	0.280632	0.0
4	-0.129534	-0.141331	0.395604	0.518519	0.296443	0.5
Scaled Test Data (X_test_Scaled):						
	Rotational speed [rpm]	Torque [Nm]	Air temperature [K]	Process temperature [K]	Tool wear [min]	Type
1254	0.207254	0.005048	0.241758	0.382716	0.007905	0.0
9948	2.145078	-1.221500	0.318681	0.259259	0.426877	0.5
7062	0.088083	0.090855	0.582418	0.580247	0.620553	1.0
8729	-0.196891	0.227138	0.219780	0.370370	0.359684	0.5
6894	0.093264	-0.151426	0.637363	0.740741	0.533597	0.5

Σχήμα 4.5: Δεδομένα Συνόλου Εκπαίδευσης και Δοκιμής έπειτα από Κλιμάκωση

4.4 Προετοιμασία Μοντέλων και Υλοποίηση Συστήματος

Αφού ολοκληρώθηκε η προεπεξεργασία των δεδομένων και έχουμε στην κατοχή μας τα κατάλληλα δεδομένα, προχωρούμε στην προετοιμασία και την εφαρμογή μοντέλων μηχανικής μάθησης, για να κατηγοριοποιήσουμε τα δεδομένα και να ανιχνεύσουμε σφάλματα, όπου αυτά υπάρχουν.

4.4.1 Αλγόριθμοι που Χρησιμοποιήθηκαν

Το Σύστημα Ανίχνευσης Ανωμαλιών περιλαμβάνει πρόβλήματα, τα οποία ανήκουν στο πεδίο της κατηγοριοποίησης και της ομαδοποίησης και γι'αυτό χρησιμοποιήθηκαν οι κατάλληλοι αλγόριθμοι της βιβλιοθήκης SkLearn. Ειδικότερα, για την ταξινόμηση των δειγμάτων χρησιμοποιήθηκαν: 1) Αλγόριθμος Τυχαίου Δάσους (Random Forest), 2) Μηχανές Διανυσματικής Στήριξης (SVM), 3) Λογιστική Παλινδρόμηση (Logistic Regression), 4) Κ-Πλησιέστεροι Γείτονες (KNN), 5) Αφελής Μπεϋζιανός Ταξινομητής (Naive Bayes). Επιπροσθέτως, για την ομαδοποίηση των δεδομένων: 1) Κ-Μέσοι (K-Means), 2) Ισορροπημένη Επαναληπτική Μείωση και Ομαδοποίηση με Χρήση Ιεραρχιών (BIRCH), 3) Ιεραρχική Ομαδοποίηση (Hierarchical Clustering).

4.4.2 Μέθοδοι Λειτουργίας

Κατά την εφαρμογή των αλγορίθμων μηχανικής μάθησης, εφαρμόστηκαν ορισμένες από τις πιο γνωστές μεθόδους της προετοιμασίας και της λειτουργίας τους. Η προετοιμασία της λειτουργίας των μοντέλων μηχανικής μάθησης είναι ένα κρίσιμο βήμα που περιλαμβάνει μια σειρά από τεχνικές για τη βελτιστοποίηση της απόδοσης και της αξιοπιστίας των μο-

ντέλων. Ένα σημαντικό μέρος αυτής της διαδικασίας είναι η επιλογή και βελτιστοποίηση των υπερπαραμέτρων, δηλαδή των παραμέτρων που δεν μαθαίνονται από τα δεδομένα αλλά καθορίζονται πριν την εκπαίδευση του μοντέλου. Σημαντική κρίνεται, επίσης, εκτίμηση γενίκευσης του μοντέλου, δηλαδή η ικανότητά του να αποδίδει καλά σε νέα δεδομένα. Πιο αναλυτικά:

Αναζήτηση σε Πλέγμα (Grid Search)

Το Grid Search¹⁰ είναι μια μέθοδος σύμφωνα με την οποία, γίνεται αναζήτηση των βέλτιστων υπερπαραμέτρων σε ένα μοντέλο. Η πλειονότητα των αλγορίθμων μηχανικής μάθησης περιέχουν παραμέτρους που προσαρμόζονται και διαφοροποιούν τον τρόπο μάθησης του μοντέλου. Η λειτουργία του Grid Search είναι επαναληπτική, καθώς εξετάζει όλες τις περιπτώσεις. Ειδικότερα, η τακτική που ακολουθείται είναι πως αρχικά, ορίζεται ένα σύνολο διαφορετικών τιμών για τις υπερπαραμέτρους. Ακολουθώντας, δοκιμάζονται όλοι οι πιθανοί συνδυασμοί τους και εν τέλει επιλέγεται αυτός με την καλύτερο αποτέλεσμα. Για την αξιολόγηση χρησιμοποιείται πληθώρα τεχνικών, όπως η ακρίβεια (accuracy), το μέσο τετραγωνικό σφάλμα (MSE) και η περιοχή κάτω από την καμπύλη (Area Under Curve – AUC).

Διασταυρωμένη Επικύρωση K-Πλαισίων (K-Fold Cross Validation)

Η K-Fold Cross Validation¹¹ αποτελεί μία τεχνική, η οποία χρησιμοποιείται στην μηχανική μάθηση για την αξιολόγηση της απόδοσης του μοντέλου σε νέα δεδομένα. Περιλαμβάνει τον διαχωρισμό του συνόλου δεδομένων σε πολλαπλά υποσύνολα, χρησιμοποιώντας το ένα για επικύρωση και τα υπόλοιπα για εκπαίδευση. Η διαδικασία αυτή επαναλαμβάνεται πολλές φορές, και κάθε φορά διαφοροποιείται το σύνολο επικύρωσης. Τελικά, υπολογίζεται ο μέσος όρος των αποτελεσμάτων του βήματος επικύρωσης, με σκοπό την παραγωγή ενός πιο εύρωστου μοντέλου. Βασικός στόχος της διασταυρωμένης επικύρωσης είναι η αποφυγή της υπερκπαίδευσης, η οποία προκαλείται όταν ένα μοντέλο είναι πολύ καλά εκπαιδευμένο στα δεδομένα εκπαίδευσης, αλλά δεν αποδίδει το αναμενόμενο σε νέα, άγνωστα δεδομένα. Αξιολογώντας το μοντέλο σε πολλά σαι επικύρωσης, το K-Fold Cross Validation παρέχει μία πιο ρεαλιστική εκτίμηση για την γενικευμένη απόδοση του μοντέλου. Συνεπώς, το Cross Validation χρησιμοποιείται και για την σύγκριση διαφορετικών αλγορίθμων και την επιλογή εκείνου που επιστρέφει τα καλύτερα αποτελέσματα κατά μέσο όρο.

Μέθοδος K-Elbow

Η μέθοδος K-Elbow¹² είναι μία τεχνική, η οποία έχει ως στόχο να καθορίσει τον ιδανικό αριθμό συστάδων σε έναν αλγόριθμο ομαδοποίησης και βασίζεται στην ιδέα της εξισορρόπησης μεταξύ του αριθμού των συστάδων και της μείωσης του σφάλματος ομαδοποίησης. Στην

¹⁰https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

¹¹https://scikit-learn.org/stable/modules/cross_validation.html

¹²<https://www.scikit-yb.org/en/latest/api/cluster/elbow.html>

ουσία ο αλγόριθμος τρέχει διαφορετικές τιμές του k (αριθμός συστάδων), ξεκινώντας από την μονάδα μέχρι ένα προκαθορισμένο μέγιστο. Για κάθε τιμή του k υπολογίζεται το άθροισμα των σφαλμάτων τετραγώνου που δείχνει το πόσο συμπαγής είναι κάθε ομάδα. Έπειτα, σχεδιάζεται το γράφημα των σφαλμάτων αυτών με τον αριθμό k και εντοπίζεται το σημείο "elbow", που αποτελεί τον ιδανικό αριθμό συστάδων και όπου η μείωση των σφαλμάτων αρχίζει να φθίνει.

4.4.3 Υλοποίηση Αλγορίθμου Τυχαίου Δάσους (Random Forest)

Για την εκπαίδευση και τη δοκιμή του Αλγορίθμου Τυχαίου Δάσους χρησιμοποιήθηκαν τα σύνολα **X_resampled**, **y_resampled** και **X_test**, **y_test**, αντίστοιχα. Αρχικά, μετατρέπουμε το **y_resampled** σε μονοδιάστατο πίνακα και ορίζουμε το *rf_model* ως τον βασικό ταξινομητή. Έπειτα, δημιουργούμε το πλέγμα αναζήτησης των κατάλληλων υπερπαραμέτρων του μοντέλου, στο οποίο θα εφαρμοστεί Grid Search. Για τον Random Forest οι υπερπαραμέτροι που εξετάζονται είναι συνολικός αριθμός των δέντρων του μοντέλου (*n_estimators*), το μέγιστο βάθος κάθε δέντρου (*max_depth*), ο ελάχιστος αριθμός δειγμάτων που απαιτείται για τον διαχωρισμό ενός κόμβου (*min_samples_split*), ο ελάχιστος αριθμός δειγμάτων που απαιτείται για να θεωρηθεί ένας κόμβος ως φύλλο και η επιλογή *bootstrap*, η οποία καθορίζει εάν το δέντρο θα εκπαιδευτεί σε ολόκληρο το σύνολο ή σε τυχαία δείγματα με αντικατάσταση από το αυθεντικό σύνολο εκπαίδευσης.

```

1 y_resampled_array = y_resampled.values.ravel()
2 rf_model = RandomForestClassifier(random_state=42)
3
4 param_grid = {
5     'n_estimators': [50, 100, 150, 200],
6     'max_depth': [None, 10, 20, 30, 40],
7     'min_samples_split': [2, 5, 10],
8     'min_samples_leaf': [1, 2, 4],
9     'bootstrap': [True, False]
10 }
11 grid_search = GridSearchCV(estimator=rf_model, param_grid=param_grid, cv=5,
12                             n_jobs=-1, scoring='f1_macro', verbose=1)

```

Κώδικας 4.3: Αναζήτηση σε Πλέγμα στον Αλγόριθμο Τυχαίου Δάσους

```

Fitting 5 folds for each of 360 candidates, totalling 1800 fits
Best Parameters:
{'bootstrap': False, 'max_depth': None, 'min_samples_leaf': 1, 'min_samples_split': 2, 'n_estimators': 50}
Best Score: 0.9960

```

Ακολουθεί η εκτέλεση της αναζήτησης στο πλέγμα, όπου εκτελείται διασταυρωμένη επικύρωση 5 φορές, εξετάζοντας όλες τους πιθανούς συνδυασμούς στον βασικό ταξινομητή. Η απόδοση κάθε συνδυασμού υπερπαραμέτρων αξιολογείται μέσω του *macro-averaged f1 score*, ιδανικό για σύνολα με ανισορροπία, ενώ η παράμετρος *n_jobs=-1* δηλώνει την χρήση όλων των πυρήνων του συστήματος. Αφού, ολοκληρωθεί η αναζήτηση, οι βέλτιστες υπερπαραμέτροι τυπώνονται μαζί με την απόδοσή τους.

4.4.4 Υλοποίηση Μηχανής Διανυσματικής Στήριξης (SVM)

Στην Μηχανή Διανυσματικής Στήριξης ακολουθείται η ίδια διαδικασία, ωστόσο το σύνολο που χρησιμοποιείται για εκπαίδευση είναι το **X_Scaled**. Στην προκειμένα περίπτωση, το πλέγμα αναζήτησης περιλαμβάνει τρεις παραμέτρους. Η παράμετρος C ελέγχει τον συμβιβασμό μεταξύ μικρού σφάλματος και ελαχιστοποίησης της πολυπλοκότητας του μοντέλου, η γ καθορίζει την επιρροή ενός μόνο παραδείγματος εκπαίδευσης και με την επιλογή *kernel* επιλέγουμε τον τύπο πυρήνα του μοντέλου.

```

1 y_resampled_array = y_resampled.values.ravel()
2 svm = SVC()
3
4 kernels = ['linear', 'rbf']
5 C_space = [0.01, 0.1, 1, 10, 100]
6 gamma_space = [0.01, 0.1, 1, 10]
7
8 param_grid = {'C': C_space, 'kernel': kernels, 'gamma': gamma_space}
9 grid_search = GridSearchCV(svm, param_grid=param_grid, cv=5,
10                             n_jobs=-1, scoring='f1_macro', verbose=2)
11
12 grid_search.fit(X_Scaled, y_resampled_array)

```

Κώδικας 4.4: Αναζήτηση σε Πλέγμα στην Μηχανή Διανυσματικής Στήριξης

Η αναζήτηση πραγματοποιείται όπως και στον Αλγόριθμο Τυχαίου Δάσους και μας επιστρέφει τις βέλτιστες υπερπαραμέτρους σε συνδυασμό με την αξιολόγηση της απόδοσής τους.

```

Best Parameters:
{'C': 100, 'gamma': 10, 'kernel': 'rbf'}
Best Score: 0.9955

```

4.4.5 Υλοποίηση Λογιστικής Παλινδρόμησης (Logistic Regression)

Η υλοποίηση της Λογιστικής Παλινδρόμησης κάνει επίσης χρήση του κλιμακωμένου συνόλου **X_Scaled** για εκπαίδευση και περιλαμβάνει την μετατροπή του **y_resampled** σε μονοδιάστατο πίνακα. Ακολουθεί ο ορισμός του ταξινομητή με τις κατάλληλες υπερπαραμέτρους.

```

1 y_resampled_array = y_resampled.values.ravel()
2
3 log_reg = LogisticRegression(C = 10, solver = 'liblinear', max_iter = 1000,
4                               multi_class = 'auto', penalty = 'l1' )

```

Κώδικας 4.5: Υλοποίηση Λογιστικής Παλινδρόμησης

Η παράμετρος C αποτελεί έναν όρο βαθμού αντίστροφης κανονικοποίησης, ο *solver* καθορίζει τον αλγόριθμο που θα αναζητήσει τις καλύτερες παραμέτρους του μοντέλου, το *max_iter* καθορίζει τον μέγιστο αριθμό επαναλήψεων του αλγορίθμου και η παράμετρος *penalty* καθορίζει τον τύπο κανονικοποίησης για αποφυγή υπερπροσαρμογής στα δεδομένα.

Η $L1$ κανονικοποίηση ενθαρρύνει τα αραιά δεδομένα, που σημαίνει ότι μπορεί να οδηγήσει ορισμένους συντελεστές χαρακτηριστικών σε τιμή ίση με μηδέν, επιλέγοντας αποτελεσματικά χαρακτηριστικά.

4.4.6 Υλοποίηση K-Πλησιέστερων Γειτόνων (KNN)

Η υλοποίηση του αλγορίθμου K-Πλησιέστερων Γειτόνων είναι ακριβώς ίδια με αυτήν της Μηχανής Διανυσματικής Στήριξης. Η διαφορά έγκειται στον ορισμό του πλέγματος, το οποίο προφανώς περιέχει διαφορετικές υπερπαραμέτρους, καθώς αναφέρεται σε νέο μοντέλο. Ειδικότερα, το πλέγμα περιλαμβάνει τον ελάχιστο αριθμό γειτόνων που ελέγχονται για κάθε σημείο δεδομένων ($n_{neighbors}$), την παράμετρο *weights* που ορίζει τον αν οι κοντινότεροι γείτονες θα έχουν μεγαλύτερο βάρος και την παράμετρο p , η οποία δηλώνει την μετρική απόστασης που χρησιμοποιείται (1:Μανχάταν, 2:Ευκλείδια).

```

1 y_resampled_array = y_resampled.values.ravel()
2 knn_classifier = KNeighborsClassifier()
3
4 param_grid = {
5     'n_neighbors': [3, 5, 7, 15, 25, 50, 100, 150, 250],
6     'weights': ['uniform', 'distance'],
7     'p': [1, 2]
8 }
9 grid_search = GridSearchCV(estimator=knn_classifier, param_grid=param_grid,
10                             cv=5,
11                             n_jobs=-1,
12                             scoring='f1_macro',
13                             verbose=1)
14
15 grid_search.fit(X_Scaled, y_resampled_array)

```

Κώδικας 4.6: Αναζήτηση σε Πλέγμα στον αλγόριθμο K-Πλησιέστερων Γειτόνων

Η αναζήτηση πραγματοποιείται όπως και στον Αλγόριθμο Μηχανής Διανυσματικής Στήριξης και μας επιστρέφει τις βέλτιστες υπερπαραμέτρους σε συνδυασμό με την αξιολόγηση της απόδοσής τους.

```

Fitting 5 folds for each of 36 candidates, totalling 180 fits
Best Parameters:
{'n_neighbors': 3, 'p': 2, 'weights': 'distance'}
Best Score: 0.9837

```

4.4.7 Υλοποίηση Αφελή Μπεϋζιανού Ταξινομητή (Naive Bayes)

Η υλοποίηση του αλγορίθμου Naive Bayes περιλαμβάνει την χρήση του κλιμακωμένου συνόλου **X_Scaled**, το βήμα μετατροπής του **y_resampled** σε μονοδιάστατο πίνακα και τον ορισμού του βασικού ταξινομητή, ωστόσο δεν ορίζονται υπερπαραμέτροι και δεν πραγματοποιείται αναζήτηση σε πλέγμα.


4.4.8 Υλοποίηση Αλγορίθμου K-Μέσων(K-Means)

Για την εκπαίδευση και την αναζήτηση ομάδων, ο αλγόριθμος K-Μέσων αξιοποιεί το σύνολο $\mathbf{X_x}$, ενώ αρχικοποιεί ένα μοντέλο KMeans.

```
1 kmeans_model = KMeans()
2
3 visualizer = KElbowVisualizer(kmeans_model, k=(2,10))
4 visualizer.fit(X)
5 visualizer.show()
```

Κώδικας 4.7: Εφαρμογή KElbow Visualizer

Στην συνέχεια, αρχικοποιείται ο K-Elbow Visualizer της βιβλιοθήκης Yellowbrick με σκοπό την εύρεση του ιδανικού αριθμού συστάδων. Ο όρος $k=(2,10)$, δηλώνει πως ο αλγόριθμος θα υπολογίσει το άθροισμα των σφαλμάτων τετραγώνου για τιμές του k από το 2 έως το 10.



Σχήμα 4.6: Οπτικοποίηση Μεθόδου Elbow


Το σχήμα 4.6 μας πληροφορεί πως ο ιδανικός αριθμός για το k είναι το 4. Πέρα από αυτό το σημείο, το ποσοστό μείωσης των σφαλμάτων τετραγώνου μειώνεται σημαντικά και συνεπώς η προσθήκη επιπρόσθετων συστάδων δεν θα βοηθήσει. Τέλος, το kmeans μοντέλο αρχικοποιείται με τις κατάλληλες παραμέτρους και προχωρά στις προβλέψεις.

```
kmeans_model = KMeans(init='random', n_clusters=4, n_init=10, max_iter=300, random_state=42)
```

4.4.9 Υλοποίηση Ισορροπημένης Επαναληπτικής Μείωσης και Ομαδοποίησης με Χρήση Ιεραρχιών (BIRCH)

Στην περίπτωση του αλγορίθμου BIRCH χρησιμοποιείται επίσης το σύνολο $\mathbf{X_x}$, ενώ για τον εντοπισμό του ιδανικού αριθμού συστάδων ο αλγόριθμος τρέχει δοκιμάζοντας τιμές από

το 2 έως το 9, μετρώντας για καθεμία το Silhouette Score της.




Σχήμα 4.7: Silhouette Scores για διαφορετικό αριθμό συστάδων

Από το σχήμα 4.7 γίνεται κατανοητό πως ο πιο αποδοτικός αριθμός clusters που δεν χωρίζει απλά το σύνολο σε δύο μεγάλες ομάδες, είναι ο 3.

4.4.10 Υλοποίηση Ιεραρχικής Ομαδοποίησης (Hierarchical Clustering)

Για την ιεραρχική ομαδοποίηση χρησιμοποιείται επίσης το σύνολο $\mathbf{X}_x$, ενώ η εύρεση του βέλτιστου αριθμού συστάδων πραγματοποιείται μέσω της δημιουργίας ενός δενδρογράμματος. Η συνάρτηση `shc.linkage()` υπολογίζει τον πίνακα σύνδεσης, η μέθοδος `ward` για τον υπολογισμό των αποστάσεων μεταξύ των συστάδων, μειώνοντας την διασπορά σε καθεμία και η ευκλείδεια απόσταση για την μέτρηση των αποστάσεων μεταξύ σημείων.



Σχήμα 4.8: Δενδρογράμμα Ιεραρχικής Ομαδοποίησης

Με βάση το δενδρογράμμα του σχήματος 4.8, συμπεραίνουμε πως ο ιδανικός αριθμός συστάδων είναι ο 3.

```
1 # plot dendrogram
2 plt.figure(figsize=(8, 5))
3 plt.title("Predictive Maintenance Dendrogram")
4
5 clusters = shc.linkage(X, method='ward', metric="euclidean")
6 shc.dendrogram(Z=clusters)
7 plt.show()
```

Κώδικας 4.8: Δημιουργία Δενδρογράμματος

Κεφάλαιο 5

Σύστημα Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής

Το κεφάλαιο αυτό, αφορά την ανάπτυξη μοντέλων μηχανικής μάθησης με στόχο την πρόβλεψη της εναπομείνουσας χρήσιμης ζωής και την πρόγνωση βλαβών σε κινητήρες αεροσκαφών, αξιοποιώντας το σύνολο δεδομένων CMAPSS της Nasa. Όπως και στο **Κεφάλαιο 4**, εδώ παρουσιάζονται το περιβάλλον και τα εργαλεία, τα οποία αξιοποιήθηκαν κατά την υλοποίηση του συστήματος, καθώς και το σύνολο δεδομένων που επιλέχθηκε για την πρόγνωση. Επίσης, περιγράφονται αναλυτικά τα βήματα προεπεξεργασίας του συνόλου δεδομένων και προετοιμασίας των μοντέλων μηχανικής μάθησης, τα οποία χρησιμοποιήθηκαν.


5.1 Εργαλεία που Χρησιμοποιήθηκαν

Όσον αφορά το περιβάλλον υλοποίησης και την γλώσσα προγραμματισμού που χρησιμοποιήθηκαν, δεν υπάρχουν διαφορές σε σχέση με αυτά του συστήματος του **Κεφαλαίου 4**. Πιο συγκεκριμένα, ως περιβάλλον υλοποίησης παρέμεινε η εφαρμογή Visual Studio Code σε συνδυασμό με την επέκταση Jupyter Notebook και ως γλώσσα ανάπτυξης η Python. Στο παρόν σύστημα χρησιμοποιούνται, επίσης, οι βιβλιοθήκες Numpy, Pandas και Scikit-Learn, με την τελευταία να περιέχει όλα τα μοντέλα των αλγορίθμων που χρησιμοποιήθηκαν στο σύστημα.

5.2 Σύνολο Δεδομένων

Για το σύστημα υπολογισμού Εναπομείνουσας Χρήσιμης Ζωής, χρησιμοποιήθηκε το σύνολο δεδομένων CMAPSS (Commercial Modular Aero-Propulsion System Simulation) της Nasa και το οποίο είναι διαθέσιμο στην επίσημη ιστοσελίδα της¹. Πρόκειται για ένα ευρέως χρησιμοποιούμενο σύνολο δεδομένων, το οποίο αφορά την έρευνα στον τομέα της προληπτικής συντήρησης και περιλαμβάνει λεπτομερή δεδομένα από τη λειτουργία και την απόδοση κινητήρων αεροσκαφών υπό διάφορες συνθήκες λειτουργίας και καταστάσεις φθοράς. Περιλαμβάνει τέσσερα διαφορετικά σύνολα δεδομένων, καθένα από τα οποία αντιπροσωπεύει διαφορετικά σενάρια λειτουργίας και καταστάσεις βλάβης.

¹https://data.nasa.gov/Aerospace/CMAPSS-Jet-Engine-Simulated-Data/ff5v-kuh6/about_data



Σχήμα 5.1: Σχηματική Απεικόνιση του κινητήρα της εξομοίωσης CMAPSS [25]

Στο συγκεκριμένο σύστημα, εκπαιδεύσαμε τα μοντέλα μας χρησιμοποιώντας το FD001, το οποίο περιέχει 20.631 μετρήσεις από 100 διαφορετικές μονάδες, ενώ ο μόνος τύπος σφάλματος που εμφανίζεται είναι η υποβάθμιση HPC. Η υποβάθμιση των κινητήρων έγινε μέσω εξομοίωσης υπό διάφορες συνθήκες λειτουργίας και φθοράς. Όπως αναφέρθηκε νωρίτερα, στόχος του dataset είναι η πρόβλεψη της εναπομείνουσας χρήσιμης ζωής κάθε ενός από τους 100 κινητήρες του συνόλου δοκιμής. Ως εναπομείνουσα χρήσιμη ζωή, ορίζεται ο αριθμός των πτήσεων που απομένει έπειτα από το τελευταίο σημείο δεδομένων που αφορά τον εκάστοτε κινητήρα.

Κάθε σύνολο δεδομένων περιέχει δεδομένα από πολλαπλές πτήσεις, με κάθε πτήση να αποτελείται από μια σειρά χρονικών σημείων. Ο κινητήρας έχει ομαλή λειτουργία στην αρχή κάθε χρονοσειράς και αναπτύσσει κάποια σφάλμα σε κάποια χρονική στιγμή. Στο σύνολο εκπαίδευσης, το σφάλμα αυτό εξελίσσεται μέχρι την αποτυχία του συστήματος, ενώ στο σύνολο δοκιμής τα δεδομένα δείγματα σταματούν πριν ο κινητήρας σταματήσει να λειτουργεί εντελώς. Σε κάθε χρονική στιγμή καταγράφονται πολλαπλές μετρήσεις αισθητήρων, συμπεριλαμβανομένων πιέσεων, θερμοκρασιών, ροών και άλλων σχετικών παραμέτρων, οι οποίες στο σύνολό τους είναι 26.

Το CMAPSS μέσω του οποίου έγινε η εξομοίωση είναι ένα εργαλείο βασισμένο σε MATLAB και Simulink. Επιτρέπει στους χρήστες να πειραματιστούν με διάφορες παραμέτρους λειτουργίας, συμπεριλαμβανομένων περιβαλλοντικών συνθηκών και συνθηκών λειτουργίας. Η εξομοίωση καλύπτει ένα ευρύ φάσμα συνθηκών των πτήσεων, όπως υψόμετρα που κυμαίνονται από το επίπεδο της θάλασσας έως τα 40.000 πόδια και θερμοκρασίες από τους -60 μέχρι τους 103 °F. Στο σχήμα 5.1 παρουσιάζονται τα βασικά στοιχεία του μοντέλου και το πώς διάφορες υπορουτίνες εκτελέστηκαν κατά την εξομοίωση.

5.3 Προεπεξεργασία Δεδομένων

Τα χαρακτηριστικά του συνόλου δεδομένων χωρίζονται σε τρεις κατηγορίες, τα **index names**, τα **setting names** και τα **sensor names**. Τα πρώτα περιλαμβάνουν τον αριθμό του κινητήρα και τον κύκλο ζωής του κάθε δείγματος, στα δεύτερα περιέχονται τρεις ρυθμίσεις λειτουργίας, ενώ τα **sensor names** αναφέρονται στις μετρήσεις των 21 αισθητήρων του μοντέλου. Όλα τα παραπάνω ορίζονται ως **column names** και είναι οι 26 στήλες του συνόλου δεδομένων, το οποίο αποτελείται από τέσσερα csv αρχεία. Τα δεδομένα είναι ήδη χωρισμένα σε σύνολο εκπαίδευσης και σύνολο δοκιμής, με την μεταβλητή στόχο RUL για το testing να βρίσκεται σε ξεχωριστό αρχείο. Αρχικά, λοιπόν, διαβάζουμε τα αρχεία και τα μετατρέπουμε σε dataframes για την πιο αποδοτική επεξεργασία τους.

```

1 file_path1 = "/Turbofan_Jet_Engine/CMaps/train_FD001.txt"
2 FD1_Train = pd.read_csv(file_path1, delimiter=' ', header = None, index_col =
   False, names = column_names)
3
4 file_path2 = "/Turbofan_Jet_Engine/CMaps/test_FD001.txt"
5 FD1_Test = pd.read_csv(file_path2, delimiter=' ', header = None, index_col =
   False, names = column_names)
6
7 file_path3 = '/Turbofan_Jet_Engine/CMaps/RUL_FD001.txt'
8 FD1_y_Test = pd.read_csv(file_path3, header = None, names=['RUL'])

```

Κώδικας 5.1: Μετατροπή Συνόλου Δεδομένων σε Dataframes

5.3.1 Προσθήκη Στήλης RUL στο Dataframe

Όπως αναφέρθηκε παραπάνω, στο σύνολο εκπαίδευσης παρέχονται δείγματα που αφορούν τους κινητήρες μέχρι και τον τελευταίο κύκλο ζωής τους. Ωστόσο, στα δεδομένα δεν συμπεριλαμβάνεται η τιμή της RUL, την οποία καλούμαστε να υπολογίσουμε. Ειδικότερα, από τον κύκλο ζωής, κατά τον οποίο σταματά η λειτουργία ενός κινητήρα, δηλαδή το συνολικό χρόνο λειτουργίας κάθε μονάδας πριν συμβεί κάποια βλάβη, αφαιρούμε τον αριθμό του κύκλου ζωής που βρίσκεται ο κινητήρας μία δεδομένη στιγμή. Έτσι, προστίθεται μία νέα στήλη με όνομα 'RUL', η οποία για κάθε δείγμα δηλώνει το πλήθος των κύκλων ζωής που του απομένει.

```


1 unit_lifetime = FD1_Train.groupby('unit_number')['time_cycles'].transform('max'
   )
2
3 # Set1 Train
4 FD1_Train['RUL'] = unit_lifetime - FD1_Train['time_cycles']
5 unit_rul_df_train = FD1_Train[['unit_number', 'RUL']]
6
7 # Upper Limit for RUL
8 FD1_Train['RUL'][FD1_Train['RUL']>130]=130

```

Κώδικας 5.2: Δημιουργία Στήλης RUL

Μετά την προσθήκη της νέας στήλης με την μεταβλητή στόχο, ορίζουμε για τις τιμές της RUL ένα άνω όριο, ίσο με 130. Αυτό γίνεται, διότι για υψηλές τιμές της RUL οι τιμές που μετρούν οι αισθητήρες δεν παρουσιάζουν διαφορές, ενώ ταυτόχρονα δεν θέλουμε τα μοντέλα μας να “μάθουν” να προβλέπουν πολύ μεγάλες τιμές εναπομείναντων κύκλων ζωής, καθώς το ενδιαφέρον της πρόβλεψης εντοπίζεται στις περιπτώσεις όπου η ζωή μίας μονάδας φτάνει προς το τέλος της και οι μεταβλητές λειτουργίας της παρουσιάζουν κάποια υποβάθμιση.

5.3.2 Αφαίρεση μη-χρήσιμων χαρακτηριστικών



Σχήμα 5.2: Μητρώο Συσχετίσεων με Κάτω Όριο το 0.85

Έχοντας ένα dataframe για κάθε σύνολο, προχωρούμε στην ανάλυση των υπόλοιπων μεταβλητών. Αρχικά, εντοπίζουμε τα στοιχεία εκείνα, τα οποίων η τιμή παραμένει σταθερή στο πέρασμα των κύκλων λειτουργίας, υπολογίζοντας την τυπική τους απόκλιση. Πιο συγκεκρι-

μένα, επτά στοιχεία με τυπική απόκλιση μικρότερη από το κατώφλι 10^{-6} απομακρύνονται από το dataset, καθώς δεν προσφέρουν ουσιώδη πληροφορία.

Σε συνέχεια απομάκρυνσης στοιχείων, τα οποία δεν βοηθούν στην πρόβλεψη και στοχεύοντας στην μείωση της πολυπλοκότητας του συνόλου, δημιουργούμε ένα μητρώο συσχετίσεων. Στο μητρώο αυτό απεικονίζονται οι συσχετίσεις όλων των μεταβλητών με την μεταβλητή στόχο *RUL*, αλλά και όσες αφορούν άλλα ζεύγη μεταβλητών και έχουν τιμή μεγαλύτερου του κατωφλίου 0,85. Εάν σε ένα dataset υπάρχουν δύο ή περισσότερες πολύ συσχετισμένες μεταβλητές, τότε αφαιρούνται οι λιγότερο σημαντικές, με σκοπό να μειωθεί η πολυπλοκότητα, η οποία είναι δυνατόν να προκαλέσει ευαισθησία στις αλλαγές των δεδομένων, δυσκολία στην ερμηνεία των συντελεστών και διακυμάνσεις στις εκτιμήσεις.

Στο μητρώο συσχετίσεων του σχήματος 5.2, παρατηρούμε πως υπάρχει το ζεύγος *Physical Core Speed-Corrected Core Speed* που ξεπερνά το όριο και συνεπώς, αφαιρούμε το δεύτερο που είναι λιγότερο σημαντικό. Επίσης, παρατηρώντας το σχήμα, βλέπουμε πως τα δύο χειρότερα χαρακτηριστικά, όσον αφορά την πληροφορία που παρέχουν για την εναπομείνουσα χρήσιμη ζωή κάθε μονάδας, είναι οι δύο ρυθμίσεις, *setting 1* και *setting 2*. Ως αποτέλεσμα, προχωράμε στην αφαίρεσή τους από το dataframe.

```
1 # Drop Constant Attributes
2 constant_columns = FD1_Train.columns[FD1_Train.std() < 0.000001]
3 print(constant_columns)
4
5 FD1_Train.drop(constant_columns,axis=1,inplace=True)
6 FD1_Test.drop(constant_columns,axis=1,inplace=True)
```

Κώδικας 5.3: Αφαίρεση Σταθερών Χαρακτηριστικών

Έπειτα από τις παραπάνω ενέργειες, διαχωρίζουμε το σύνολο εκπαίδευσης, δημιουργώντας ένα dataframe με τις ανεξάρτητες μεταβλητές και ένα για την μεταβλητή *RUL*. Από το πρώτο, λοιπόν, απομακρύνουμε την στήλη *RUL* και την στήλη *unit number* που δηλώνει τον αριθμό της μονάδας, ενώ στο δεύτερο προσθέτουμε μόνο μία στήλη για την *RUL*. Η δομή των δύο dataframes για το σύνολο εκπαίδευσης έχει ως εξής:

```
FD1_X_Train shape: (20631, 15)
FD1_y_Train shape: (20631,)
```

5.3.3 Προσαρμογή Συνόλου Δοκιμής

Όσον αφορά το σύνολο δοκιμής, αυτό είναι ήδη χωρισμένο σε δύο dataframes, χαρακτηριστικών και μεταβλητής στόχου. Ωστόσο, το csv αρχείο *RUL FD001.txt* περιέχει μία *RUL* τιμή για κάθε μονάδα, η οποία αντιστοιχεί στον τελευταίο δεδομένο κύκλο ζωής της στο σύνολο δοκιμής που είναι σαφές πως δεν είναι ο τελευταίος κύκλος ζωής της γενικότερα. Αυτό σημαίνει πως τα μοντέλα αφού εκπαιδευτούν, πρέπει να κάνουν τις προβλέψεις τους πάνω σε ένα σύνολο που θα περιέχει μόνο ένα δείγμα για κάθε κινητήρα.

```
1 Last5_X_Test = FD1_Test.groupby('unit_number').tail(5)
```


Για τον λόγο αυτό, για κάθε μία μονάδα από τις 100, υπολογίζουμε τον μέσο όρο των μεταβλητών της, λαμβάνοντας υπόψη τους τελευταίους 5 γνωστούς κύκλους ζωής, έτσι ώστε το dataframe δοκιμής, για το οποίο θα γίνουν οι υπολογισμοί, να διατηρεί μόνο 100 δείγματα, ένα για κάθε μονάδα και η πρόβλεψη να είναι ακριβέστερη. Η δομή των δύο dataframes για το σύνολο δοκιμής έχει ως εξής:

```
Last_5_X_Test shape: (100, 15)
FD1_y_Test shape: (100, 1)
```

5.3.4 Κλιμάκωση Τιμών

Αρχικά ελέγχουμε για την ύπαρξη 'missing values' στα παραπάνω με τη χρήση της συνάρτησης **isnull** και παρατηρούμε πως δεν υπάρχουν τιμές της μορφής 'NaN' σε κανένα από τα δύο dataframes. Ακολουθεί η εφαρμογή δύο τεχνικών κλιμάκωσης, της Min-Max και της Standard².

Standard Scaling

Το Standard Scaling είναι μία τεχνική κλιμάκωσης που χρησιμοποιείται για να μετασχηματίσει τα δεδομένα με τέτοιον τρόπο που να έχουν μηδενική μέση τιμή και τυπική απόκλιση 1. Ο μετασχηματισμός αυτός φαίνεται και στο σχήμα 5.3. Ο τύπος, ο οποίος ακολουθείται για το standardization είναι ο εξής :

$$X' = \frac{X - \mu}{\sigma} \quad (5.1)$$

Vdcmean1	Vdcmax1	Vdcmin1	Pdcmean1	IR	T	range 1	range 2	range 3	range 4
513.522799	514.369415	509.002655	169.603373	660	22	0.343390	0.343390	1.332270e-14	5.773160e-15
516.959237	521.970593	503.241431	116.954097	450	15	0.400736	0.400736	1.554310e-14	0.000000e+00
511.459214	511.837039	509.378912	184.213307	720	24	0.247183	0.247183	2.131630e-14	7.105430e-15
515.757920	518.028478	507.378348	147.283635	570	19	0.527644	0.527644	1.199040e-14	1.332270e-14
500.334599	500.827418	500.127036	238.608844	960	32	5.314147	5.314147	2.442490e-14	2.042810e-14
Vdcmean1	Vdcmax1	Vdcmin1	Pdcmean1	IR	T	range 1	range 2	range 3	range 4
0.715087	0.667757	0.801222	0.605310	0.619687	0.48	0.003063	0.003063	1.0	1.597576e-15
0.776950	0.799837	0.671459	0.384166	0.384787	0.20	0.003578	0.003578	1.0	0.000000e+00
0.677939	0.623754	0.809697	0.666676	0.686801	0.56	0.002200	0.002200	1.0	1.966248e-15
0.755324	0.731338	0.764637	0.511560	0.519016	0.36	0.004716	0.004716	1.0	3.686720e-15
0.477674	0.432449	0.601312	0.895155	0.955257	0.88	0.047656	0.047656	1.0	5.652960e-15

Σχήμα 5.3: Δεδομένα πριν και μετά το Standardization

Ο λόγος εφαρμογής και των δύο τεχνικών κλιμάκωσης είναι πως κάθε μοντέλο μηχανικής μάθησης έχει τις δικές του ιδιαιτερότητες και αποδίδει καλύτερα σε διαφορετικές συνθήκες. Πλέον, μετά από όλα τα παραπάνω βήματα προεπεξεργασίας, καταλήγουμε με διαφορετικά

²<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>

dataframes, προκειμένου να πραγματοποιηθούν ποικίλες δοκιμές και να εφαρμοστούν τα κατάλληλα στο εκάστοτε μοντέλο. Πιο αναλυτικά, έχουμε στην διάθεσή μας τα εξής:

- **FD1_Train:** Dataframe που περιέχει όλα τα στοιχεία του συνόλου, εκτός από τις σταθερές μεταβλητές.
- **FD1_X_Train:** Dataframe από το οποίο έχουν αφαιρεθεί τα στοιχεία εκείνα (*setting 1* και *setting 2*) που δεν προσφέρουν ουσιώδη πληροφορία.
- **FD1_X_Train_sc:** Dataframe, από το οποίο έχουν αφαιρεθεί μη χρήσιμα στοιχεία και έχει υποστεί Min-Max κλιμάκωση.
- **FD1_X_Train_st:** Dataframe, από το οποίο έχουν αφαιρεθεί μη χρήσιμα στοιχεία και έχει υποστεί Standard κλιμάκωση.
- **Fed_X_Test:** Dataframe για το σύνολο δοκιμής, το οποίο περιέχει τις τιμές, μόνο για τον τελευταίο γνωστό κύκλο ζωής κάθε κινητήρα.
- **Last_5_X_Test:** Dataframe για το σύνολο δοκιμής, το οποίο περιέχει τον μέσο όρο των τιμών, από τους 5 τελευταίους γνωστούς κύκλους ζωής κάθε κινητήρα.

5.4 Προετοιμασία Μοντέλων και Υλοποίηση Συστήματος

Αφού ολοκληρώθηκε η προεπεξεργασία των δεδομένων και έχουμε στην κατοχή μας τα κατάλληλα dataframes, προχωρούμε στην προετοιμασία και την εφαρμογή μοντέλων μηχανικής μάθησης, για να υπολογίσουμε την εναπομείνουσα ωφέλιμη ζωή κινητήρων αεροσκαφών.

5.4.1 Αλγόριθμοι που Χρησιμοποιήθηκαν και Μέθοδοι Λειτουργίας

Εφόσον το πρόβλημα που αντιμετωπίζουμε είναι ένα πρόβλημα παλινδρόμησης, χρησιμοποιήθηκαν οι πιο γνωστοί αλγόριθμοι παλινδρόμησης, οι οποίοι είναι διαθέσιμοι στην βιβλιοθήκη SkLearn. Ονομαστικά, είναι οι ακόλουθοι: 1) Αλγόριθμος Τυχαίου Δάσους (Random Forest), 2) Μηχανές Διανυσματικής Στήριξης (SVM), 3) Γραμμική Παλινδρόμηση (Linear Regression), 4) Λογιστική Παλινδρόμηση (Logistic Regression), 5) Κ-Πλησιέστεροι Γείτονες (KNN), 6) Ακραία Ενίσχυση Κλίσης (XGBoost).

Κατά την εφαρμογή των αλγορίθμων μηχανικής μάθησης, εφαρμόστηκαν οι τεχνικές, οι οποίες αναφέρθηκαν στο **Κεφάλαιο 4** και συγκεκριμένα η Αναζήτηση σε Πλέγμα και η Διασταυρωμένη Επικύρωση Κ-Πλαισίων. Η πρώτη βοηθά στην επιλογή των κατάλληλων υπερπαραμέτρων για το κάθε μοντέλο, ενώ η δεύτερη μας παρέχει μία εκτίμηση για την απόδοσή του σε άγνωστα δεδομένα.

5.4.2 Υλοποίηση Αλγορίθμου Τυχαίου Δάσους (Random Forest)

Για την εκπαίδευση και την δοκιμή του Αλγορίθμου Τυχαίου Δάσους χρησιμοποιήθηκαν τα σύνολα **FD1_X_Train**, **FD1_y_Train** και **FD1_X_Test**, **FD1_y_Test**, αντίστοιχα. Αρχικά, μετατρέπουμε τα **FD1_y_Train** και **FD1_y_Test** σε μονοδιάστατους πίνακες, συνθήκη που απαιτείται για την εκπαίδευση του μοντέλου και κατόπιν ορίζουμε ως *rf* το βασικό μοντέλο του αλγορίθμου. Στην συνέχεια, για τις ανάγκες του Grid Search δημιουργούμε το πλέγμα αναζήτησης υπερπαραμέτρων του μοντέλου, τοποθετώντας τις πιο πιθανές τιμές. Για τον Random Forest οι υπερπαραμέτροι που εξετάζονται είναι ο συνολικός αριθμός των δέντρων του μοντέλου (*n_estimators*) και το *max_features*, το οποίο δηλώνει πώς επιλέγεται ο αριθμός των χαρακτηριστικών που χρησιμοποιούνται για τον διαχωρισμό στους κόμβους.

```

1 rf = RandomForestRegressor(n_jobs=-1, random_state=38)
2
3 param_grid = {
4     "n_estimators": [50, 200, 300, 400, 500],
5     "max_features": ["sqrt", "log2"]
6 }
7
8 grid_search = GridSearchCV(estimator=rf, param_grid=param_grid,
9                             scoring="neg_root_mean_squared_error",
10                             n_jobs=-1, cv=5)
11
12 grid_search.fit(FD1_X_Train, FD1_y_Train_array)

```

Κώδικας 5.4: Αναζήτηση σε Πλέγμα και Εκπαίδευση Αλγορίθμου Τυχαίου Δάσους

Περνώντας στην εκτέλεση της αναζήτησης με το Grid Search, εδώ εκτελείται διασταυρωμένη επικύρωση, εξετάζοντας όλες τους πιθανούς συνδυασμούς στο βασικό μοντέλο *rf*. Ως μέτρο απόδοσης χρησιμοποιείται η αρνητική ρίζα μέσου τετραγωνικού σφάλματος, ενώ με το *n_jobs = -1* δηλώνουμε πως θα αξιοποιηθούν όλοι οι πυρήνες του συστήματος. Όταν η αναζήτηση ολοκληρωθεί, πραγματοποιείται εκτύπωση των καλύτερων παραμέτρων και το μοντέλο με τις βέλτιστες υπερπαραμέτρους, αποθηκεύεται στη μεταβλητή *rf_new*. Αφού, λοιπόν, ανακτήθηκε το βέλτιστο μοντέλο, ακολουθεί η πρόβλεψη στα δεδομένα εκπαίδευσης και στα δεδομένα δοκιμής. Κατα τη διάρκεια των παραπάνω διαδικασιών, μετρήθηκαν ο χρόνος που απαιτήθηκε για την αναζήτηση Grid Search, οι χρόνοι πρόβλεψης, αλλά και ο συνολικός χρόνος υλοποίησης του αλγορίθμου.

Best Parameters: {'max_features': 'sqrt', 'n_estimators': 500}

5.4.3 Υλοποίηση Μηχανής Διανυσματικής Στήριξης (SVM)

Στην περίπτωση της SVM το σύνολο δεδομένων πάνω στο οποίο εκπαιδεύεται το μοντέλο πρέπει να έχει υποστεί κλιμάκωση. Για τον λόγο αυτό επιλέγονται τα **FD1_X_Train_sc**, **FD1_y_Test_sc**, dataframes που προέκυψαν από την εφαρμογή Min-Max Scaling. Η διαδικασία που ακολουθείται είναι ίδια με αυτή του Random Forest και περιλαμβάνει την μετατροπή των συνόλων της μεταβλητής στόχου σε μονοδιάστατους πίνακες και τον ορισμό του βασικού μοντέλου *svr*.

```

1 svr = SVR()
2 param_grid = {
3     'kernel': ['rbf'],
4     'C': [0.01, 0.1, 1, 10, 50, 100],
5     'epsilon': [0.01, 0.1, 1, 5, 10, 50],
6     'gamma': [0.01, 0.1, 0.5, 1, 10]
7 }
8 grid_search = GridSearchCV(svr, param_grid=param_grid,
9                             cv=5, n_jobs = -1,
10                             scoring='neg_mean_squared_error', verbose=2)
11
12 grid_search.fit(FD1_X_Train_sc, FD1_y_Train_array)

```

Κώδικας 5.5: Αναζήτηση σε Πλέγμα και Εκπαίδευση Μηχανής Διανυσματικής Στήριξης

Όσον αφορά τις υπερπαραμέτρους της Μηχανής Διανυσματικής Στήριξης, αυτές είναι πολλές, γεγονός που καθιστά την αναζήτηση Grid Search απαραίτητη. Πιο συγκεκριμένα, το πλέγμα περιέχει τον rbf πυρήνα και πολλαπλές τιμές για τις παραμέτρους *C*, *epsilon* και *gamma*. Το *C* θέτει το όριο που διατηρεί το μοντέλο ανάμεσα στον βαθμό εκπαίδευσης και την πολυπλοκότητα. Το *epsilon* αφορά την μέγιστη απόσταση από την ακριβή πρόβλεψη χωρίς να επιβάλλεται ποινή, ενώ το *gamma* ορίζει τη μορφή του rbf πυρήνα.

```

Best Parameters: {'C': 100, 'epsilon': 10, 'gamma': 1, 'kernel': 'rbf'}
Best Score (NMSE): 324.82361364217763

```

Όταν η αναζήτηση ολοκληρωθεί, πραγματοποιείται εκτύπωση των καλύτερων παραμέτρων βάσει αρνητικής ρίζας μέσου τετραγωνικού σφάλματος και το μοντέλο με τις βέλτιστες υπερπαραμέτρους, αποθηκεύεται στη μεταβλητή *svm_reg_new*. Αφού, λοιπόν, ανακτήθηκε το βέλτιστο μοντέλο, ακολουθεί η πρόβλεψη με παράλληλο υπολογισμό των χρόνων που απαιτούνται.

5.4.4 Υλοποίηση Γραμμικής Παλινδρόμησης (Linear Regression)

Ο αλγόριθμος Γραμμικής Παλινδρόμησης δεν απαιτεί κανονικοποιημένα δεδομένα, συνεπώς αξιοποιεί τα dataframes **FD1_X_Train**, **FD1_y_Train** και **FD1_X_Test**, **FD1_y_Test**. Εκτελούνται τα ίδια βήματα με το SVM με το πλέγμα να περιέχει κυρίως τις επιλογές True ή False για τις υπερπαραμέτρους. Η διαφορά σε σχέση με τα προηγούμενα μοντέλα είναι πως ως μετρική αξιολόγησης των πιθανών συνδυασμών, χρησιμοποιείται το Μέσο Α-

πόλυτο Σφάλμα. Άρα, με τη σειρά ορίζονται το βασικό μοντέλο και το πλέγμα αναζήτησης και πραγματοποιείται η αναζήτηση του συνδυασμού που επιστρέφει τα καλύτερα αποτελέσματα.

```

1 linear_reg = LinearRegression()
2
3 param_grid = {
4     'fit_intercept': [True, False],
5     'copy_X': [True, False],
6     'n_jobs': [None, -1],
7     'positive': [True, False],
8 }
9
10 grid_search = GridSearchCV(estimator=linear_reg, param_grid=param_grid,
11                             cv=5, scoring='neg_mean_absolute_error')
12
13 grid_search.fit(FD1_X_Train, FD1_y_Train_array)

```

Κώδικας 5.6: Αναζήτηση σε Πλέγμα και Εκπαίδευση Γραμμικής Παλινδρόμησης

Αναλυτικά, το *fit_intercept* αποφασίζει για το εάν θα υπολογιστεί η σταθερά intercept, το *copy_X* αν είναι αληθές, δεν τροποποιούνται τα δεδομένα, ενώ το *positive* θέτει αν έχει τιμή True ή False, τοποθετεί θετικούς ή αρνητικούς συντελεστές, αντίστοιχα, στη λύση. Κατά τα άλλα ακολουθούν παρόμοια βήματα εκτέλεσης. επιλέγεται ο καλύτερος εκτιμητής, εκτυπώνονται τα καλύτερα αποτελέσματα και πραγματοποιείται ο υπολογισμός της ενπομείναςας χρήσιμης ζωής στα σύνολα εκπαίδευσης και δοκιμής.

5.4.5 Υλοποίηση K-Πλησιέστερων Γειτόνων (KNN)

Ο αλγόριθμος K-Πλησιέστερων γειτόνων αποδίδει καλύτερα όταν τα δεδομένα έχουν υποστεί standardization και γι'αυτό επιλέγουμε τα σύνολα dataframes **FD1_X_Train_st**, **FD1_y_Train** και **FD1_X_Test_st**, **FD1_y_Test**. Αφού τα δεδομένα της μεταβλητής στόχου μετατραπούν σε μονοδιάστατους πίνακες και αρχικοποιηθεί ο *knn_regressor*, ορίζεται το πλέγμα αναζήτησης. Σε αυτό το πλέγμα περιέχονται ο αριθμός των πλησιέστερων γειτόνων που χρησιμοποιούνται για την πρόβλεψη και η παράμετρος *weights*, η οποία καθορίζει αν το βάρος των γειτόνων είναι ίδιο για όλους ή εξαρτάται από την απόσταση. Στη συνέχεια, εκτελείται η αναζήτηση Grid Search, μέσω διασταυρωμένης επικύρωσης 5 φορές και αξιολόγησης βάσει αρνητικής ρίζας μέσου τετραγωνικού σφάλματος.

```

1 knn_regressor = KNeighborsRegressor()
2
3 param_grid = {
4     'n_neighbors': [3, 10, 50, 100, 250, 500],
5     'weights': ['uniform', 'distance']
6 }
7
8 grid_search_new = GridSearchCV(estimator=knn_regressor, param_grid=param_grid,
9                                 cv=5, verbose=1, scoring='
10     neg_mean_squared_error')

```

```
11 grid_search_new.fit(FD1_X_Train_st, FD1_y_Train_array)
```

Κώδικας 5.7: Αναζήτηση σε Πλέγμα και Εκπαίδευση K-Πλησιέστερων Γειτόνων

```
Fitting 5 folds for each of 12 candidates, totalling 60 fits
Best Parameters: {'n_neighbors': 50, 'weights': 'distance'}
Negative Mean Squared Error: -322.7652533208069
```

5.4.6 Υλοποίηση Ακραίας Ενίσχυσης Κλίσης (XGBoost)

Το XGBoost έχει ως βάση του τα δέντρα απόφασης και ως αποτέλεσμα όπως και ο αλγόριθμος Τυχαίου Δάσους χρησιμοποιεί τα **dataframes** **FD1_X_Train**, **FD1_y_Train** και **FD1_X_Test**, **FD1_y_Test**. Εδώ το πλέγμα αναζήτησης είναι αρκετά μεγάλο και περιέχει τα *learning_rate*, *max_depth*, *min_child_weight*, *gamma* και *objective*.

```
1 xgb_reg = xgb.XGBRegressor()
2
3 param_grid = {
4     'learning_rate': [0.01, 0.1, 0.2, 1],
5     'max_depth': [3, 5, 7],
6     'min_child_weight': [1, 3, 5],
7     'gamma': [0, 0.1, 0.2],
8     'objective': ['reg:squarederror']
9 }
10
11 grid_search = GridSearchCV(estimator=xgb_reg, param_grid=param_grid, cv=5,
12                             scoring='neg_mean_squared_error')
13 grid_search.fit(FD1_X_Train, FD1_y_Train_array)
```

Κώδικας 5.8: Αναζήτηση σε Πλέγμα και Εκπαίδευση XGBoost

Ειδικότερα, το *learning_rate* καθορίζει τον ρυθμό μάθησης του μοντέλου, το *max_depth* το μέγιστο βάθος των δέντρων και το *min_child_weight* τον ελάχιστο αριθμό παρατηρήσεων που απαιτείται για κάθε κόμβο φύλλου. Επίσης, η υπερπαραμέτρος *gamma* δείχνει το πόσο απαιτείται να μειωθεί η συνάρτηση κόστους για να διαχωριστεί ένας κόμβος και ο *objective* αποτελεί τον στόχο του μοντέλου, που στην προκειμένη περίπτωση είναι η τετραγωνική απώλεια σφάλματος. Όπως είναι λογικό, απαιτείται αρκετός χρόνος για την ολοκλήρωση της αναζήτησης, η οποία γίνεται με τον ίδιο τρόπο, όπως στους προηγούμενους αλγορίθμους και προφανώς την ακολουθούν οι αντίστοιχες προβλέψεις.


```
Best Parameters: {'gamma': 0, 'learning_rate': 0.2, 'max_depth': 3, 'min_child_weight': 5}
Negative Mean Squared Error: -312.43636415392416
```

Κεφάλαιο 6

Νευρωνικό Δίκτυο

Μακράς-Βραχύχρονης Μνήμης

Το κεφάλαιο αυτό αποτελεί συνέχεια του **Κεφαλαίου 5**, επεκτείνοντας την ανάπτυξη του συστήματος πρόβλεψης εναπομείναςας χρήσιμης ζωής κινητήρων αεροσκαφών. Πιο συγκεκριμένα, εκτός από τους αλγορίθμους που αναφέρθηκαν νωρίτερα, όσον αφορά το παρόν πρόβλημα εκτίμησης, υλοποιήθηκε και ένα Αναδρομικό Νευρωνικό Δίκτυο τύπου Μακράς-Βραχύχρονης Μνήμης. Στόχος του μοντέλου αυτού είναι με την κατάλληλη προεπεξεργασία και πειραματισμό να αποφέρει καλύτερα αποτελέσματα από τους κοινούς αλγορίθμους της βιβλιοθήκης Sklearn. Η επιλογή του Long Short-Term Memory δικτύου επιφέρει πολλά πλεονεκτήματα, όπως η αποτελεσματική διαχείριση μακροπρόθεσμων εξαρτήσεων. Τέτοιου είδους δίκτυα, είναι ιδανικά για πρόβλεψη χρονοσειρών, αφού διατηρούν τη χωρική και χρονική δομή των δεδομένων, ενώ ταυτόχρονα διακατέχονται από υψηλή ανθεκτικότητα στον θόρυβο. Ακολουθούν, τα εργαλεία που χρησιμοποιήθηκαν, η προετοιμασία του συνόλου, η παρουσίαση της αρχιτεκτονικής του δικτύου και δομή της μάθησης του μοντέλου.



Σχήμα 6.1: Δομή Αναδρομικού Νευρώνα LSTM [7]

6.1 Εργαλεία που Χρησιμοποιήθηκαν

Όσον αφορά το περιβάλλον υλοποίησης και την γλώσσα προγραμματισμού που χρησιμοποιήθηκαν, δεν υπάρχουν διαφορές σε σχέση με αυτά του συστήματος του **Κεφαλαίου 5**. Πιο συγκεκριμένα, ως περιβάλλον υλοποίησης παρέμεινε η εφαρμογή Visual Studio Code σε συνδυασμό με την επέκταση Jupyter Notebook και ως γλώσσα ανάπτυξης η Python. Για την ανάπτυξη του Αναδρομικού Νευρωνικού Δικτύου αξιοποιήθηκαν βιβλιοθήκες και εργαλεία, από την πλατφόρμα Tensorflow, όπως το Keras. Χαρακτηριστικά, εισάγονται τα layers και το Sequential που μας επιτρέπουν τη δημιουργία νευρωνικών δικτύων ως στοίβα από επίπεδα νευρώνων. Επίσης, χρησιμοποιείται ο Standard Scaler, καθώς το δίκτυο απαιτεί τυποποιημένα δεδομένα.

6.1.1 Tensorflow

Το Tensorflow¹ είναι μία ανοιχτού κώδικα πλατφόρμα για μηχανική μάθηση. Διαθέτει ένα ολοκληρωμένο και ευέλικτο οικοσύστημα εργαλείων και βιβλιοθηκών που επιτρέπει την χρήση State-of-the-art τεχνολογιών και την εύκολη υλοποίηση εφαρμογών μηχανικής μάθησης. Αναπτύχθηκε αρχικά από ερευνητές και μηχανικούς της Google και παρέχει σταθερά API's σε Python και C++.

6.1.2 Keras

Το Keras² είναι ένα υψηλού επιπέδου API της πλατφόρμας Tensorflow. Παρέχει μία προσιτή, εξαιρετικά παραγωγική διεπαφή για την επίλυση προβλημάτων μηχανικής μάθησης, με έμφαση στη βαθιά μάθηση. Το Keras καλύπτει κάθε βήμα της ροής εργασίας της μηχανικής μάθησης, από την επεξεργασία δεδομένων έως τη ρύθμιση υπερπαραμέτρων και την ανάπτυξη. Αναπτύχθηκε με επίκεντρο τη δυνατότητα γρήγορου πειραματισμού, καθώς έχει σχεδιαστεί προσφέροντας απλές, συνεπείς διεπαφές και ελαχιστοποιεί τον αριθμό ενεργειών που απαιτούνται για κοινές περιπτώσεις χρήσης.

6.2 Προετοιμασία Συνόλου Δεδομένων

Για τα καλύτερα δυνατά αποτελέσματα είναι απαραίτητη η σωστή προετοιμασία του συνόλου δεδομένων πριν αυτό εισαχθεί στο αναδρομικό νευρωνικό δίκτυο. Η διαδικασία αυτή αποτελείται από τον ορισμό τριών συναρτήσεων και εν συνεχεία από ένα κομμάτι κώδικα, στο οποίο εφαρμόζονται οι συναρτήσεις αυτές, αλλά και παρόμοια βήματα προεπεξεργασίας με αυτά που περιγράφηκαν στο **Κεφάλαιο 5**. Στην προετοιμασία του συνόλου δεδομένων βοήθησε αρκετά ο κώδικας από το Github repository [36].

¹<https://github.com/tensorflow/tensorflow>

²<https://www.tensorflow.org/guide/keras>

6.2.1 Συναρτήσεις Προετοιμασίας Δεδομένων

Πιο αναλυτικά, η πρώτη συνάρτηση που ορίζεται είναι η `process_targets()`, η οποία υπολογίζει την τιμή της RUL για κάθε δεδομένο δείγμα μίας μονάδας, δηλαδή το πόσους ακόμα κύκλους ζωής της απομένουν. Ο τρόπος υπολογισμού εξαρτάται από το αν οριστεί η τιμή της `early_rul` ή όχι, όπως φαίνεται και στον κώδικα 6.1. Χωρίς τον ορισμό μίας τέτοιας τιμής, οι επιστρεφόμενες `rul` ξεκινούν από το `data_length-1` και μειώνονται κατά ένα σε κάθε δείγμα, έως ότου φτάσουν στο μηδέν. Εάν παρέχεται μια τιμή για το `early_rul`, η συνάρτηση ελέγχει αν η διαφορά `data_length - early_rul` είναι μεγαλύτερη από μηδέν. Αν ναι, τότε το RUL μένει σταθερό στο `early_rul` για το αρχικό αυτό διάστημα και μετά αρχίζει να μειώνεται μέχρι το μηδέν.

```

1 def process_targets(data_length, early_rul = None):
2     if early_rul == None:
3         return np.arange(data_length-1, -1, -1)
4     else:
5         early_rul_duration = data_length - early_rul
6         if early_rul_duration <= 0:
7             return np.arange(data_length-1, -1, -1)
8         else:
9             return np.append(early_rul*np.ones(shape =
10                 (early_rul_duration,)), np.arange(early_rul-1, -1, -1))

```

Κώδικας 6.1: Συνάρτηση `process_targets(data_length, early_rul = None)`

Η επόμενη συνάρτηση είναι η `process_input_data_with_targets(input_data, target_data = None, window_length = 1, shift = 1)` είναι υπεύθυνη για την επεξεργασία των δεδομένων εισόδου, μετατρέποντας τα με τέτοιο τρόπο ώστε να είναι στην κατάλληλη μορφή για την εκπαίδευση του LSTM δικτύου. Από τη στιγμή που το `dataset` περιέχει χρονοσειρές, ακολουθείται μία αρκετά κοινή τακτική, όπου τα δεδομένα χωρίζονται σε μικρότερα επικαλυπτόμενα σύνολα καθορισμένου μήκους. Δέχεται ως παραμέτρους το σύνολο δεδομένων εισόδου, τα δεδομένα στόχου αν αυτά υπάρχουν, το μήκος του παραθύρου και την μετατόπιση μεταξύ των διαδοχικών παραθύρων.

```

1 def process_input_data_with_targets(input_data, target_data = None,
2     window_length = 1, shift = 1):
3
4     num_batches = int(np.floor((len(input_data) - window_length)/shift)) + 1
5     num_features = input_data.shape[1]
6     output_data = np.repeat(np.nan, repeats = num_batches * window_length *
7         num_features).reshape(num_batches, window_length,
8         num_features)
9
10    if target_data is None:
11        for batch in range(num_batches):
12            output_data[batch, :, :] = input_data[(0+shift*batch):(0+shift*batch+
13                window_length), :]
14        return output_data

```

```

13     else:
14         output_targets = np.repeat(np.nan, repeats = num_batches)
15         for batch in range(num_batches):
16             output_data[batch, :, :] = input_data[(0+shift*batch):(0+shift*batch+
window_length), :]
17             output_targets[batch] = target_data[(shift*batch + (window_length-1
))]
18         return output_data, output_targets

```

Κώδικας 6.2: Συνάρτηση process_input_data_with_targets()

Τα δεδομένα στόχου καθορίζουν τη ροή εκτέλεσης της συνάρτησης, όπως φαίνεται και στον κώδικα 6.2. Βάσει του συνολικού μήκους των δεδομένων, του μήκους του παραθύρου και της μετατόπισης, υπολογίζεται ο αριθμός των batches που μπορούν να προκύψουν. Για κάθε batch που έχει διαστάσεις window_length x num_features, δημιουργείται ένα παράθυρο δεδομένων, το οποίο αποθηκεύεται σε έναν πίνακα output_data. Ένας δεύτερος πίνακας, ο output_targets δημιουργείται για να αποθηκεύσει τις αντίστοιχες RUL τιμές για κάθε window. Κάθε τιμή αντιστοιχεί στον τελευταίο κύκλο ζωής κάθε παραθύρου. Ως έξοδος, επιστρέφονται οι παραπάνω πίνακες output_data και output_targets.

Τρίτη και τελευταία συνάρτηση είναι η process_test_data(test_data_for_an_engine, window_length, shift, num_test_windows = 1), μία συνάρτηση σχεδιασμένη να τροποποιεί τα σύνολα δοκιμής και να τους δίνει μία μορφή ιδανική, για να περάσουν σε ένα εκπαιδευμένο μοντέλο, εξασφαλίζοντας πως τα δεδομένα test είναι προεπεξεργασμένα με τον ίδιο τρόπο όπως τα δεδομένα εκπαίδευσης. Όσον αφορά τις παραμέτρους τις, αυτές είναι τα δεδομένα δοκιμής των κινητήρων, το μέγεθος του παραθύρου, η μετατόπιση μεταξύ των διαδοχικών παραθύρων και ο αριθμός των παραθύρων δοκιμής που σκοπεύουμε να δημιουργήσουμε.

```

1 def process_test_data(test_data_for_an_engine, window_length, shift,
    num_test_windows = 1):
2
3     max_num_test_batches = int(np.floor((len(test_data_for_an_engine) -
window_length)/shift)) + 1
4
5     if max_num_test_batches < num_test_windows:
6         required_len = (max_num_test_batches - 1) * shift + window_length
7         batched_test_data_for_an_engine = process_input_data_with_targets(
test_data_for_an_engine[-required_len:, :],
8
9         target_data = None,
10
11         window_length = window_length,
12
13         = shift)
14         return batched_test_data_for_an_engine, max_num_test_batches
15
16     else:
17         required_len = (num_test_windows - 1) * shift + window_length
18         batched_test_data_for_an_engine = process_input_data_with_targets(
test_data_for_an_engine[-required_len:, :],

```

```

16     target_data = None,
17     window_length = window_length,
18     shift = shift)
19     return batched_test_data_for_an_engine, num_test_windows

```

Κώδικας 6.3: Συνάρτηση `process_test_data(test_data_for_an_engine, window_length, shift, num_test_windows = 1)`

Η λειτουργία της συνάρτησης είναι όμοια με αυτήν της `process_input_data_with_targets`. Υπολογίζεται ο μέγιστος αριθμός από `batches` λαμβάνοντας υπόψη το συνολικό μήκος των δεδομένων, του μήκους του παραθύρου και της μετατόπισης και στη συνέχεια συγκρίνεται ο αριθμός αυτός με τον επιθυμητό αριθμό παραθύρων (κώδικας 6.3). Αν ο μέγιστος αριθμός των `batches` είναι μεγαλύτερος, τότε δημιουργούνται τόσα παράθυρα όσα είναι δυνατόν να προκύψουν από το μέγεθος των δεδομένων. Σε αντίθετη περίπτωση δημιουργείται πλήθος παραθύρων ίσο με τον αριθμό ίσο που έχει τεθεί. Επιστρέφει, λοιπόν, τα παράθυρα δεδομένων που προέκυψαν και το πλήθος τους.

6.2.2 Προεπεξεργασία Συνόλου Δεδομένων

Αφού, ορίστηκαν οι συναρτήσεις προετοιμασίας του συνόλου, ξεκινά η προεπεξεργασία των δεδομένων εκπαίδευσης και δοκιμής. Η διαδικασία περιλαμβάνει τη φόρτωση των τριών αρχείων, που περιέχουν τα δεδομένα, τα διάβασμά τους και την μετατροπή τους σε `dataframes`. Το μήκος του παραθύρου ορίζεται ίσο με 30, η μετατόπιση παίρνει την τιμή 1, το άνω όριο για τις RUL τιμές τίθεται ίσο με 125 και ο αριθμός των παραθύρων δοκιμής 5. Ακολουθεί η απομάκρυνση των χαρακτηριστικών εκείνων που δεν προσφέρουν ουσιώδη πληροφορία και η κανονικοποίηση των δεδομένων με τη χρήση του `Standard Scaler`.

```

1 test_data = pd.read_csv("/Turbofan_Jet_Engine/CMaps/test_FD001.txt", sep = "\s+",
2     ", header = None)
3 true_rul = pd.read_csv("/Turbofan_Jet_Engine/CMaps/RUL_FD001.txt", sep = '\s+',
4     ", header = None)
5 train_data = pd.read_csv("/Turbofan_Jet_Engine/CMaps/train_FD001.txt", sep= "\s+",
6     ", header = None)
7
8 window_length = 30
9 shift = 1
10 early_rul = 125
11 processed_train_data = []
12 processed_train_targets = []
13
14 num_test_windows = 5
15 processed_test_data = []
16 num_test_windows_list = []
17
18 columns_to_be_dropped = [0,1,2,3,4,5,9,10,14,20,22,23]

```

```

16
17 train_data_first_column = train_data[0]
18 test_data_first_column = test_data[0]
19
20 scaler = StandardScaler()
21 train_data = scaler.fit_transform(train_data.drop(columns =
    columns_to_be_dropped))
22 test_data = scaler.transform(test_data.drop(columns = columns_to_be_dropped))
23
24 train_data = pd.DataFrame(data = np.c_[train_data_first_column, train_data])
25 test_data = pd.DataFrame(data = np.c_[test_data_first_column, test_data])

```

Κώδικας 6.4: Διαδικασία Προεπεξεργασίας Συνόλων

Στη συνέχεια, ξεκινά η εφαρμογή των παραπάνω συναρτήσεων και η επεξεργασία των δεδομένων εκπαίδευσης. Για κάθε μονάδα στα δεδομένα εκπαίδευσης, τα δεδομένα διαχωρίζονται με βάση τον αριθμό της και πραγματοποιείται έλεγχος για το αν υπάρχουν αρκετά δεδομένα για να δημιουργηθεί ένα παράθυρο δεδομένων του συγκεκριμένου μήκους. Εφόσον ο έλεγχος είναι επιτυχημένος, γίνεται χρήση των συναρτήσεων `process_targets()` και `process_input_data_with_targets()`, με τα αποτελέσματα να αποθηκεύονται σε δύο λίστες και να συνενώνονται σε έναν πίνακα. Ο ίδιος διαχωρισμός και ο ίδιος έλεγχος πραγματοποιούνται και στα δεδομένα δοκιμής. Μετά τον έλεγχο τα δεδομένα επεξεργάζονται χρησιμοποιώντας τη συνάρτηση `process_test_data`, και τα αποτελέσματα αποθηκεύονται στην αντίστοιχη λίστα, όπως φαίνεται στον κώδικα 6.6.

Έχοντας ολοκληρώσει κάθε βήμα προεπεξεργασίας, τα δεδομένα μαζί με τις μεταβλητές στόχου, ανακατεύονται τυχαία, με σκοπό την αποδοτικότερη εκπαίδευση. Τελός, διαχωρίζουμε το σύνολο εκπαίδευσης μέσω της `train_test_split` και εκτυπώνοντας το σχήμα των συνόλων που προέκυψαν έχουμε τα εξής:

```

Processed train data shape: (14184, 30, 14)
Processed validation data shape: (3547, 30, 14)
Processed train targets shape: (14184,)
Processed validation targets shape: (3547,)
Processed test data shape: (497, 30, 14)

```

```

1 # Process training data
2 for i in np.arange(1, num_train_machines + 1):
3     temp_train_data = train_data[train_data[0] == i].drop(columns = [0]).values
4
5     if (len(temp_train_data) < window_length):
6         print("Train engine {} doesn't have enough data for window_length of {}".format(i, window_length))
7         raise AssertionError("Window length is larger than number of data points for some engines. "
8                                "Try decreasing window length.")
9
10    temp_train_targets = process_targets(data_length = temp_train_data.shape[0],

```

```

11         early_rul = early_rul)
12     data_for_a_machine, targets_for_a_machine = process_input_data_with_targets
13     (temp_train_data,
14
15     temp_train_targets,
16
17     window_length = window_length,
18
19     shift = shift)
20
21     processed_train_data.append(data_for_a_machine)
22     processed_train_targets.append(targets_for_a_machine)
23
24 processed_train_data = np.concatenate(processed_train_data)
25 processed_train_targets = np.concatenate(processed_train_targets)

```

Κώδικας 6.5: Διαδικασία Προεπεξεργασίας Συνόλου Εκπαίδευσης

```

1 # Process test data
2 for i in np.arange(1, num_test_machines + 1):
3     temp_test_data = test_data[test_data[0] == i].drop(columns = [0]).values
4
5     if (len(temp_test_data) < window_length):
6         print("Test engine {} doesn't have enough data for window_length of {}".
7             .format(i, window_length))
8         raise AssertionError("Window length is larger than number of data
9             points for some engines. "
10                 "Try decreasing window length.")
11
12     test_data_for_an_engine, num_windows = process_test_data(temp_test_data,
13         window_length = window_length,
14
15         shift = shift,
16         num_test_windows =
17         num_test_windows)
18
19     processed_test_data.append(test_data_for_an_engine)
20     num_test_windows_list.append(num_windows)
21
22 processed_test_data = np.concatenate(processed_test_data)
23 true_rul = true_rul[0].values
24
25 # Shuffle training data
26 index = np.random.permutation(len(processed_train_targets))
27 processed_train_data, processed_train_targets = processed_train_data[index],
28     processed_train_targets[index]

```

Κώδικας 6.6: Διαδικασία Προεπεξεργασίας Συνόλου Δοκιμής

6.3 Αρχιτεκτονική Αναδρομικού Νευρωνικού Δικτύου

Η αρχιτεκτονική του νευρωνικού δικτύου, το οποίο υλοποιείται στα πλαίσια του συστήματος υπολογισμού εναπομείνουσας χρήσιμης ζωής βασίζεται σε μία σειρά από LSTM επίπεδα, τα οποία είναι ιδανικά για την επεξεργασία χρονοσειρών. Αξιοποιείται η δομή sequential, μέσω της οποίας δημιουργείται μία στοίβα από επίπεδα, όπου το ένα ακολουθεί το άλλο σε μία αλληλουχία.

Το μοντέλο ξεκινά με το 1ο LSTM επίπεδο, το οποίο αποτελείται από 128 μονάδες και με την ανάθεση **input_shape=(window_length, 14)** καθορίζει ότι το σχήμα των εισερχόμενων δεδομένων θα έχει μήκος ίσο με αυτό του παραθύρου και 14 χαρακτηριστικά. Στην έξοδό του επιστρέφει ολόκληρη την ακολουθία εξόδου για κάθε δείγμα, επιτρέποντας στο επόμενο επίπεδο να την επεξεργαστεί, ενώ η συνάρτηση ενεργοποίησης tanh προσφέρει τη δυνατότητα ταχύτερης σύγκλισης στο μοντέλο. Το 2ο επίπεδο LSTM έχει 96 μονάδες, την tanh ως συνάρτηση ενεργοποίησης και επιστρέφει επίσης την πλήρη ακολουθία για το επόμενο επίπεδο. Το 3ο LSTM που είναι και το τελευταίο, έχει 64 μονάδες, αλλά σε αντίθεση με τα προηγούμενα επιστρέφει μόνο την τελευταία έξοδο κάθε δείγματος, η οποία τροφοδοτείται στα dense επίπεδα.

```


1 def create_compiled_model():
2     model = Sequential([
3         layers.LSTM(128, input_shape=(window_length, 14),
4             return_sequences=True, activation="tanh"),
5         layers.Dropout(0.2),
6         layers.LSTM(96, activation="tanh", return_sequences=True),
7         layers.Dropout(0.2),
8         layers.LSTM(64, activation="tanh"),
9         layers.Dropout(0.2),
10        layers.Dense(32, activation="relu"),
11        layers.Dropout(0.2),
12        layers.Dense(64, activation="relu"),
13        layers.Dense(1)
14    ])
15    model.compile(loss="mse",
16        optimizer=tf.keras.optimizers.Adam(learning_rate=0.001))
17    return model

```

Κώδικας 6.7: Υλοποίηση Μοντέλου LSTM

Μετά από κάθε LSTM και Dense υπάρχουν τα Dropout layers προκειμένου να αποφευχθεί η υπερπροσαρμογή. Σε κάθε Dropout επίπεδο το 20% των νευρώνων απομακρύνονται τυχαία. Ακολουθούν τρία Dense επίπεδα, εκ των οποίων τα δύο πρώτα έχουν 32 και 64 μονάδες αντίστοιχα. Ως συνάρτηση ενεργοποίησης έχει επιλεγθεί η ReLU, η οποία επιστρέφει τις μη αρνητικές τιμές αναλλοίωτες και τις αρνητικές τις κάνει μηδέν. Το τελικό Dense επίπεδο αποτελείται από έναν νευρώνα και βγάζει στην έξοδο την τελική τιμή πρόβλεψης.

Όπως βλέπουμε στον κώδικα 6.7 μετά τον ορισμό των επιπέδων του μοντέλου, υπάρχει ένα κρίσιμο βήμα για την προετοιμασία του. Στο βήμα αυτό περιλαμβάνεται η επιλογή της συνάρτησης απώλειας και του αλγορίθμου βελτιστοποίησης που θα χρησιμοποιηθούν για



Σχήμα 6.2: Επίπεδα του Νευρωνικού Δικτύου LSTM

την προσαρμογή των βαρών του μοντέλου κατά τη διαδικασία εκπαίδευσης. Ως συνάρτηση απώλειας επιλέγεται το Μέσο Τετραγωνικό Σφάλμα, καθώς “τιμωρεί” περισσότερο τις μεγάλες αποκλίσεις μεταξύ των προβλέψεων και των πραγματικών τιμών. Ο αλγόριθμος βελτιστοποίησης που χρησιμοποιείται είναι ο Adaptive Moment Estimation, ο οποίος προσαρμόζει το ρυθμό παραμόρφωσης για κάθε παράμετρο ξεχωριστά. Σχετικά με τον ρυθμό μάθησης, ορίζεται αρχικά ίσος με 0.001, ωστόσο έπειτα από πέντε epochs αλλάζει σε 0.0001.

6.3.1 Εκπαίδευση LSTM Μοντέλου

Για την αποδοτικότερη εκπαίδευση του μοντέλου, δημιουργήθηκε η συνάρτηση `train_model_with_metrics`, η οποία υλοποιεί έναν βασικό βρόχο εκπαίδευσης (Κώδικας 6.8) για ένα νευρωνικό δίκτυο και ταυτόχρονα καταγράφει ορισμένες μετρικές απόδοσης, όπως η απώλεια, το μέσο απόλυτο σφάλμα και το μέσο τετραγωνικό σφάλμα. Ο βρόχος εκτελείται σε κάθε εποχή εκπαίδευσης και σε κάθε επανάληψη τα βάρη του δικτύου ενημερώνονται μέσω της `GradientTape`, η οποία υπολογίζει το σφάλμα και τους παραγώγους των βαρών. Εντός του βρόχου εκπαίδευσης υπάρχει και ο βρόχος επικύρωσης, όπου παρόμοια με τον βρόχο εκπαίδευσης οι μετρικές απόδοσης ενημερώνονται συνεχώς. Για την αποθήκευση των αποτελεσμάτων υπάρχει το λεξικό `history`, ενώ οι μετρικές των συνόλων εκπαίδευσης και επικύρωσης εκτυπώνονται σε κάθε επανάληψη. Συνοπτικά, η διαδικασία αυτή βοηθάει στην αξιολόγηση της απόδοσης του μοντέλου και στη σύγκριση της απόδοσης σε κάθε εποχή.

```

1 def train_model_with_metrics(net, train_data_iter, validation_data_iter, lr,
2   num_epochs, scheduler_callback=None):
3     optimizer = tf.keras.optimizers.Adam(learning_rate=lr)
4     loss_object = tf.keras.losses.MeanSquaredError()
5
6     history = {'train_loss': [], 'val_loss': [], 'train_mse': [],
7               'val_mse': [], 'train_rmse': [], 'val_rmse': [],
8               'train_mae': [], 'val_mae': [], 'train_r2': [], 'val_r2': []}
9
10    for epoch in range(num_epochs):
11        if scheduler_callback is not None:
12            lr = scheduler_callback(epoch)
13            optimizer.lr.assign(lr)
14
15        train_true = []
16        train_preds = []
17        val_true = []

```



```
9 validation_data_iter = tf.data.Dataset.from_tensor_slices((processed_val_data,  
10     processed_val_targets)).batch(batch_size)  
11  
12 callback = tf.keras.callbacks.LearningRateScheduler(scheduler, verbose=1)  
13  
14 history = train_model_with_metrics(model, train_data_iter, validation_data_iter  
    , initial_lr, num_epochs, scheduler_callback=scheduler)
```

Κώδικας 6.9: Εκπαίδευση και Αξιολόγηση Μοντέλου LSTM

Κεφάλαιο 7

Πειραματική Αξιολόγηση

7.1 Μετρικές Αξιολόγησης στο πρόβλημα Ταξινόμησης

Οι μετρικές αξιολόγησης όσον αφορά τα προβλήματα ταξινόμησης μας προσφέρουν μία ποσοτική εκτίμηση για την απόδοση του μοντέλου. Κάθε μετρική αξιολόγησης έχει τα δικά της πλεονεκτήματα και ιδιαιτερότητες, με την επιλογή της κατάλληλης να εξαρτάται από το εκάστοτε πρόβλημα και την κρισιμότητά του.

- **Ακρίβεια Ταξινόμησης (Accuracy):** Η ακρίβεια ταξινόμησης είναι η πιο διαδεδομένη μετρική αξιολόγησης και υπολογίζεται ως ο λόγος των σωστών προβλέψεων προς τις συνολικές προβλέψεις που πραγματοποιήθηκαν, δηλαδή πόσο συχνά το μοντέλο ταξινομεί σωστά τα δείγματα.

$$\text{Accuracy} = \frac{\text{No. of correct predictions}}{\text{Total number of input samples}} \quad (7.1)$$

Γενικά, λειτουργεί ιδανικά, όταν το σύνολο δεδομένων πάνω στο οποίο ελέγχεται το μοντέλο αποτελείται από ίσο αριθμό δειγμάτων για κάθε κλάση και δεν χαρακτηρίζεται από άνιση κατανομή των δειγμάτων των κλάσεων.

- **Μητρώο Σύγχυσης (Confusion Matrix):** Το Μητρώο Σύγχυσης δημιουργεί ένα $N \times N$ μητρώο, όπου N είναι ο αριθμός των κλάσεων ή των κατηγοριών που καλούμαστε να προβλέψουμε. Στην ουσία αποτελεί έναν πίνακα, ο οποίος αποτελείται από συνδυασμούς πραγματικών και προβλεπόμενων τιμών.

- True Positive: Έγινε πρόβλεψη Positive και ήταν αληθής.
- True Negative: Έγινε πρόβλεψη Negative και ήταν αληθής.
- False Positive (Λάθος Τύπου 1): Έγινε πρόβλεψη Positive και ήταν ψευδής.
- False Negative (Λάθος Τύπου 2): Έγινε πρόβλεψη Negative και ήταν ψευδής.

Το μητρώο σύγχυσης είναι ιδιαίτερα χρήσιμο στον υπολογισμό της Ανάκλησης, της Ακρίβειας και των AUC-ROC Curves.

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Σχήμα 7.1: Μητρώο Σύγχησης

- **Ορθότητα (Precision):** Η μετρική με το όνομα Precision εκφράζει το πόσες από τις Positive προβλέψεις που έγιναν από το μοντέλο, είναι όντως σωστές. Υπολογίζεται από τον αριθμό των True Positive προβλέψεων διαιρεμένων με το άθροισμα των True Positive και False Positive προβλέψεων.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (7.2)$$

- **Ανάκληση (Recall):** Η μετρική με το όνομα Recall επεξηγεί το πόσες από τις πραγματικές Positive περιπτώσεις προβλέφθηκαν σωστά από το μοντέλο μας. Υπολογίζεται από τον αριθμό των True Positive προβλέψεων διαιρεμένων με το άθροισμα των True Positive και False Negative προβλέψεων. Αποτελεί μία μετρική, η οποία είναι ιδιαίτερος χρήσιμη όταν οι περιπτώσεις False Negative είναι κρισιμότερες από τις περιπτώσεις False Positive .

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (7.3)$$


- **F1-Score:** Το F1-Score αποτελεί τον αρμονικό μέσο γύρω από την ιδέα της Ακρίβειας και της Ανάκλησης, ενώ γίνεται μέγιστο (ίσο με 1) όταν αυτές οι δύο μετρικές είναι ίσες. Στην ουσία μας πληροφορεί για το πόσο ακριβής (πόσες περιπτώσεις ταξινομούνται σωστά) και πόσο εύρωστος (δεν χάνει σημαντικό αριθμό παραδειγμάτων) είναι ο ταξινομητής μας. Η F1 είναι αρκετά καλή μετρική σε περιπτώσεις όπου οι False Negative και False Positive κοστίζουν το ίδιο, η προσθήκη επιπλέον δεδομένων δεν αλλάζει το αποτέλεσμα και υπάρχουν πολλές True Negative περιπτώσεις.

$$F1 = 2 \cdot \frac{1}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}} \quad (7.4)$$

- **AUC-ROC curve:** Ως Receiver Operator Characteristic (ROC) ορίζεται μία καμπύλη πιθανότητας, η οποία σχεδιάζει το True Positive Rate έναντι του False Positive Rate

σε διάφορες τιμές κατωφλίου και διαχωρίζει το σήμα από τον θόρυβο. Η Area Under the Curve δηλώνει την περιοχή κάτω από αυτήν την καμπύλη και έχει τιμές στο εύρος $[0,1]$ και εκφράζει την ικανότητα ενός ταξινομητή να διακρίνει μεταξύ κλάσεων.

- True Positive Rate (TPR)=True Positives/(True Positives + False Negatives)
- False Positive Rate (FPR) = False Positives / (False Positives + True Negatives)



Σχήμα 7.2: ROC Curves

Ένας τέλειος ταξινομητής παρουσιάζεται ως μία ROC Curve, η οποία περνάει από την πάνω αριστερή γωνία όπου $TPR=1$ και $FPR=0$, ενώ ένας τυχαίος ταξινομητής έχει μία καμπύλη, η οποία βρίσκεται πιο κοντά ή περνά διαμέσου της διαγωνίου ($TPR=FPR$).

7.2 Μετρικές Αξιολόγησης στο πρόβλημα Παλινδρόμησης

Οι μετρικές αξιολόγησης όσον αφορά τα προβλήματα παλινδρόμησης είναι απαραίτητες, καθώς μας βοηθούν να χτίσουμε και να αναπτύξουμε ένα μοντέλο υψηλής ακρίβειας. Υπάρχουν πολλές μετρικές όσον αφορά την διαδικασία παλινδρόμησης με καθεμία να ταιριάζει σε διαφορετικά σύνολα από δεδομένα.

- **Μέσο Απόλυτο Σφάλμα:** Πρόκειται για μία αρκετά απλή μετρική, η οποία υπολογίζει την απόλυτη διαφορά μεταξύ των πραγματικών και των προβλεπόμενων τιμών. Ο τύπος σύμφωνα με τον οποίο γίνεται ο υπολογισμός είναι:

$$MAE = \frac{1}{n} \sum_{i=1}^n |x_i - y_i| \quad (7.5)$$

Όπου X_i είναι οι πραγματικές τιμές για το i -οστό δείγμα και Y_i είναι οι προβλεπόμενες τιμές για το i -οστό δείγμα.

- **Μέσο Τετραγωνικό Σφάλμα:** Άλλη μία ιδιαίτερα διαδεδομένη μετρική, είναι το Μέσο Τετραγωνικό Σφάλμα. Αυτό μετρά το τετράγωνο των μέσων αποκλίσεων μεταξύ των

πραγματικών τιμών ενός συνόλου δεδομένων και των προβλεπόμενων τιμών. Εκφράζει το πόσο καλά λειτουργεί το μοντέλο πρόβλεψης και ο τύπος σύμφωνα με τον οποίο γίνεται ο υπολογισμός είναι:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2 \quad (7.6)$$

Όπου X_i είναι οι πραγματικές τιμές για το i -οστό δείγμα και Y_i είναι οι προβλεπόμενες τιμές για το i -οστό δείγμα.

- **Ρίζα Μέσου Τετραγωνικού Σφάλματος:** Είναι μία μετρική που συχνά χρησιμοποιείται στην ανάλυση παλινδρόμησης και μετρά την ακρίβεια και το πόσο καλά έχει προσαρμοστεί το μοντέλο πρόβλεψης, ειδικά όταν τα δεδομένα είναι συνεχείς αριθμοί. Αναλυτικά, για κάθε δείγμα υπολογίζει τη διαφορά της πραγματικής από την προβλεπόμενη τιμή, υψώνει το αποτέλεσμα στο τετράγωνο και αθροίζει όλα αυτά τα τετράγωνα μαζί. Στη συνέχεια διαιρεί το τετράγωνο με το πλήθος των δειγμάτων και έχει τον μέσο όρο. Τέλος, υπολογίζει την ρίζα του μέσου όρου.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2} \quad (7.7)$$

Όπου X_i είναι οι πραγματικές τιμές για το i -οστό δείγμα και Y_i είναι οι προβλεπόμενες τιμές για το i -οστό δείγμα.

- **Συντελεστής Προσδιορισμού R-Squared:** Είναι μία στατιστική μετρική που στοχεύει να εκφράσει το πόσο καλά έχει προσαρμοστεί το μοντέλο στα δεδομένα. Ποσοτικοποιεί το ποσοστό διακύμανσης της εξαρτημένης μεταβλητής, στο οποίο συμβάλλουν οι ανεξάρτητες μεταβλητές του μοντέλου.

$$R^2 = 1 - \frac{SSR}{SST} \quad (7.8)$$

Το R-Squared Score είναι ένα χρήσιμο στατιστικό στοιχείο για την αξιολόγηση της συνολικής αποτελεσματικότητας και της επεξηγηματικής ισχύος ενός μοντέλου παλινδρόμησης.

Όπου SSR αντιπροσωπεύει το άθροισμα των υπολειμμάτων στο τετράγωνο μεταξύ των προβλεπόμενων τιμών και των πραγματικών τιμών και SST είναι το συνολικό άθροισμα των τετραγώνων, το οποίο μετρά τη συνολική διακύμανση στην εξαρτημένη μεταβλητή.

7.3 Μετρικές Αξιολόγησης στο πρόβλημα Ομαδοποίησης

- **Silhouette:** Η Silhouette αναφέρεται σε μία μέθοδο ερμηνείας και επικύρωσης της συνέπειας εντός των συστάδων δεδομένων. Η τιμή της αποτελεί ένα μέτρο του πόσο

παρόμοιο είναι ένα αντικείμενο με τη δική του συστάδα σε σύγκριση με τις υπόλοιπες. Κυμαίνεται από το -1 έως το 1, με τις υψηλότερες τιμές να δείχνουν ότι το αντικείμενο ταιριάζει καλά με τη δική του συστάδα και ελάχιστα με τις γειτονικές συστάδες. Μια ομαδοποίηση με μέσο πλάτος σιλουέτας πάνω από 0,7 θεωρείται “ισχυρή”, μια τιμή πάνω από 0,5 “λογική” και πάνω από 0,25 “άσθενή”, αλλά με την αύξηση της διαστατικότητας των δεδομένων, καθίσταται δύσκολο να επιτευχθούν τόσο υψηλές τιμές λόγω της “κατάρας” της διαστατικότητας, καθώς οι αποστάσεις γίνονται πιο παρόμοιες. Η βαθμολογία σιλουέτας είναι εξειδικευμένη για τη μέτρηση της ποιότητας των συστάδων όταν οι συστάδες έχουν κυρτό σχήμα και ενδέχεται να μην αποδίδει καλά εάν οι συστάδες δεδομένων έχουν ακανόνιστα σχήματα ή ποικίλα μεγέθη.

$$s(i) = \begin{cases} 1 - \frac{a(i)}{b(i)}, & \text{if } a(i) < b(i) \\ 0, & \text{if } a(i) = b(i) \\ \frac{b(i)}{a(i)} - 1, & \text{if } a(i) > b(i) \end{cases} \quad (7.9)$$

Όπου $a(i)$ είναι η μέση απόσταση μεταξύ του i και των άλλων σημείων δεδομένων της ίδιας συστάδας, ενώ το $b(i)$ αποτελεί την μικρότερη μέση απόσταση του i από όλα τα σημεία οποιασδήποτε άλλης συστάδας. Η συστάδα με αυτή τη μικρότερη μέση ανομοιογένεια λέγεται ότι είναι η «γειτονική συστάδα» του i . Στον παραπάνω τύπο φαίνεται ο υπολογισμός της Silhouette για ένα σημείο δεδομένων, ενώ η Silhouette του μοντέλου υπολογίζεται ως ο μέσος όρος όλων των σημείων.

7.4 Χρόνος Εκπαίδευσης, Ταξινόμησης και Πρόβλεψης

Ως επιπλέον μετρική για την αξιολόγηση των μοντέλων μηχανικής μάθησης, επιλέχθηκαν οι χρόνοι εκπαίδευσης και ταξινόμησης για το πρόβλημα της κατηγοριοποίησης και οι χρόνοι εκπαίδευσης και πρόβλεψης για τα μοντέλα υπολογισμού της εναπομείνουσας χρήσιμης ζωής. Για την μετρική αυτή αξιοποιήθηκε η συνάρτηση `time()` της Python. Μετρήσεις έγιναν και στις περιπτώσεις, στις οποίες πραγματοποιήθηκε αναζήτηση σε πλέγμα για τον εντοπισμό των καλύτερων υπερπαραμέτρων.

7.5 Περιβάλλον Εκτέλεσης

Η εκπαίδευση και η αξιολόγηση των μοντέλων μηχανικής μάθησης έγινε τοπικά σε σύστημα με τα παρακάτω χαρακτηριστικά:

- Λειτουργικό σύστημα: Ubuntu 22.04.3 LTS
- Επεξεργαστής: AMD Ryzen 5 5600H with Radeon Graphics
- Κάρτα Γραφικών: GPU NVIDIA GeForce GTX 1650
- Python 3.10.12, TensorFlow 2.14.1


7.6 Αποτελέσματα Ανίχνευσης Ανωμαλιών

7.6.1 Αποτελέσματα Ταξινόμησης

Παρακάτω παρουσιάζονται τα αποτελέσματα, τα οποία προέκυψαν για τις επιλεγμένες μετρικές αξιολόγησης, όσον αφορά τα μοντέλα ταξινόμησης του Συστήματος Ανίχνευσης Ανωμαλιών. Ειδικότερα, στα σχήματα 7.3, 7.4, 7.5, 7.6, 7.7, 7.8, 7.9 και 7.10 απεικονίζονται τα διαγράμματα της ακρίβειας, της ορθότητας, της ανάκλησης, του αρμονικού μέσου όρου μεταξύ ορθότητας και ανάκλησης, τα μητρώα σύγχυσης, καθώς και οι χαρακτηριστικές καμπύλες δέκτη αντίστοιχα για τα εκπαιδευμένα μοντέλα μηχανικής μάθησης που παρουσιάστηκαν στο **Κεφάλαιο 4**, ως προς το σύνολο δεδομένων ελέγχου. Πέραν της ακρίβειας, η οποία παρουσιάζεται συνολικά για κάθε μοντέλο, οι υπόλοιπες μετρικές απόδοσης αναλύονται περαιτέρω για κάθε πιθανή κλάση της μεταβλητής στόχου. Αυτό συμβαίνει διότι το σύνολο ελέγχου έχει πολύ μεγάλο ποσοστό δειγμάτων της κλάσης "No Failure", τα οποία αναγνωρίζονται καλά από τους ταξινομητές, ενώ αντιθέτως ο αριθμός των δειγμάτων που αφορούν τις κλάσεις σφαλμάτων είναι πολύ μικρός. Αυτό σημαίνει πως η εκτίμηση της απόδοσης ενός μοντέλου συνολικά δεν είναι αξιόπιστη και γι'αυτό απαιτείται αναλυτικός έλεγχος σε κάθε κλάση.

Ακρίβεια (Accuracy)


Παρατηρώντας το σχήμα 7.3 καθίσταται σαφές πως τα μοντέλα Random Forest και Support Vector Machines είναι ιδιαίτερος αποτελεσματικά και έχουν υψηλή ακρίβεια, με τιμές 0.97 και 0.96 αντίστοιχα. Αρκετά υψηλή είναι και η ακρίβεια του αλγορίθμου K Πλησιέστερων Γειτόνων που είναι ίση με 0.92, ενώ πιο χαμηλά ακολουθούν η Λογιστική Παλινδρόμηση με τιμή 0.84 και ο Αφελής Μπεϋζιανός Ταξινομητής με τιμή 0.79.



Σχήμα 7.3: Αποτελέσματα Ακρίβειας Μοντέλων

Ορθότητα (Precision)

Το διάγραμμα του σχήματος 7.4 μας δείχνει τις τιμές της ορθότητας για τα πέντε μοντέλα, ανά κλάση της μεταβλητής στόχου. Παρατηρείται πως τα περισσότερα μοντέλα αποδίδουν εξαιρετικά υψηλή ορθότητα στην κλάση "No Failure", αναγνωρίζοντας σωστά τις περιπτώσεις υγιούς εξοπλισμού στις οποίες δεν χρειάζεται παρέμβαση συντήρησης. Η αποτυχία που ανιχνεύεται καλύτερα από όλες είναι η Υπερφόρτωση (Overstrain Failure) με τον αλγόριθμο Random Forest να υπερέχει με ορθότητα 0.82 και τον SVM να παρουσιάζει αξιοπρεπή επίδοση με 0.69. Τα υπόλοιπα τρία μοντέλα δεν επιφέρουν ενθαρρυντικά αποτελέσματα, αφού ο KNN έχει τιμή 0.36 και οι Naive Bayes, Logistic Regression παρουσιάζουν αδυναμία ταξινόμησης με τιμή ορθότητας ίση με 0.2. Όσον αφορά τις κλάσεις "Heat Dissipation Failure" και "Power Failure", οι αλγόριθμοι Random Forest και SVM συνεχίζουν να αποδίδουν σε αξιοπίστο βαθμό σε αντίθεση με τους υπόλοιπους, ενώ στην περίπτωση αποτυχίας "Tool Wear" όλα τα μοντέλα αποτυγχάνουν πλήρως.




Σχήμα 7.4: Αποτελέσματα Ορθότητας Μοντέλων

Ανάκληση (Recall)

Βάσει του διαγράμματος του σχήματος 7.5 συμπεραίνεται πως τα μοντέλα ανακαλούν αρκετά καλά τα δείγματα ως προς καθεμία από τις κλάσεις. Το μοντέλο Λογιστικής Παλινδρόμησης παρουσιάζει μεγάλη σταθερότητα σε όλες τις κλάσεις: 0.96, 0.84, 0.89, 0.89, 0.84, όπως και ο Naive Bayes σε μικρότερο, ωστόσο, βαθμό: 0.86, 0.79, 0.92, 0.67, 0.63. Όσον αφορά τον Random Forest ανακαλεί τα σωστά δείγματα εξαιρετικά για την κλάση της Μη Αποτυχίας με τιμή 0.98, αρκετά καλά για τις κλάσεις "Heat Dissipation Failure", "Overstrain Failure" και "Power Failure" με τιμές 0.65, 0.73 και 0.80, ενώ δεν ανακαλεί ικανοποιητικά τα δείγματα της κλάσης "Tool Wear Failure". Στο ίδιο μήκος κύματος κινείται και ο KNN, ο οποίος για τις τέσσερις πρώτες κλάσεις ανακαλεί τα σωστά δείγματα εξαιρετικά καλά, έχοντας τιμές 0.84, 0.93, 0.78 και 0.76, ενώ βρίσκεται πολύ χαμηλά, στο 0.37, στην

ανάκληση των περιπτώσεων "Tool Wear Failure". Τέλος, το μοντέλο SVM σε αντίθεση με το διάγραμμα της ορθότητας, εδώ δεν παρουσιάζει ικανοποιητικά αποτελέσματα με εξαίρεση τα δείγματα της "No Failure".



Σχήμα 7.5: Αποτελέσματα Ανάκλησης Μοντέλων


Αρμονικός Μέσος Όρος Ανάκλησης-Ακρίβειας (F1-Score)

Στο σχήμα 7.6 απεικονίζεται το διάγραμμα του Αρμονικού Μέσου μεταξύ Ορθότητας και Ανάκλησης, το οποίο μας παρέχει μία ισορροπημένη εικόνα της απόδοσης κάθε μοντέλου. Παρατηρείται πως όλα τα μοντέλα παρουσιάζουν ιδιαίτερα υψηλές επιδόσεις στην κλάση "No Failure", έχοντας κατά σειρά τις εξής τιμές: Random Forest 0.99, Support Vector Machine 0.98, KNN 0.96, Logistic Regression 0.91 και Naive Bayes 0.88. Όσον αφορά τις κλάσεις "Heat Dissipation Failure", "Overstrain Failure" και "Power Failure" τον υψηλότερο αρμονικό μέσο τον έχει ο Random Forest με τιμές 0.65, 0.77, 0.71, αντίστοιχα. Χαμηλότερες επιδόσεις, ωστόσο μερικώς ικανοποιητικές επιτυγχάνουν στις κλάσεις αυτές οι αλγόριθμοι SVM και KNN.

Οι τιμές τους κυμαίνονται μεταξύ 0.51 και 0.67, με εξαίρεση τον αρμονικό μέσο του KNN της κλάσης "Heat Dissipation Failure" που δεν ξεπερνά το 0.43. Ακολουθεί το μοντέλο Λογιστικής Παλινδρόμησης με τιμές αρμονικού μέσου μεταξύ 0.32 και 0.48, ενώ την χειρότερη αξιολόγηση παρουσιάζει ο Naive Bayes με τιμές από 0.15 έως 0.33. Σχετικά με την κλάση "Tool Wear Failure" εκεί παρατηρείται αδυναμία αναγνώρισης σφαλμάτων από όλα τα μοντέλα.

Μητρώο Σύγχυσης (Confusion Matrix)

Στα σχήματα 7.7 και 7.8 παρουσιάζονται τα μητρώα σύγχυσης για κάθε ένα από τα μοντέλα. Τα μητρώα αυτά μας δίνουν μία αναλυτική εικόνα για τον αριθμό των δειγμάτων που ταξινομούνται, διακρίνοντας την κλάση, στην οποία ανήκουν και την κλάση, στην ο-




Σχήμα 7.6: Αποτελέσματα F1-Score Μοντέλων


ποία εντάχθηκαν από το μοντέλο. Γενικά, οι κλάσεις "Heat Dissipation Failure" και "No Failure" ανιχνεύονται αρκετά καλά από όλα τα μοντέλα, εν αντιθέσει με τις "Overstrain Failure", "Power Failure" και "Tool Wear Failure" όπου παρατηρούνται περισσότερα λάθη και εμφανίζονται αρκετά False Positives και False Negatives. Πιο συγκεκριμένα, το μοντέλο Λογιστικής Παλινδρόμησης ανιχνεύει αρκετά καλά την κλάση "No Failure", με 4046 σωστές ταξινομήσεις, αλλά παρουσιάζει αρκετά σημαντικό ποσοστό λαθών στην κλάση "Tool Wear Failure", με μόνο 16 σωστές ανιχνεύσεις και πληθώρα False Negatives. Ο Random Forest αποδίδει εξαιρετικά στις περισσότερες κλάσεις, με μερικές λανθασμένες επιλογές στις "Overstrain Failure" και "Tool Wear Failure". Ακολουθεί ο KNN με ικανοποιητικά αποτελέσματα στις κλάσεις "No Failure", "Heat Dissipation Failure" και "Overstrain Failure" και αρκετά λάθη στις περιπτώσεις των "Power Failure" και "Tool Wear Failure". Στον Naive Bayes παρατηρείται μεγάλος αριθμός False Positives και False Negatives για τις "Overstrain Failure" και "Tool Wear Failure", ενώ η αδυναμία του SVM εντοπίζεται στις ελάχιστες σωστές προβλέψεις σχετικά με σφάλμα "Power" και "Tool Wear".

Χαρακτηριστικές Καμπύλες Δέκτη (Area under the ROC Curve)


Στα σχήματα 7.9 και 7.10 παρουσιάζονται οι χαρακτηριστικές καμπύλες δέκτη για κάθε κλάση σε κάθε ένα από τα μοντέλα, παρέχοντας πληροφορία σχετικά με την σχέση των True Positive Rate και του False Positive Rate. Το AUC για τους αλγορίθμους Random Forest και Logistic Regression είναι πολύ υψηλό για όλες τις κλάσεις, με την κλάση "Tool Wear Failure" να παρουσιάζει μία πιο χαμηλή απόδοση, αλλά εξακολουθεί να είναι αρκετά υψηλή. Τα μοντέλα KNN και SVM παρουσιάζουν επίσης, αρκετά καλές επιδόσεις σε όλες τις κλάσεις εκτός της "Tool Wear Failure", όπου εντοπίζεται δυσκολία στην ανίχνευσή της. Τέλος, ο Μπεϋζιανός Ταξινομητής έχει μικρότερο AUC για την κλάση "Power Failure", στην οποία και αντιμετωπίζει δυσκολίες.




Σχήμα 7.7: Μητρώα Σύγκρισης Μοντέλων Λογιστικής Παλινδρόμησης και Τυχαίου Δάσους



Σχήμα 7.8: Μητρώα Σύγκρισης KNN, Naive Bayes, SVM



Σχήμα 7.9: Χαρακτηριστικές Καμπύλες Δέκτη Μοντέλων Λογιστικής Παλινδρόμησης και Τυχάιου Δάσους



Σχήμα 7.10: Χαρακτηριστικές Καμπύλες Δέκτη KNN, Naive Bayes, SVM

Συγκεντρωτικά Αποτελέσματα

Στον πίνακα 7.1 παρουσιάζονται οι τελικές μέσες τιμές κάθε μετρικής απόδοσης που χρησιμοποιήθηκε κατά την αξιολόγηση των αποτελεσμάτων για κάθε μοντέλο μηχανικής μάθησης, με ακρίβεια τριών δεκαδικών ψηφίων. Επίσης, στον πίνακα 7.2 παρουσιάζονται οι χρόνοι εκπαίδευσης και πρόβλεψης για κάθε μοντέλο σε δευτερόλεπτα. Οι χρόνοι εκπαίδευσης διαφέρουν από μοντέλο σε μοντέλο με τους Naive Bayes και KNN να μην ξεπερνούν τα 2 εκατοστά του δευτερολέπτου, ενώ οι υπόλοιποι εκπαιδεύονται για πάνω από ένα δευτερόλεπτο, με τον ταξινομητή SVM μάλιστα να διαρκεί περισσότερο από 8 δευτερόλεπτα. Σχετικά με τους χρόνους πρόβλεψης, όλοι διαρκούν λιγότερο από ένα δευτερόλεπτο με τον μέγιστο χρόνο να είναι τα 0.3991 του SVM και τον ελάχιστο τα 0.0036 της Λογιστικής Παλινδρόμησης.

Μοντέλο	Ακρίβεια	Ορθότητα	Ανάκληση	F1-Score	AUC
Random Forest	0.970	0.979	0.970	0.974	0.975
Support Vector Machine	0.963	0.972	0.963	0.967	0.928
K Nearest Neighbors	0.920	0.973	0.920	0.943	0.894
Logistic Regression	0.840	0.975	0.840	0.894	0.967
Naive Bayes	0.791	0.970	0.791	0.861	0.935

Πίνακας 7.1: Μέσες τιμές κάθε μετρικής απόδοσης για κάθε μοντέλο στο σύνολο δοκιμής

Μοντέλο	Χρόνος Εκπαίδευσης	Χρόνος Πρόβλεψης
Random Forest	1.8847	0.0154
Support Vector Machine	8.5430	0.3991
K Nearest Neighbors	0.0173	0.0514
Logistic Regression	3.0445	0.0036
Naive Bayes	0.0055	0.0044

Πίνακας 7.2: Χρόνοι Εκπαίδευσης και Πρόβλεψης των Μοντέλων Μηχανικής Μάθησης

7.6.2 Αποτελέσματα Ομαδοποίησης

Στην υποενότητα αυτή παρουσιάζονται τα αποτελέσματα, τα οποία προέκυψαν από την αξιολόγηση των αλγορίθμων ομαδοποίησης K-Means, BIRCH και Hierarchical Clustering, η υλοποίηση των οποίων περιγράφηκε στο **Κεφάλαιο 4**. Πιο συγκεκριμένα, στον πίνακα 7.3 αναγράφονται οι τιμές της μετρικής Silhouette για κάθε μοντέλο, ενώ στο σχήμα 7.11 απεικονίζεται η Silhouette Analysis κάθε cluster για όλα τα μοντέλα. Επίσης, στο σχήμα 7.12, απεικονίζονται στον τρισδιάστατο χώρο οι συστάδες, οι οποίες σχηματίστηκαν σε καθεμία από τις τρεις απόπειρες ομαδοποίησης.

Συγκεντρωτικά Αποτελέσματα

Παρατηρώντας τον πίνακα 7.3 φαίνεται πως και τα τρία μοντέλα ομαδοποίησης χαρακτηρίζονται από παρόμοιες επιδόσεις. Συγκεκριμένα, ο αλγόριθμος K-Μέσων μαζί με τον αλγόριθμο ιεραρχικής ομαδοποίησης έχουν σχεδόν ίδιο Silhouette Score με τιμές 0.373 και 0.378, αντίστοιχα, ενώ ακολουθεί ο αλγόριθμος BIRCH με score ίσο με 0.338. Τα αποτελέσματα αυτά δείχνουν πως τα μοντέλα διαχωρίζουν τα δεδομένα με μέτριο, αλλά ικανοποιητικό τρόπο.


Μοντέλο	Silhouette Score
K-Means	0.3731
BIRCH	0.3387
Hierarchical Clustering	0.3783

Πίνακας 7.3: Silhouette Scores για κάθε Μοντέλο Ομαδοποίησης

Silhouette Analysis

Το σχήμα 7.11 απεικονίζει την Silhouette Analysis κάθε ενός από τα τρία μοντέλα, για κάθε cluster ξεχωριστά. Όσον αφορά τον αλγόριθμο K-Μέσων, η μέση τιμή της Silhouette είναι 0.373, με τα clusters 2 και 3 να έχουν αρκετά καλή κατανομή με τιμές κοντά στο 0.5 για τα περισσότερα σημεία. Τα clusters 0 και 1 εμφανίζουν μικρές τιμές Silhouette και υλοποιούν τόσο καλή ομαδοποίηση. Για τον αλγόριθμο BIRCH, η μέση τιμή της Silhouette είναι 0.34 με τα clusters 1 και 2 να είναι συμπαγή αλλά να περιέχουν χαμηλές τιμές, ακόμα και αρνητικές. Αυτό σημαίνει πως μερικά σημεία έχουν ενταχθεί σε λάθος ομάδες, κάτι το οποίο παρατηρείται κυρίως στην συστάδα 1 και αποτελεί την αιτία για την μικρότερη μέση τιμή της Silhouette στον BIRCH. Τέλος, η Ιεραρχική Ομαδοποίηση επιτυγχάνει μέση τιμή Silhouette ίση με 0.378. Περιέχει τρία clusters με καλύτερο διαχωρισμό από αυτόν του BIRCH, ωστόσο και εδώ υπάρχουν σημεία που δεν έχουν τοποθετηθεί στην κατάλληλη ομάδα.

Η ύπαρξη μικρών ομάδων οφείλεται στον μικρό αριθμό δειγμάτων που αφορούν περιπτώσεις σφαλμάτων. Πρόκειται για ομάδες, οι οποίες δυσκολεύουν την ομαδοποίηση και τον πλήρη διαχωρισμό των δεδομένων, αλλά δεν δηλώνουν απαραίτητα κακή απόδοση των αλγορίθμων. Επίσης, στις ομάδες που δημιουργούνται, οι αρνητικές τιμές οφείλονται στο γεγονός πως δείγματα διαφορετικών ομάδων βρίσκονται πολύ κοντά μεταξύ τους, με αποτέλεσμα την δυσκολία διαχωρισμού.




Σχήμα 7.11: Silhouette Analysis των μοντέλων

Τρισδιάστατη Οπτικοποίηση Συστάδων

Η απεικόνιση των συστάδων που δημιουργήθηκαν από τους αλγορίθμους πραγματοποιείται με το t-SNE, το οποίο δημιουργεί χαμηλής διάστασης αναπαράσταση δεδομένων, αποκαλύπτοντας τις σχέσεις γειτνίασης και την τοπική δομή των δεδομένων. Παρόλο που είναι πιο αργό από το PCA, επιλέχθηκε λόγω ύπαρξης μη γραμμικών σχέσεων στα δεδομένα.

Στο σχήμα 7.12 φαίνεται πως και τα τρία μοντέλα ακολουθούν ένα παρόμοιο μοτίβο. Πιο συγκεκριμένα, παρατηρείται η δημιουργία δύο cluster, τα οποία καταλαμβάνουν μεγάλη περιοχή και εντάσσουν κυρίως δεδομένα που αφορούν περιπτώσεις μη-αποτυχίας. Από και πέρα ο αλγόριθμος K-Μέσων δημιουργεί άλλες δύο πιο μικρές και συμπαγείς συστάδες που περιέχουν κατά κύριο λόγο δείγματα σφαλμάτων. Η ιεραρχική ομαδοποίηση και ο BIRCH τοποθετούν τα υπόλοιπα δεδομένα σε μία τρίτη συστάδα, η οποία είναι ευδιάκριτη και αφορά δεδομένα αποτυχίας. Γενικά, φαίνεται πως ο K-Means έχει τον καλύτερο διαχωρισμό με εμφανή όρια ανάμεσα στα clusters, η ιεραρχική ομαδοποίηση ακολουθεί, αλλά περιλαμβάνει αρκετά αλληλεπικαλυπτόμενα clusters και ο BIRCH προσφέρει έναν μέτριο διαχωρισμό, όπου τα δύο μεγάλα clusters δεν είναι τόσο σαφώς ορισμένα.



Σχήμα 7.12: Τρισδιάστατη Οπτικοποίηση των συστάδων των μοντέλων


7.7 Αποτελέσματα Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής

7.7.1 Μοντέλα Μηχανικής Μάθησης βιβλιοθήκης Scikit-Learn

Παρακάτω παρουσιάζονται τα αποτελέσματα, τα οποία προέκυψαν για τις επιλεγμένες μετρικές αξιολόγησης, όσον αφορά τα μοντέλα παλινδρόμησης του Συστήματος Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής. Στα σχήματα 7.13, 7.14 και 7.15, παρουσιάζονται τα διαγράμματα Μέσου Τετραγωνικού Σφάλματος, Μέσου Απόλυτου Σφάλματος και Συντελεστή Προσδιορισμού αντίστοιχα για τα μοντέλα μηχανικής μάθησης που παρουσιάστηκαν στο **Κεφάλαιο 5**, ως προς το σύνολο δεδομένων ελέγχου. Ακόμη, μέσω των σχημάτων 7.16, 7.17, 7.19, 7.18, 7.20 απεικονίζονται οι αναλυτικές προβλέψεις των αλγορίθμων για κάθε κύκλο ζωής του συνόλου ελέγχου σε σύγκριση με τις πραγματικές τιμές της εναπομείνουσας χρήσιμης ζωής.

Μέσο Τετραγωνικό Σφάλμα (MSE)


Το παρακάτω διάγραμμα στο σχήμα 7.13 περιέχει και συγκρίνει τις τιμές του Μέσου Τετραγωνικού Σφάλματος για τους αλγορίθμους Random Forest, XGBoost, K-Nearest Neighbors, Linear Regression και Support Vector Machines. Είναι σαφές πως ο αλγόριθμος Τυχαίου Δάσους και το μοντέλο XGBoost αποδίδουν πολύ καλύτερα σε σχέση με τους υπόλοιπους, ελαχιστοποιώντας το σφάλμα σε 323.66 και 328.1 μονάδες, αντίστοιχα. Σε επίπεδα απόδοσης ακολουθεί ο KNN, ο οποίος επιστρέφει μέσο τετραγωνικό σφάλμα ίσο με 489.49. Τέλος, σε παρόμοια αξιολόγηση κυμαίνονται η Γραμμική Παλινδρόμηση και οι Μηχανές Διανυσματικής Στήριξης. Αυτές έχουν τα δύο μεγαλύτερα τετραγωνικά σφάλματα ξεπερνώντας τις 520 μονάδες.



Σχήμα 7.13: Μέσο Τετραγωνικό Σφάλμα Μοντέλων

Μέσο Απόλυτο Σφάλμα (MAE)


Το παρακάτω διάγραμμα στο σχήμα 7.14 περιέχει και συγκρίνει τις τιμές του Μέσου Απόλυτου Σφάλματος για τους αλγόριθμους Random Forest, XGBoost, K-Nearest Neighbors, Linear Regression και Support Vector Machines. Σε σχέση με το Μέσο Τετραγωνικό Σφάλμα, το Μέσο Απόλυτο προσφέρει ουσιαστικότερη πληροφορία, καθώς εκφράζει την απόλυτη διαφορά μεταξύ πραγματικής και προβλεπόμενης τιμής. Φαίνεται πως τις κρυφαίες επιδόσεις τις έχουν ξανά ο αλγόριθμος Τυχαίου Δάσους με σφάλμα 13.54 και το μοντέλο XGBoost με σφάλμα 13.65. Στην περίπτωση του απόλυτου σφάλματος μετά τα δύο καλύτερα μοντέλα, ακολουθούν το μοντέλο SVM με 16.79 και ο αλγόριθμος των K-Πλησιέστερων Γειτόνων με σφάλμα 16.86. Η χειρότερη επίδοση παρουσιάζεται από την Γραμμική Παλινδρόμηση με ικανοποιητικό βέβαια σφάλμα ίσο με 17.92.



Σχήμα 7.14: Μέσο Απόλυτο Σφάλμα Μοντέλων

Συντελεστή Προσδιορισμού (R^2)


Το σχήμα 7.15 παρέχει πληροφορίες σχετικά με τον βαθμό προσαρμογής κάθε μοντέλου στα δεδομένα και αξιολογεί την επεξηγηματική ισχύ του. Όπως και στις προηγούμενες μετρίκες, τον μεγαλύτερο συντελεστή προσδιορισμού, 0.81, τον έχουν τα μοντέλα Random Forest και XGBoost. Ο αλγόριθμος K-Πλησιέστερων Γειτόνων έχει τον τρίτο μεγαλύτερο συντελεστή, ίσο με 0.72, ενώ τα Support Vector Machines και Linear Regression έχουν την τιμή 0.70. Συνεπώς, από αυτούς τους συντελεστές προκύπτει ότι και τα πέντε μοντέλα προσαρμόστηκαν αρκετά καλά γύρω από το σύνολο δεδομένων και κάνουν αξιόπιστες προβλέψεις.



Σχήμα 7.15: Συντελεστής Προσδιορισμού (R^2) Μοντέλων


Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού

Στα σχήματα 7.16, 7.17, 7.18, 7.19 και 7.20 απεικονίζονται για κάθε μία από τις 100 μονάδες κινητήρων, ο πραγματικός αριθμός των κύκλων ζωής που της απομένουν σε σύγκριση με τον αντίστοιχο αριθμό που προέβλεψε κάθε μοντέλο.




Σχήμα 7.16: Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στον αλγόριθμο Τυχαίου Δάσους


Σε γενικές γραμμές παρατηρείται πως οι περιπτώσεις πλήρους αστοχίας της πρόβλεψης, δηλαδή η διαφορά μεταξύ προβλεπόμενης και πραγματικής τιμής να είναι πάνω από 15-20 κύκλους ζωής είναι ελάχιστες. Στις περιπτώσεις του Random Forest και του XGBoost, οι οποίοι έχουν και το μικρότερο Μέσο Απόλυτο Σφάλμα, παρατηρούνται κάποιες διαφορές




Σχήμα 7.17: Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στο XGBoost



Σχήμα 7.18: Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στον αλγόριθμο KNN



Σχήμα 7.19: Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στην SVM



Σχήμα 7.20: Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στην Γραμμική Παλινδρόμηση

όταν οι εναπομείναντες κύκλοι ζωής είναι πάνω από 80, αλλά σε πιο μικρούς αριθμούς κύκλων ζωής αποδίδουν εξαιρετικά. Στον αλγόριθμο K-Πλησιέστερων Γειτόνων παρατηρείται μία τάση η προβλεπόμενη τιμή να είναι σχεδόν πάντα μεγαλύτερη από την πραγματική, ωστόσο οι διαφορές δεν είναι ιδιαίτερα μεγάλες. Αντιθέτως, στην Μηχανή Διανυσματικής Στήριξης συνήθως, οι προβλεπόμενες τιμές είναι μικρότερες από τις πραγματικές. Τέλος, οι μεγαλύτερες διαφορές εντοπίζονται στην Γραμμική Παλινδρόμηση, η οποία όπως φάνηκε και στο σχήμα 7.14 έχει και το μεγαλύτερο Απόλυτο Σφάλμα.


7.7.2 Αναδρομικό Νευρωνικό Δίκτυο Μακράς Βραχύχρονης Μνήμης

Παρακάτω παρουσιάζονται τα αποτελέσματα, τα οποία προέκυψαν για τις επιλεγμένες μετρικές αξιολόγησης, όσον αφορά το Αναδρομικό Νευρωνικό Δίκτυο Μακράς Βραχύχρονης Μνήμης, το οποίο παρουσιάστηκε στο **Κεφάλαιο 6**. Όπως και στους αλγορίθμους του **Κεφαλαίου 5**, έτσι και στην περίπτωση του νευρωνικού δικτύου, για την αξιολόγησή του χρησιμοποιήθηκαν οι κλασικές μετρικές του Μέσου Τετραγωνικό Σφάλματος, του Μέσου Απολύτου Σφάλματος και ο Συντελεστής Προσδιορισμού, με τα αποτελέσματα να παρουσιάζονται στο σχήμα 7.21. Επίσης, για την καλύτερη κατανόηση των προβλέψεων του νευρωνικού δικτύου, στο σχήμα 7.22 απεικονίζονται για κάθε μία μονάδα κινητήρα, η προβλεπόμενη τιμή σε σύγκριση με την πραγματική.

Βασικές Μετρικές Αξιολόγησης για το Νευρωνικό Δίκτυο

Στο σχήμα 7.21 απεικονίζονται τα αποτελέσματα αξιολόγησης του Αναδρομικού Νευρωνικού Δικτύου όσον αφορά τα σύνολα εκπαίδευσης και επικύρωσης κατά μήκος των εποχών του. Βλέπουμε ότι μετά την εποχή 5 το νευρωνικό συγκλίνει και επιτυγχάνει εξαιρετικές προβλέψεις. Το Μέσο Τετραγωνικό του Σφάλμα έπετα από την εποχή 10 καταλήγει στην τιμή 143.06, το Μέσο Απόλυτο Σφάλμα είναι ίσο με 8.46, ενώ και ο Συντελεστής Προσδιο-


ρισμού είναι ιδιαίτερα υψηλός και ίσος με 0.92. Όλα τα παραπάνω δείχνουν πως το δίκτυο εκπαιδεύτηκε επαρκώς με το σύνολο εκπαίδευσης και αποδίδει πολύ καλά σε νέα δεδομένα.



Σχήμα 7.21: Μέσο Τετραγωνικό Σφάλμα, Μέσο Απόλυτο Σφάλμα, Συντελεστής Προσδιορισμού Νευρωνικού Δικτύου

Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού

Στο σχήμα 7.22 απεικονίζονται για κάθε μία από τις 100 μονάδες κινητήρων, ο πραγματικός αριθμός των κύκλων ζωής που της απομένουν σε σύγκριση με τον αντίστοιχο αριθμό που προέβλεψε το νευρωνικό δίκτυο. Οι πιο μεγάλες διαφορές παρατηρούνται όταν οι εναπομείναντες κύκλοι ζωής της μηχανής είναι πολλοί, ενώ στις πιο πολλές περιπτώσεις είναι μικρότερες από 8.46 που είναι και το Μέσο Απόλυτο Σφάλμα.




Σχήμα 7.22: Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού στο Αναδρομικό Νευρωνικό Δίκτυο

7.7.3 Ανάλυση Αποτελεσμάτων Βάσει του Αριθμού Κύκλων Ζωής

Ανάλογα με την υγεία μίας μονάδας κινητήρα και των κύκλων ζωής που της απομένουν, αλλάζει και η βαρύτητα μίας πρόβλεψης. Επειδή οι προβλέψεις που αφορούν τους τελευταίους κύκλους ζωής του εξοπλισμού είναι πολύ πιο κρίσιμες, οι μονάδες του συνόλου δοκιμής χωρίστηκαν βάσει εναπομείναντων κύκλων σε: Υγιείς Μονάδες [91,145], Μονάδες Χαμηλού Ρίσκου [51,90], Μονάδες Μεσαίου Ρίσκου [21,50] και Μονάδες Υψηλού Ρίσκου [0,20]. Η παραπάνω διαδικασία αφορά τα δύο μοντέλα με τα καλύτερα αποτελέσματα, τον Αλγόριθμο Τυχαίου Δάσους και το Αναδρομικό Νευρωνικό Δίκτυο.


Το ακόλουθο σχήμα 7.23 παρουσιάζει αναλυτικά το Μέσο Τετραγωνικό Σφάλμα και το Μέσο Απόλυτο Σφάλμα των προβλέψεων των δύο μοντέλων σε κάθε τμήμα. Είναι εμφανές πως τα δύο μοντέλα αποδίδουν πολύ καλύτερα σε μονάδες που ανήκουν στις κατηγορίες Μεσαίου και Υψηλού Ρίσκου. Ειδικότερα, και από τις δύο μετρικές αξιολόγησης φαίνεται πως η απόδοση των μοντέλων πέφτει πολύ κάτω από τον μέσο όρο στα τμήματα [0,20] και [21,40]. Ο αλγόριθμος Τυχαίου Δάσους έχει Μέσο Τετραγωνικό Σφάλμα 323.66 για το σύνολο και καταγράφει 149.23 και 194.86 στις κατηγορίες Υψηλού και Μεσαίου Ρίσκου. Έχει επίσης, Μέσο Απόλυτο Σφάλμα ίσο με 13.54 για το σύνολο, το οποίο μειώνεται σε 6.98 στο διάστημα [0,20] και σε 10.07 στο διάστημα [21,40]. Αντίστοιχα, οι τιμές του Αναδρομικού Νευρωνικού Δικτύου στο πλήρες σύνολο επικύρωσης είναι 143.06 για το Μέσο Τετραγωνικό Σφάλμα και 8.46 για το Μέσο Απόλυτο Σφάλμα, την ώρα που στα τμήματα Υψηλού και Μεσαίου Ρίσκου μειώνονται σε 21.85, 91.34 και 3.97, 7.02. Χειρότερες είναι οι επιδόσεις στις κατηγορίες Χαμηλού Ρίσκου και Υγιών Μονάδων, με αποτέλεσμα να ανεβαίνουν και οι μέσοι όροι των αποτελεσμάτων των μοντέλων. Τέλος, παρατηρείται ότι το Αναδρομικό Νευρωνικό Δίκτυο υπερτερεί έναντι του Αλγορίθμου Τυχαίου Δάσους ξεκάθαρα, εκτός από την κατηγορία Χαμηλού Ρίσκου, όπου ο δεύτερος αποδίδει πολύ καλύτερα.




Σχήμα 7.23: Σύγκριση Αξιολόγησης Αλγορίθμου Τυχαίου Δάσους και Αναδρομικού Νευρωνικού Δικτύου ανά Τμήμα

Προβλεπόμενος Αριθμός Κύκλων Ζωής εναντίον Πραγματικού ανά Κατηγορία

Στα σχήματα 7.24 και 7.25 παρουσιάζονται οι διαφορές μεταξύ προβλεπόμενης και πραγματικής τιμής, για κάθε πρόβλεψη που πραγματοποιήθηκε όσον αφορά το σύνολο ελέγχου, το οποίο περιέχει 100 μονάδες, από τον Αλγόριθμο Τυχαίου Δάσους και το Αναδρομικό Νευρωνικό Δίκτυο. Κοινό χαρακτηριστικό των προβλέψεων των δύο μοντέλων είναι πως τις μικρότερες αστοχίες τις παρουσιάζουν στις κατηγορίες Υψηλού και Μεσαίου Ρίσκου, οι οποίες είναι και οι πιο κρίσιμες στην διαδικασία της Προγνωστικής Συντήρησης. Αυτό είναι προφανές, καθώς οι περισσότερες τιμές στα τμήματα $[0,20]$ και $[21,40]$ είναι μονοψήφιος αριθμός. Επίσης, και στα τέσσερα διαφορετικά τμήματα παρατηρείται ότι τα μοντέλα τείνουν να προβλέπουν τιμές κύκλων που απομένουν, μεγαλύτερες από τις πραγματικές. Εξαιρεση αποτελεί η κατηγορία Υγιούς Κινητήρα, γεγονός που προκύπτει από το άνω όριο, το οποίο τέθηκε στο σύνολο εκπαίδευσης κατά την επεξεργασία του συνόλου δεδομένων.



Σχήμα 7.24: Διαφορές Προβλεπόμενων Εναπομείναντων Κύκλων Ζωής από τους Πραγματικούς για τις προβλέψεις του Αλγορίθμου Τυχαίου Δάσους



Σχήμα 7.25: Διαφορές Προβλεπόμενων Εναπομείναντων Κύκλων Ζωής από τους Πραγματικούς για τις προβλέψεις του Αναδρομικού Νευρωνικού Δικτύου

7.7.4 Συγκεντρωτικά Αποτελέσματα Συστήματος Πρόβλεψης Εναπομείνου Χρήσιμης Ζωής

Στους παρακάτω πίνακες 7.4, 7.5 και 7.6 παρουσιάζονται τα συγκεντρωτικά αποτελέσματα του Συστήματος Πρόβλεψης Εναπομείνου Χρήσιμης Ζωής Μονάδων Κινητήρων. Πιο αναλυτικά, ο πίνακας 7.4 περιέχει τις τελικές μέσες τιμές κάθε μετρικής απόδοσης που χρησιμοποιήθηκε κατά την αξιολόγηση των αποτελεσμάτων για κάθε μοντέλο μηχανικής μάθησης. Ο πίνακας 7.5 παρουσιάζει τα συγκριτικά αποτελέσματα μεταξύ Αλγορίθμου Τυχαίου Δάσους και Νευρωνικού Δικτύου LSTM ανά υποσύνολο και τέλος, ο πίνακας 7.6 περιέχει τους χρόνους εκπαίδευσης και πρόβλεψης των μοντέλων.

Μοντέλο	MSE	MAE	R^2 Score
Random Forest	323.66	13.54	0.81
Support Vector Machine	526.56	16.79	0.70
K Nearest Neighbors	489.49	16.86	0.72
Linear Regression	521.90	17.92	0.70
XGBoost	328.10	13.65	0.81
LSTM Neural Network	143.6	8.46	0.92

Πίνακας 7.4: Μέσες τιμές κάθε μετρικής απόδοσης για κάθε μοντέλο στο σύνολο δοκιμής

Subset	Random Forest		LSTM	
	MSE	MAE	MSE	MAE
Υψηλό Ρίσκο	149.63	6.98	21.85	3.97
Μεσαίο Ρίσκο	194.86	10.07	91.34	7.02
Χαμηλό Ρίσκο	405.85	16.26	520.09	20.29
Υγιής Κινητήρας	394.28	15.87	185.31	11.17

Πίνακας 7.5: Σύγκριση Αλγορίθμου Τυχαίου Δάσους και Νευρωνικού Δικτύου LSTM σε διαφορετικά υποσύνολα

Μοντέλο	Χρόνος Εκπαίδευσης	Χρόνος Πρόβλεψης
Random Forest	2.917	0.068
Support Vector Machine	10.413	0.060
K Nearest Neighbors	0.03	0.03
Linear Regression	0.01	0.001
XGBoost	0.25	0.001
LSTM	255.6	255.6

Πίνακας 7.6: Χρόνοι Εκπαίδευσης και Πρόβλεψης των Μοντέλων Μηχανικής Μάθησης

Κεφάλαιο 8

Συμπεράσματα και Μελλονικοί Στόχοι

8.1 Συμπεράσματα

Τα τελευταία χρόνια, η ραγδαία ανάπτυξη της τεχνολογίας έχει μεταμορφώσει σημαντικά τον χώρο της βιομηχανίας σε ολόκληρο τον κόσμο. Οι εξελίξεις στους τομείς της μηχανικής μάθησης, της ανάλυσης μεγάλου όγκου δεδομένων και στο Διαδίκτυο των Αντικειμένων έχουν ανοίξει τον δρόμο για την υλοποίηση πληθώρας έξυπνων και αποδοτικών διεργασιών. Μία από αυτές είναι και η Προγνωστική Συντήρηση του μηχανολογικού εξοπλισμού, κατά την οποία αξιοποιούνται τεχνικές βασισμένες σε δεδομένα, επιτρέποντας την έγκαιρη ανίχνευση βλαβών, την πρόβλεψη της στιγμής αποτυχίας του εξοπλισμού, την αποφυγή δαπανηρών διακοπών λειτουργίας και τη βελτιστοποίηση της παραγωγικής διαδικασίας. Στόχος της παρούσας διπλωματικής είναι η ανάπτυξη δύο συστημάτων που υλοποιούν τις δύο βασικές λειτουργίες της Προγνωστικής Συντήρησης, οι οποίες είναι η Ανίχνευση Ανωμαλιών και η Πρόβλεψη Εναπομείνουσας Χρήσιμης Ζωής του εξοπλισμού.

Όσον αφορά το Σύστημα Ανίχνευσης Ανωμαλιών, αυτό αποτελείται από ένα σύνολο δεδομένων που περιέχει δείγματα μίας μηχανής αλέσματος. Το σύνολο υπέστη τις απαραίτητες προσεγγίσεις προεπεξεργασίας, ενώ σε αυτό εφαρμόστηκαν μοντέλα μηχανικής μάθησης με σκοπό την ταξινόμηση των δειγμάτων της μηχανής στην κατάλληλη κλάση ανάλογα με την κατάσταση της υγείας της και την ομαδοποίηση των δεδομένων διακρίνοντας τα σε συστάδες βάσει των χαρακτηριστικών τους. Η χρήση διαδοσμένων μετρικών αξιολόγησης, αρχικά, απέδειξε πως ο Αλγόριθμος Τυχαίου Δάσους και οι Μηχανές Διανυσματικής Στήριξης υπερέχουν έναντι των υπολοίπων στην πλειονότητα των μετρικών. Ακόμη, πέραν της κλάσης Μη Αποτυχίας που αναγνωρίζεται εξαιρετικά, οι κατηγορίες σφαλμάτων παρόλο που αποτελούν σπάνιες περιπτώσεις, ανιχνεύονται σε ικανοποιητικό βαθμό από τα περισσότερα μοντέλα, με εξαίρεση τον Μπεϋζιανό ταξινομητή, αλλά και την περίπτωση λάθους Tool Wear. Σχετικά με τους χρόνους πρόβλεψης κανένα μοντέλο δεν ξεπερνούσε τα πέντε δέκατα του δευτερολέπτου, ενώ στην εκπαίδευση αυτό που καθυστέρησε περισσότερο ήταν το SVM. Η διαδικασία της ομαδοποίησης επέφερε μέτρια αποτελέσματα. Οι αλγόριθμοι κατά κύριο λόγο σχημάτισαν τρεις με τέσσερις συστάδες, οι οποίες πέτυχαν ως ένα βαθμό μία διάκριση μεταξύ υγιούς εξοπλισμού και περιπτώσεων αποτυχίας. Βάσει της μετρικής Shilhouette επικρατέστερος αποδείχθηκε ο αλγόριθμος K-Μέσων.

Το δεύτερο βασικό κομμάτι της διπλωματικής είναι το Σύστημα Πρόβλεψης Εναπομείνουσας Χρήσιμης Ζωής του εξοπλισμού, για το οποίο αξιοποιήθηκαν ένα σύνολο δεδομένων

με δείγματα από κινητήρες αεροσκαφών, μοντέλα μηχανικής μάθησης και ένα μοντέλο βαθιάς μάθησης. Στην περίπτωση υπολογισμού των εναπομείναντων κύκλων ζωής για κάθε μονάδα κινητήρα τα μοντέλα επιτυγχάνουν πολύ υψηλές επιδόσεις. Το αναδρομικό νευρωνικό δίκτυο, παρόλο που δεν έχει κάποια πολύπλοκη δομή, καταγράφει ιδιαίτερα ακριβείς προβλέψεις, ενώ από τα μοντέλα παλινδρόμησης αυτά που ξεχωρίζουν είναι ο Αλγόριθμος Τυχαίου Δάσους και ο XGBoost. Ακόμα μεγαλύτερη ακρίβεια προβλέψεων παρατηρείται σε μηχανές, των οποίων οι εναπομείναντες κύκλοι ζωής είναι λίγοι και βρίσκονται σε κρίσιμο στάδιο της λειτουργίας τους. Οι χρόνοι εκπαίδευσης και πρόβλεψης είναι αρκετά χαμηλοί με εξαίρεση την εκπαίδευση του νευρωνικού δικτύου που ξεπερνά το ένα λεπτό και των Μηχανών Διανυσματικής Στήριξης που διαρκεί περίπου δέκα δευτερόλεπτα.

8.2 Μελλονικοί Στόχοι

Η υλοποίηση των δύο συστημάτων Πρόγνωσης Συντήρησης, τα οποία παρουσιάστηκαν σε αυτή τη διπλωματική αποτελεί μία ιδανική αφετηρία για την καθολική εφαρμογή της Μηχανικής Μάθησης στον χώρο της βιομηχανίας. Στο πλαίσιο αυτό υπάρχουν περιθώρια για βελτιώσεις και προσθήκες στα συστήματα, αλλά και στον τρόπο λήψης των απαραίτητων δεδομένων από τις μηχανές.

Ένα σημαντικό εμπόδιο στην υλοποίηση ολοκληρωμένων και αποδοτικών συστημάτων Πρόγνωσης Συντήρησης είναι η έλλειψη πρόσβασης σε μεγάλο αριθμό συνόλων δεδομένων. Στην παρούσα διπλωματική εργασία αξιοποιήθηκαν δύο αρκετά καλά δομημένα σύνολα, ωστόσο γενικά οι βιομηχανίες για λόγους ιδιωτικότητας και ασφάλειας δεδομένων δεν δημοσιοποιούν τις μετρήσεις τους με αποτέλεσμα τα διαθέσιμα σύνολα να είναι ελάχιστα. Επίσης, το πρόβλημα έλλειψης ικανοποιητικού όγκου δεδομένων εντείνεται από το γεγονός ότι σε πραγματικές συνθήκες λειτουργίας, οι περιπτώσεις ύπαρξης βλάβης ή αποτυχίας σε μία μηχανή είναι λίγες και δεν επαρκούν για την σωστή εκπαίδευση των μοντέλων. Συνεπώς, η διάθεση όλο και περισσότερων συνόλων δεδομένων από τις βιομηχανίες, καθώς και η εξομίωση περισσότερων περιπτώσεων αποτυχίας με βάση πραγματικά δεδομένα είναι απαραίτητες εξελίξεις για την ανάπτυξη αποδοτικότερων και πληρέστερων συστημάτων, όπως στην περίπτωση της δημιουργίας συστάδων από δεδομένα διαφορετικών χαρακτηριστικών και κατηγοριών.

Μία ακόμη σημαντική προσθήκη στον σχεδιασμό των δύο συστημάτων Πρόγνωσης Συντήρησης, θα ήταν η εκπαίδευση καινούριων μοντέλων Μηχανικής Μάθησης ή η ανάπτυξη νέων νευρωνικών δικτύων, τα οποία πιθανόν να οδηγήσουν σε υψηλότερες επιδόσεις. Ωστόσο, πέραν της εφαρμογής νέων μοντέλων, θα μπορούσαν αξιοποιηθούν τα ήδη υπάρχοντα με έναν συνεργατικό τρόπο, συνδυάζοντας τα θετικά στοιχεία κάθε αλγορίθμου με σκοπό την ευελιξία και την αντιμετώπιση διαφορετικού είδους προβλημάτων.

Τέλος, ένας στόχος είναι να επιχειρηθεί η επέκταση των συστημάτων, έτσι ώστε να μην περιορίζουν τις δυνατότητες τους μόνο σε συγκεκριμένες κατηγορίες μηχανών. Αφού τροφοδοτηθούν με δεδομένα, τα οποία αφορούν ποικίλα συστήματα και περιέχουν μεγάλο όγκο μετρήσεων θα μπορούν να καλύψουν μεγάλο όγκο αναγκών στη βιομηχανία.

Βιβλιογραφία

- [1] Data clustering: Intro, methods, applications, *Encord*, <https://encord.com/blog/data-clustering-intro-methods-applications/>, 2023.
- [2] Mounia Achouch, Mariya Dimitrova, Khaled Ziane, Sasan Sattarpanah Karganroudi, Rizck Dhouib, Hussein Ibrahim και Mehdi Adda, On predictive maintenance in industry 4.0: Overview, models, and challenges, *Applied Sciences*, 12(16), <https://www.mdpi.com/2076-3417/12/16/8081>, 2022.
- [3] Rachel Johnson Aditya Baru, Three ways to estimate remaining useful life for predictive maintenance, *MathWorks*, <https://fr.mathworks.com/company/technical-articles/three-ways-to-estimate-remaining-useful-life-for-predictive-maintenance.html>, 2023.
- [4] aishwarya.27, Recurrent neural networks, *Geeks for Geeks*, <https://www.geeksforgeeks.org/introduction-to-recurrent-neural-network/>, 2023.
- [5] Jafar Alzubi, Anand Nayyar και Akshi Kumar, Machine learning from theory to algorithms: An overview, *Journal of Physics Conference Series*, 1142(1):012012, <https://app.dimensions.ai/details/publication/pub.1110322334>, 2018.
- [6] S. Arena, E. Florian, I. Zennaro, P.F. Orrù και F. Sgarbossa, A novel decision support system for managing predictive maintenance strategies based on machine learning approaches, *Safety Science*, 146:105529, <https://www.sciencedirect.com/science/article/pii/S0925753521003726>, 2022.
- [7] Ritwik Raha Aritra Roy Gosthipaty, Devjyoti Chakraborty, Long short-term memory networks, *pyimagesearch*, <https://pyimagesearch.com/2022/08/01/long-short-term-memory-networks/>, 2022.
- [8] Mayank Banoula, Introduction to long short-term memory(lstm), *Simplilearn*, <https://www.simplilearn.com/tutorials/artificial-intelligence-tutorial/lstm>, 2023.

- [9] Jam Canda, Machine learning techniques for predictive maintenance, *Medium*, <https://medium.com/@jam.canda/machine-learning-techniques-for-predictive-maintenance-662d056e7f08>, 2024.
- [10] Jean Christophe Chouinard, How to use k-nearest neighbors (knn) with python (scikit-learn example), *JC Chouinard*, <https://www.jcchouinard.com/k-nearest-neighbors/>, 2023.
- [11] M.H. Dunham. *Data Mining: Introductory And Advanced Topics*. Pearson Education. <https://books.google.gr/books?id=O6F9iwsqZQwC>, 2006.
- [12] Fábio Ferraz Júnior, Roseli Aparecida Francelin Romero και Sheng Jen Hsieh, Machine learning for the detection and diagnosis of anomalies in applications driven by electric motors, *Sensors*, 23(24), <https://www.mdpi.com/1424-8220/23/24/9725>, 2023.
- [13] Eleonora Florian, Fabio Sgarbossa και Ilenia Zennaro, Machine learning-based predictive maintenance: A cost-oriented model for implementation, *International Journal of Production Economics*, 236:108114, <https://www.sciencedirect.com/science/article/pii/S0925527321000906>, 2021.
- [14] Geeksforgeeks, Understanding of lstm networks, *Geeksforgeeks*, <https://www.geeksforgeeks.org/understanding-of-lstm-networks/>, 2023.
- [15] GeeksforGeeks, Logistic regression in machine learning, *Geeks for Geeks*, <https://www.geeksforgeeks.org/understanding-logistic-regression/>, 2024.
- [16] GeeksforGeeks, Naive bayes classifiers, *Geeks for Geeks*, <https://www.geeksforgeeks.org/naive-bayes-classifiers/>, 2024.
- [17] GeeksforGeeks, Xgboost, *Geeks for Geeks*, <https://www.geeksforgeeks.org/xgboost/>, 2024.
- [18] S. Gollapudi. *Practical Machine Learning*. Packt Publishing. <https://books.google.gr/books?id=WmsdDAAAQBAJ>, 2016.
- [19] Jainvidip, Understanding decision trees, *Medium*, <https://medium.com/@jainvidip/understanding-decision-trees-1ba0ef5f6bb4>, 2024.
- [20] Nikhil Joshi, Most manufacturers are not industry 4.0 ready, *LinkedIn*, <https://www.linkedin.com/pulse/most-manufacturers-industry-40-ready-nikhil-joshi>, 2019.
- [21] Pooja Kamat και Rekha Sugandhi, Anomaly detection for predictive maintenance in industry 4.0- a survey, *E3S Web Conf.*, 170:02007, <https://doi.org/10.1051/e3sconf/202017002007>, 2020.

- [22] Vijay Kanade, What is a support vector machine? working, types, and examples, *Spicework*, <https://www.spiceworks.com/tech/big-data/articles/what-is-support-vector-machine/>, 2022.
- [23] Varun Khanchandani, Predictive analysis — netflix and spotify can read your mind!, *Medium*, <https://medium.com/@varun.khanchandani/predictive-analysis-netflix-and-spotify-can-read-your-mind-c78299f6df93>, 2021.
- [24] Monkey Learn, Machine learning, *Monkey Learn*, <https://monkeylearn.com/machine-learning/>, 2023.
- [25] Chongdang Liu, Linxuan Zhang, Yuan Liao, Cheng Wu και Gongzhuang Peng, Multiple sensors based prognostics with prediction interval optimization via echo state gaussian process, *IEEE Access*, III:1-1, 2019.
- [26] Kavita Mali, Everything you need to know about linear regression!, *Analytics Vidhya*, <https://www.analyticsvidhya.com/blog/2021/10/everything-you-need-to-know-about-linear-regression/>, 2024.
- [27] Kamal Medjaher, Diego Tobon-Mejia και Nouredine Zerhouni, Remaining useful life estimation of critical components with application to bearings., *IEEE Transactions on Reliability*, 61(2):292-302, <https://hal.science/hal-00737596>, 2012.
- [28] Kamal Medjaher, Diego Alejandro Tobon-Mejia και Nouredine Zerhouni, Remaining useful life estimation of critical components with application to bearings, *IEEE Transactions on Reliability*, 61(2):292-302, 2012.
- [29] JZ Mohammed και W Meira Jr, Data mining and machine learning: Fundamental concepts and algorithms, *Cambridge University: Cambridge, UK*, 2020.
- [30] Hari Narayanan, What is the best fit line?, *Linkedin*, <https://www.linkedin.com/pulse/what-best-fit-line-hari-narayanan-erspf>, 2024.
- [31] Artem Oppermann, What is deep learning and how does it work?, *Builtin*, <https://builtin.com/machine-learning/deep-learning>, 2023.
- [32] Abdelfetah Ouadah, Leila Zemmouchi-Ghomari και Nedjma Salhi, Selecting an appropriate supervised machine learning algorithm for predictive maintenance, *The International Journal of Advanced Manufacturing Technology*, 119, <https://link.springer.com/article/10.1007/s00170-021-08551-9>, 2022.
- [33] M. Pal, Random forest classifier for remote sensing classification, *International Journal of Remote Sensing*, 26(1):217-222, <https://doi.org/10.1080/01431160412331269698>, 2005.

- [34] Sunil Ray, Naive bayes classifier explained: Applications and practice problems of naive bayes classifier, *Analytics Vidhya*, <https://www.analyticsvidhya.com/blog/2017/09/naive-bayes-explained/>, 2024.
- [35] Jordi Roger Riba, Álvaro Gómez-Pau, Jimmy Martínez και Manuel Moreno-Eguilaz, On-line remaining useful life estimation of power connectors focused on predictive maintenance, *Sensors*, 21(11), <https://www.mdpi.com/1424-8220/21/11/3739>, 2021.
- [36] Biswajit Sahoo. Data-Driven Remaining Useful Life (RUL) Prediction, 2020, https://biswajitsahoo1111.github.io/rul_codes_open/.
- [37] Anshul Saini, Guide on support vector machine (svm) algorithm, *Analytics Vidhya*, <https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/>, 2024.
- [38] saumyasaxena2730, Deep learning, *Geeks for Geeks*, <https://www.geeksforgeeks.org/introduction-deep-learning/>, 2024.
- [39] Shipra Saxena, What is lstm? introduction to long short-term memory, *Analytics Vidhya*, <https://www.analyticsvidhya.com/blog/2021/03/introduction-to-long-short-term-memory-lstm/>, 2024.
- [40] J.Z. Sikorska, M. Hodkiewicz και L. Ma, Prognostic modelling options for remaining useful life estimation by industry, *Mechanical Systems and Signal Processing*, 25(5):1803-1836, <https://www.sciencedirect.com/science/article/pii/S0888327010004218>, 2011.
- [41] Oliver J. Sutton, Introduction to k nearest neighbour classification and condensed nearest neighbour data reduction, <https://api.semanticscholar.org/CorpusID:18781499>, 2012.
- [42] Andreas Theissler, Judith Pérez-Velázquez, Marcel Kettelgerdes και Gordon Elger, Predictive maintenance enabled by machine learning: Use cases and challenges in the automotive industry, *Reliability Engineering and System Safety*, 215:107864, <https://www.sciencedirect.com/science/article/pii/S0951832021003835>, 2021.
- [43] Danny Varghese, Comparative study on classic machine learning algorithms, *Towards Science*, <https://towardsdatascience.com/comparative-study-on-classic-machine-learning-algorithms-24f9ff6ab222>, 2018.
- [44] Analytics Vidhya, Introduction to xgboost algorithm in machine learning, *Analytics Vidhya*, <https://www.analyticsvidhya.com/blog/2018/09/>

an-end-to-end-guide-to-understand-the-math-behind-xgboost/,
2024.

[45] Dr. Roi Yehoshua, Random forests, *Medium*, <https://medium.com/@roiyehe/random-forests-98892261dc49>, 2023.

[46] Data Zero, What is industry 4.0?, *Dat4 Zero*, <https://dat4zero.eu/what-is-industry-4-0/>, 2024.



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

**Συστήμα Πρόγνωσης Συντήρησης Μηχανολογικού Εξο-
πλισμού και Προμηθειών με χρήση Μηχανικής Μάθησης**

Παπαχριστοφίλου Σαράντης

ΠΑΤΡΑ

ΟΚΤΩΒΡΙΟΣ 2024



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

**Συστήμα Πρόγνωσης Συντήρησης Μηχανολογικού Εξο-
πλισμού και Προμηθειών με χρήση Μηχανικής Μάθησης**

Παπαχριστοφίλου Σαράντης

ΠΑΤΡΑ

ΟΚΤΩΒΡΙΟΣ 2024